

Clase ED2: Datos agrupados y medidas de resumen

Histograma, ojiva, medidas de tendencia central, dispersión y posición. Diagrama de caja

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

- 1 Datos agrupados en intervalos
- 2 Histograma, polígono de frecuencias y ojiva
- 3 Medidas de tendencia central
- 4 Medidas de dispersión
- 5 Medidas de posición: cuartiles y diagrama de caja
- 6 Forma de la distribución: simetría
- 7 Resumen

¿Cuándo agrupar en intervalos?

Motivación

Cuando la variable es **continua**, o es discreta pero con **muchos valores distintos**, listar una frecuencia por cada valor deja de ser útil: hay demasiadas filas, muchas con frecuencia 0 o 1. La solución es agrupar el recorrido de los datos en **intervalos de clase** (o clases).

Elementos de una clase

- **Límites de clase:** extremos del intervalo, p. ej. $[L_i; L_{i+1})$.
- **Amplitud:** $a_i = L_{i+1} - L_i$ (suele tomarse constante para todas las clases).
- **Marca de clase:** punto medio $m_i = \frac{L_i + L_{i+1}}{2}$; es el valor “representante” de todos los datos que caen en esa clase.

Regla práctica para el número de clases

Con n datos, una guía usual es tomar entre $\sqrt{n}$ y $1 + \log_2(n)$ (regla de Sturges) intervalos, ajustando por conveniencia (evitar clases vacías o con una sola observación).

Tabla de frecuencias para datos agrupados

Intervalo	m_i	F_i	f_i	F_i^{ac}	f_i^{ac}
[70; 90)	80	2	0,022	2	0,022
[90; 110)	100	3	0,033	5	0,056
[110; 130)	120	6	0,067	11	0,122
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$


Convención de los límites

Con notación $[L_i; L_{i+1})$, el extremo izquierdo se incluye en la clase y el derecho no (pertenece a la clase siguiente). Así cada dato cae en **una y solo una** clase, sin ambigüedad.

Histograma

Definition

El **histograma** es un gráfico de barras **contiguas** (sin espacios entre sí), una por cada intervalo de clase, cuya **área** es proporcional a la frecuencia de la clase. Si todas las clases tienen igual amplitud, la altura de cada barra puede tomarse directamente igual a F_i (o f_i).



Diferencia clave con el diagrama de barras

Polígono de frecuencias y ojiva

Polígono de frecuencias absolutas

Se obtiene uniendo con segmentos los puntos (m_i, F_i) (marca de clase, frecuencia de esa clase). Cierra el polígono agregando una clase ficticia de frecuencia 0 antes de la primera y después de la última.

Ojiva (polígono de frecuencias acumuladas)

Se obtiene uniendo los puntos (L_{i+1}, F_i^{ac}) : en el **límite superior** de cada clase se ubica la frecuencia acumulada hasta esa clase inclusive. Es una función creciente que va de 0 (en el límite inferior de la primera clase) a n (en el límite superior de la última).

¿Para qué sirve la ojiva?

Permite leer gráficamente, en forma aproximada, cuántos datos (o qué proporción) son menores o iguales que un valor dado, y estimar cuantiles (mediana, cuartiles) por interpolación.

Media, mediana y moda: datos no agrupados

Media aritmética

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Usa toda la información, pero es sensible a valores extremos (outliers).

Mediana

Ordenados los datos, es el valor central: deja al 50 % de las observaciones por debajo y 50 % por arriba. Con n impar es el dato de posición $\frac{n+1}{2}$; con n par, el promedio de los dos datos centrales. Es **robusta** frente a valores atípicos.

Moda

Es el valor que más se repite (frecuencia máxima). Es la única medida de centralización que tiene sentido para variables **cualitativas**. Puede no existir o no ser única.

Media, mediana y moda: datos agrupados

Cuando los datos están agrupados en intervalos, se pierde la información individual y se trabaja con **valores aproximados**:

Media aproximada

$$\bar{x} \approx \frac{1}{n} \sum_i m_i F_i$$

(se supone que todos los datos de una clase se concentran en su marca m_i).

Clase modal y clase mediana

No se puede dar un único valor exacto: se identifica la **clase modal** (mayor F_i) y la **clase mediana** (la primera clase cuya F_i^{ac} supera $n/2$). Si se requiere un valor puntual, se puede usar la marca de esa clase, o interpolar linealmente dentro de ella.

Rango, varianza y desvío estándar

Rango

$R = x_{\text{máx}} - x_{\text{mín}}$. Muy simple, pero solo usa dos datos (muy sensible a outliers).

Varianza muestral

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right)$$

Promedio (casi) de los cuadrados de las desviaciones respecto a la media. La segunda forma (**fórmula de cálculo**) evita restar cada dato de la media uno por uno: solo requiere $\sum x_i$ y $\sum x_i^2$.

Desvío estándar

$s = \sqrt{s^2}$: mismas unidades que la variable original (a diferencia de s^2).

Coeficiente de variación

Definition

$$CV = \frac{s}{\bar{x}}$$

Es la razón entre el desvío estándar y la media: mide la dispersión *en relación con* la magnitud típica de los datos (**variabilidad relativa**). Suele expresarse en porcentaje.

Ejemplo

Si $\bar{x} = 80$ y $s = 20$, entonces $CV = 20/80 = 0,25 = 25 \%$.

¿Para qué sirve y cuándo no usarlo?

- Es adimensional: permite comparar la dispersión de **dos variables distintas** (o dos muestras con medias muy distintas), algo que s sola no permite.
- No debe usarse si la variable toma valores negativos, o si el cero de la escala es arbitrario (p.ej. temperatura en $^{\circ}\text{C}$ o $^{\circ}\text{F}$).

Varianza y desvío para datos agrupados

Con datos agrupados en intervalos, se aproxima igual que la media, usando las marcas de clase m_i :

$$s^2 \approx \frac{1}{n-1} \sum_i (m_i - \bar{x})^2 F_i = \frac{1}{n-1} \left(\sum_i m_i^2 F_i - n\bar{x}^2 \right)$$

Interpretación

Todo lo calculado a partir de datos agrupados (media, mediana, moda, varianza) es una **aproximación**: se pierde precisión respecto de calcular con los datos individuales, porque cada observación se trata como si estuviera exactamente en la marca de su clase.

Cuantiles y cuartiles

Definition

Los **cuantiles** dividen a los datos ordenados en partes con igual cantidad de observaciones. Los **cuartiles** Q_1 , Q_2 , Q_3 dividen a los datos en 4 partes iguales (25 % cada una):

- Q_1 (primer cuartil): 25 % de los datos por debajo.
- Q_2 (segundo cuartil) = **mediana**: 50 % de los datos por debajo.
- Q_3 (tercer cuartil): 75 % de los datos por debajo.

Rango intercuartílico (RIC)


$$RIC = Q_3 - Q_1$$

Es el rango del 50 % central de los datos: una medida de dispersión **robusta** frente a valores extremos (a diferencia del rango o la varianza).

Diagrama de caja (boxplot)

Construcción: resumen de cinco números

Se basa en $x_{\min}$, Q_1 , Q_2 (mediana), Q_3 , $x_{\max}$ (ajustados por outliers, ver siguiente diapositiva). La caja va de Q_1 a Q_3 , con una línea en la mediana; los “bigotes” se extienden hacia los valores no atípicos más alejados.



Valores atípicos (outliers)

Definition

Un dato x se considera **valor atípico (outlier)** si:

$$x < Q_1 - 1,5 \cdot RIC \quad \text{o} \quad x > Q_3 + 1,5 \cdot RIC.$$

Efecto sobre el diagrama de caja


Los outliers se marcan individualmente con un punto o asterisco (*), **fuera** de los bigotes. En ese caso, el bigote ya no llega hasta $x_{\min}/x_{\max}$, sino hasta el dato más extremo que *no* es atípico.

Diagramas de caja comparativos (side-by-side)

Colocar varios boxplots uno al lado del otro (p.ej. por sexo, por máquina, por grupo) permite **comparar visualmente** posición central, dispersión, simetría y presencia de outliers entre distintos grupos, sin necesidad de superponer histogramas.


Formas de la distribución

Asimetría Negativa




$$\bar{x} < \text{Mediana} < \text{Moda}$$

Simétrica



$$\bar{x} \approx \text{Mediana} \approx \text{Moda}$$

Asimetría Positiva




$$\text{Moda} < \text{Mediana} < \bar{x}$$

Simetría reflejada en el Boxplot

Lectura rápida de la forma mediante el Diagrama de Caja

- **Simétrica:** La mediana está justo al centro de la caja ($Q_2 - Q_1 \approx Q_3 - Q_2$) y los bigotes tienen longitudes equivalentes.
- **Asimétrica a derecha (+):** La mediana queda desplazada hacia Q_1 , el bigote derecho es más largo y suele haber outliers en el extremo superior.
- **Asimétrica a izquierda (-):** La mediana queda desplazada hacia Q_3 , el bigote izquierdo es más largo y suele haber outliers en el extremo inferior.



Resumen de la clase

- Con variables continuas o muchos valores distintos, se **agrupa en intervalos** (marca de clase, amplitud) y se resume con **histograma, polígono de frecuencias y ojiva**.
- **Tendencia central**: media (usa toda la info, sensible a outliers), mediana (robusta), moda (única para cualitativas).
- **Dispersión**: rango, varianza s^2 y desvío s (fórmula de cálculo: $\sum x_i^2 - n\bar{x}^2$), y coeficiente de variación $CV = s/\bar{x}$ para comparar variabilidad relativa.
- **Posición**: cuartiles Q_1, Q_2, Q_3 y rango intercuartílico $RIC = Q_3 - Q_1$.
- El **diagrama de caja** resume los cinco números y expone outliers ($x < Q_1 - 1,5 RIC$ o $x > Q_3 + 1,5 RIC$); side-by-side permite comparar grupos.
- La forma de la distribución (simétrica / asimétrica) se lee comparando media, mediana y moda, o la forma del boxplot/histograma.
- Con esto ya se cuenta con todas las herramientas para resolver la Práctica 1 de Estadística Descriptiva.