

Clase 13: Distribuciones asociadas al muestreo normal

Unidad 3: Vectores aleatorios

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

- 1 Introducción
- 2 Distribución chi-cuadrado
- 3 Distribución t de Student
- 4 Distribución F de Snedecor
- 5 Distribución multinomial
- 6 Distribución normal multivariada
- 7 Síntesis: el rol de estas distribuciones
- 8 Resumen

¿Por qué estas distribuciones?

Contexto

En las próximas unidades trabajaremos con **muestras aleatorias** $X_1, \dots, X_n$ y con estadísticos calculados a partir de ellas (medias, varianzas muestrales, etc.). Cuando la población de origen es normal, estos estadísticos tienen distribuciones que **no** son normales, pero que se derivan de ella de forma exacta.

¿Por qué estas distribuciones?

Contexto

En las próximas unidades trabajaremos con **muestras aleatorias** $X_1, \dots, X_n$ y con estadísticos calculados a partir de ellas (medias, varianzas muestrales, etc.). Cuando la población de origen es normal, estos estadísticos tienen distribuciones que **no** son normales, pero que se derivan de ella de forma exacta.

Las protagonistas de hoy

- Distribución **chi-cuadrado** (χ^2): base de la varianza muestral y de las pruebas de bondad de ajuste.
- Distribución **t de Student**: inferencia sobre la media con varianza desconocida.
- Distribución **F de Snedecor**: comparación de varianzas, análisis de varianza.
- Distribuciones **multinomial** y **multinormal**: generalizaciones multivariadas.

Todas son funciones de variables aleatorias normales independientes: por eso pertenecen naturalmente a esta unidad.

Definición

Definition (Chi-cuadrado con n grados de libertad)

Si $Z_1, \dots, Z_n$ son variables aleatorias independientes con distribución $N(0, 1)$, la variable

$$\chi^2 = Z_1^2 + Z_2^2 + \dots + Z_n^2$$

se dice que tiene distribución **chi-cuadrado con n grados de libertad**, y se denota $\chi^2 \sim \chi_n^2$.

Definición

Definition (Chi-cuadrado con n grados de libertad)

Si $Z_1, \dots, Z_n$ son variables aleatorias independientes con distribución $N(0, 1)$, la variable

$$\chi^2 = Z_1^2 + Z_2^2 + \dots + Z_n^2$$

se dice que tiene distribución **chi-cuadrado con n grados de libertad**, y se denota $\chi^2 \sim \chi_n^2$.

Caso $n = 1$

Si $Z \sim N(0, 1)$, entonces $Z^2 \sim \chi_1^2$. Se puede mostrar (por cambio de variable) que su densidad es

$$f(x) = \frac{1}{\sqrt{2\pi x}} e^{-x/2}, \quad x > 0.$$

Densidad general y propiedades

Densidad de χ_n^2

$$f(x) = \frac{1}{2^{n/2}\Gamma(n/2)} x^{n/2-1} e^{-x/2}, \quad x > 0,$$

es decir, χ_n^2 coincide con la distribución **Gamma** $(\frac{n}{2}, \frac{1}{2})$.

Propiedades

- $E[\chi_n^2] = n$, $\text{Var}(\chi_n^2) = 2n$.
- **Propiedad reproductiva:** si $U \sim \chi_m^2$ y $V \sim \chi_n^2$ son independientes, entonces $U + V \sim \chi_{m+n}^2$ (consecuencia inmediata de la definición como suma de normales estándar al cuadrado).
- La densidad es asimétrica a derecha; a medida que n crece, se aproxima a una normal (por el Teorema Central del Límite).

Justificación de la propiedad reproductiva

Demostración.

Si $U = Z_1^2 + \cdots + Z_m^2$ con los $Z_i \sim N(0, 1)$ i.i.d., y $V = W_1^2 + \cdots + W_n^2$ con los $W_j \sim N(0, 1)$ i.i.d., y U, V independientes (es decir, los Z_i y W_j son en total $m + n$ variables $N(0, 1)$ independientes), entonces

$$U + V = Z_1^2 + \cdots + Z_m^2 + W_1^2 + \cdots + W_n^2$$

es, por definición, una suma de $m + n$ cuadrados de normales estándar independientes, luego $U + V \sim \chi_{m+n}^2$. □

Ejemplo 1

Example

Sean $Z_1, Z_2, Z_3 \sim N(0, 1)$ independientes. Sea $U = Z_1^2 + Z_2^2 \sim \chi_2^2$ y $V = Z_3^2 \sim \chi_1^2$. ¿Cuál es la distribución de $U + V$? Calcular $E[U + V]$ y $\text{Var}(U + V)$.

Ejemplo 1

Example

Sean $Z_1, Z_2, Z_3 \sim N(0, 1)$ independientes. Sea $U = Z_1^2 + Z_2^2 \sim \chi_2^2$ y $V = Z_3^2 \sim \chi_1^2$. ¿Cuál es la distribución de $U + V$? Calcular $E[U + V]$ y $\text{Var}(U + V)$.

Resolución

Como U y V son funciones de conjuntos disjuntos de variables independientes, U y V son independientes, y por la propiedad reproductiva $U + V = Z_1^2 + Z_2^2 + Z_3^2 \sim \chi_3^2$.

$$E[U + V] = 3, \quad \text{Var}(U + V) = 2 \cdot 3 = 6.$$

Relevancia para la varianza muestral

Resultado central (se demostrará formalmente más adelante)

Si $X_1, \dots, X_n$ es una muestra aleatoria de una población $N(\mu, \sigma^2)$, y

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

es la varianza muestral, entonces

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Por qué importa

Este resultado es la puerta de entrada a los intervalos de confianza y pruebas de hipótesis sobre σ^2 , y aparecerá constantemente en las unidades de **Inferencia Estadística**.

Definición

Definition (t de Student con n grados de libertad)

Si $Z \sim N(0, 1)$ y $U \sim \chi_n^2$ son **independientes**, la variable

$$T = \frac{Z}{\sqrt{U/n}}$$

tiene distribución **t de Student con n grados de libertad**, denotada $T \sim t_n$.

Densidad (sin demostración)

$$f(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi} \Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, \quad t \in \mathbb{R}.$$

Propiedades de la t de Student

Propiedades

- Simétrica respecto de 0, con forma de campana similar a la normal estándar pero con **colas más pesadas**.
- $E[T] = 0$ para $n > 1$ (no existe para $n = 1$).
- $\text{Var}(T) = \frac{n}{n-2}$ para $n > 2$ (siempre mayor que 1, la varianza de $N(0, 1)$).
- Cuando $n \rightarrow \infty$, la distribución t_n converge a la $N(0, 1)$: para muestras grandes, ambas son prácticamente indistinguibles.

Propiedades de la t de Student

Propiedades

- Simétrica respecto de 0, con forma de campana similar a la normal estándar pero con **colas más pesadas**.
- $E[T] = 0$ para $n > 1$ (no existe para $n = 1$).
- $\text{Var}(T) = \frac{n}{n-2}$ para $n > 2$ (siempre mayor que 1, la varianza de $N(0, 1)$).
- Cuando $n \rightarrow \infty$, la distribución t_n converge a la $N(0, 1)$: para muestras grandes, ambas son prácticamente indistinguibles.

Uso típico

Si $X_1, \dots, X_n$ es una muestra $N(\mu, \sigma^2)$ con σ^2 **desconocida**, se puede probar que

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1},$$

lo que permite hacer inferencia sobre μ sin conocer σ^2 (base de los tests t y los intervalos de

Ejemplo 2

Example

Sean $Z \sim N(0, 1)$ y $U \sim \chi_9^2$ independientes. Se define $T = Z/\sqrt{U/9}$. Indicar la distribución de T , su varianza, y comparar su dispersión con la de Z .

Ejemplo 2

Example

Sean $Z \sim N(0, 1)$ y $U \sim \chi_9^2$ independientes. Se define $T = Z/\sqrt{U/9}$. Indicar la distribución de T , su varianza, y comparar su dispersión con la de Z .

Resolución

Por definición, $T \sim t_9$. Su varianza es

$$\text{Var}(T) = \frac{9}{9-2} = \frac{9}{7} \approx 1.286,$$

mayor que $\text{Var}(Z) = 1$. Esto refleja la incertidumbre adicional que introduce estimar la escala a partir de U (en la práctica, a partir de S^2) en lugar de conocerla exactamente.

Definición

Definition (F de Snedecor)

Si $U \sim \chi_m^2$ y $V \sim \chi_n^2$ son **independientes**, la variable

$$F = \frac{U/m}{V/n}$$

tiene distribución **F de Snedecor con m y n grados de libertad**, denotada $F \sim F_{m,n}$.

Propiedades

- F toma valores positivos; su densidad es asimétrica a derecha.
- Si $F \sim F_{m,n}$, entonces $1/F \sim F_{n,m}$ (se invierten los grados de libertad).
- Relación con t : si $T \sim t_n$, entonces $T^2 \sim F_{1,n}$.

Justificación de $T^2 \sim F_{1,n}$

Demostración.

Si $T = Z/\sqrt{U/n}$ con $Z \sim N(0, 1)$, $U \sim \chi_n^2$ independientes, entonces

$$T^2 = \frac{Z^2}{U/n} = \frac{Z^2/1}{U/n}.$$

Pero $Z^2 \sim \chi_1^2$ (visto al principio de la clase), y Z^2 es independiente de U (pues Z lo es). Por definición de la F de Snedecor con $m = 1$, $n = n$, se concluye $T^2 \sim F_{1,n}$. □

Ejemplo 3

Example

Dos muestras independientes de tamaños $n_1 = 10$ y $n_2 = 15$ provienen de poblaciones normales con igual varianza σ^2 . Sean S_1^2 y S_2^2 las varianzas muestrales respectivas. ¿Qué distribución tiene S_1^2/S_2^2 ?

Ejemplo 3

Example

Dos muestras independientes de tamaños $n_1 = 10$ y $n_2 = 15$ provienen de poblaciones normales con igual varianza σ^2 . Sean S_1^2 y S_2^2 las varianzas muestrales respectivas. ¿Qué distribución tiene S_1^2/S_2^2 ?

Resolución

Sabemos que $\frac{(n_1 - 1)S_1^2}{\sigma^2} \sim \chi_9^2$ y $\frac{(n_2 - 1)S_2^2}{\sigma^2} \sim \chi_{14}^2$, independientes. Entonces

$$F = \frac{\frac{(n_1 - 1)S_1^2}{\sigma^2} / 9}{\frac{(n_2 - 1)S_2^2}{\sigma^2} / 14} = \frac{S_1^2}{S_2^2} \sim F_{9,14}.$$

Este resultado es la base de las pruebas de igualdad de varianzas, y del análisis de varianza (ANOVA).

Distribución multinomial

Definition (Multinomial)

Se repite n veces, de forma independiente, un experimento con k resultados posibles $A_1, \dots, A_k$, con probabilidades $p_1, \dots, p_k$ ($\sum_j p_j = 1$). Sea X_j el número de veces que ocurre A_j . El vector $(X_1, \dots, X_k)$ tiene distribución **multinomial**, con función de probabilidad conjunta

$$P(X_1 = x_1, \dots, X_k = x_k) = \frac{n!}{x_1! x_2! \cdots x_k!} p_1^{x_1} p_2^{x_2} \cdots p_k^{x_k},$$

para $x_1 + \cdots + x_k = n$, $x_j \geq 0$ enteros.

Observación

Es la generalización natural de la binomial ($k = 2$) a más de dos categorías. Cada X_j marginalmente es $\text{Bin}(n, p_j)$.

Ejemplo 4

Example

Una urna contiene bolillas rojas (40 %), verdes (35 %) y azules (25 %). Se extraen 5 bolillas con reposición. ¿Cuál es la probabilidad de obtener exactamente 2 rojas, 2 verdes y 1 azul?

Ejemplo 4

Example

Una urna contiene bolillas rojas (40 %), verdes (35 %) y azules (25 %). Se extraen 5 bolillas con reposición. ¿Cuál es la probabilidad de obtener exactamente 2 rojas, 2 verdes y 1 azul?

Resolución

Con $n = 5$, $p_1 = 0.40$, $p_2 = 0.35$, $p_3 = 0.25$, $x_1 = 2$, $x_2 = 2$, $x_3 = 1$:

$$P(2, 2, 1) = \frac{5!}{2! 2! 1!} (0.40)^2 (0.35)^2 (0.25)^1 = 30 \times 0.16 \times 0.1225 \times 0.25 \approx 0.147.$$

Distribución normal multivariada (multinormal)

Definition (Vector normal multivariado, caso bidimensional)

(X, Y) tiene distribución **normal bivariada** con parámetros $\mu_X, \mu_Y, \sigma_X^2, \sigma_Y^2$ y coeficiente de correlación $\rho \in (-1, 1)$ si su densidad conjunta es

$$f(x, y) = \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_X)^2}{\sigma_X^2} - \frac{2\rho(x-\mu_X)(y-\mu_Y)}{\sigma_X\sigma_Y} + \frac{(y-\mu_Y)^2}{\sigma_Y^2} \right] \right\}$$

Propiedades de la normal bivariada

Propiedades clave

- Las marginales son normales: $X \sim N(\mu_X, \sigma_X^2)$, $Y \sim N(\mu_Y, \sigma_Y^2)$.
- ρ es exactamente el coeficiente de correlación entre X e Y .
- **Caso especial importante:** si $\rho = 0$, la densidad conjunta factoriza como producto de las marginales, por lo que X e Y resultan **independientes**. (En general, no correlación $\neq$ independencia, ¡pero para el caso normal bivariado sí equivalen!)
- Toda combinación lineal $aX + bY$ es normal.
- Las distribuciones condicionales $f_{X|Y}(x | y)$ también son normales.

Generalización a n dimensiones

Vector normal multivariado $N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$

En notación matricial, un vector $\mathbf{X} = (X_1, \dots, X_n)$ tiene distribución normal multivariada con vector de medias $\boldsymbol{\mu}$ y matriz de covarianzas $\boldsymbol{\Sigma}$ (simétrica definida positiva) si su densidad es

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}.$$

Por qué es tan importante

La familia multinormal es central en **Regresión y correlación** y en el **Análisis Multivariado**: aparece al modelar k mediciones correlacionadas (por ejemplo, distintas variables económicas o biométricas) y sustenta buena parte de la inferencia estadística clásica.

Mirando hacia adelante

Estas cuatro familias de distribuciones — χ^2 , t , F y multinomial/multinormal— son la maquinaria detrás de casi todos los métodos que se estudiarán en las unidades de **Estimación** y **Pruebas de Hipótesis**:

- χ^2 : intervalos y pruebas para σ^2 ; pruebas de bondad de ajuste y de independencia (con la multinomial).
- t de Student: intervalos y pruebas para μ con σ^2 desconocida.
- F de Snedecor: comparación de dos varianzas; ANOVA.
- Multinormal: base de la regresión múltiple y de la inferencia con varias variables simultáneas.

Ideas clave de hoy

- χ_n^2 = suma de n cuadrados de $N(0, 1)$ independientes; $E = n$, $\text{Var} = 2n$; propiedad reproductiva.
- $t_n = Z/\sqrt{U/n}$ con $Z \sim N(0, 1)$, $U \sim \chi_n^2$ independientes: colas más pesadas que la normal, converge a $N(0, 1)$ cuando $n \rightarrow \infty$.
- $F_{m,n} = (U/m)/(V/n)$ con $U \sim \chi_m^2$, $V \sim \chi_n^2$ independientes: compara varianzas.
- La **multinomial** generaliza la binomial a k categorías; la **multinormal** generaliza la normal a varias dimensiones correlacionadas.
- Estas distribuciones son la base técnica de la inferencia estadística que se desarrollará en las próximas unidades.