Clase 14: Esperanza matemática y sus propiedades

Unidad 4: Función generadora de momentos

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

1. Motivación
2. Esperanza de una variable aleatoria discreta
3. Esperanza de una variable aleatoria continua
4. Propiedades de la esperanza
5. Esperanza de una función de una variable aleatoria
6. Resumen

¿Por qué resumir una variable aleatoria?

Idea central

Hasta ahora describimos una variable aleatoria mediante su función de probabilidad puntual (caso discreto) o su función de densidad (caso continuo). Estas funciones contienen **toda** la información probabilística, pero muchas veces necesitamos un número que resuma el comportamiento "típico" de la variable.

- ¿Cuál es el valor promedio que esperamos observar a largo plazo?
- ¿Cuánto se dispersan los valores respecto de ese promedio? (lo veremos en la Clase 15)
- Estas preguntas se responden con los llamados **momentos** de la distribución.

En esta clase

Definimos la esperanza matemática (primer momento), estudiamos sus propiedades y aprendemos a calcular la esperanza de funciones de una variable aleatoria.

Definición: caso discreto

Definition (Esperanza matemática – caso discreto)

Sea X una variable aleatoria discreta con rango $R_X = \{x_1, x_2, x_3, \dots\}$ y función de probabilidad puntual $p(x_i) = P(X = x_i)$. La **esperanza matemática** (o valor esperado, o media) de X es

$$E(X) = \sum_{x_i \in R_X} x_i \, p(x_i),$$

siempre que la serie converja **absolutamente**, es decir $\sum_{x_i} |x_i| \, p(x_i) < \infty$.

Notación

También se escribe μ o μ_X para $E(X)$. Si la serie no converge absolutamente, decimos que la esperanza **no existe**.

Interpretación

$E(X)$ es un promedio ponderado de los valores posibles de X, donde cada valor pesa según su probabilidad. Se interpreta como el valor promedio que tomaría X si repitiéramos el

Ejemplo: dado equilibrado

Example

Sea X el resultado de tirar un dado equilibrado. Entonces $R_X = \{1, 2, 3, 4, 5, 6\}$ y $p(x_i) = 1/6$ para cada i.

$$E(X) = \sum_{i=1}^{6} i \cdot \frac{1}{6} = \frac{1}{6}(1 + 2 + 3 + 4 + 5 + 6) = \frac{21}{6} = 3.5$$

Observación importante

$E(X) = 3.5$ **no es** un valor posible de X. La esperanza es un promedio a largo plazo, no un valor que necesariamente pueda observarse en una sola realización.

Ejemplo: variable Bernoulli

Example

Sea $X \sim \text{Bernoulli}(p)$, es decir $P(X = 1) = p$, $P(X = 0) = 1 - p$.

$$E(X) = 0 \cdot (1 - p) + 1 \cdot p = p.$$

Example (Binomial)

Sea $X \sim \text{Bin}(n, p)$. Se puede demostrar (usando la definición y manipulación combinatoria, o más fácilmente como suma de n Bernoulli independientes) que

$$E(X) = np.$$

Example (Poisson)

Sea $X \sim \text{Poisson}(\lambda)$. Entonces

$$E(X) = \sum_{k}^{\infty} k \frac{e^{-\lambda}\lambda^k}{k!} = \lambda e^{-\lambda} \sum_{k}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} e^{\lambda} = \lambda.$$

Definición: caso continuo

Definition (Esperanza matemática – caso continuo)

Sea X una variable aleatoria continua con función de densidad $f(x)$. La esperanza matemática de X es

$$E(X) = \int_{-\infty}^{\infty} x\, f(x)\, dx,$$

siempre que $\displaystyle\int_{-\infty}^{\infty} |x|\, f(x)\, dx < \infty$.

Analogía

La suma del caso discreto se reemplaza por una integral, y la función de probabilidad puntual por la densidad. La interpretación es la misma: un promedio ponderado por la "masa de probabilidad".

Ejemplo: distribución uniforme

Example

Sea $X \sim U(a, b)$, con densidad $f(x) = \dfrac{1}{b-a}$ para $x \in [a, b]$.

$$E(X) = \int_a^b x \cdot \frac{1}{b-a}\, dx = \frac{1}{b-a}\left[\frac{x^2}{2}\right]_a^b = \frac{b^2 - a^2}{2(b-a)} = \frac{a+b}{2}.$$

Es decir, la esperanza es el punto medio del intervalo, como era de esperar por simetría.

Ejemplo: distribución exponencial

Example

Sea $X \sim \text{Exp}(\lambda)$, con densidad $f(x) = \lambda e^{-\lambda x}$ para $x \geq 0$.

$$E(X) = \int_0^\infty x\lambda e^{-\lambda x}\, dx.$$

Integrando por partes con $u = x$, $dv = \lambda e^{-\lambda x} dx$:

$$E(X) = \left[-xe^{-\lambda x}\right]_0^\infty + \int_0^\infty e^{-\lambda x}\, dx = 0 + \left[-\frac{1}{\lambda}e^{-\lambda x}\right]_0^\infty = \frac{1}{\lambda}.$$

Distribución normal

Si $X \sim N(\mu, \sigma^2)$, se puede demostrar (usando simetría de la densidad respecto de μ) que $E(X) = \mu$. El parámetro μ de la normal es, precisamente, su esperanza.

Propiedades básicas

Theorem (Propiedades de la esperanza)

Sean X, Y variables aleatorias con esperanza finita y $a, b \in \mathbb{R}$ constantes. Entonces:

1. ***Esperanza de una constante:*** $E(c) = c$.
2. ***Homogeneidad:*** $E(aX) = a\,E(X)$.
3. ***Linealidad:*** $E(aX + b) = a\,E(X) + b$.
4. ***Aditividad:*** $E(X + Y) = E(X) + E(Y)$ *(vale siempre, incluso si X e Y no son independientes).*
5. *Si $X \geq 0$ (con probabilidad 1), entonces $E(X) \geq 0$.*
6. *Si $X \leq Y$ (con probabilidad 1), entonces $E(X) \leq E(Y)$ (monotonía).*

Demostración de la linealidad (caso discreto)

Proof.

Sea X discreta con función de probabilidad puntual $p(x_i)$. Por definición,

$$E(aX+b) = \sum_i (ax_i + b)\, p(x_i) = a \sum_i x_i\, p(x_i) + b \sum_i p(x_i).$$

Como $\sum_i x_i p(x_i) = E(X)$ y $\sum_i p(x_i) = 1$, se obtiene

$$E(aX+b) = a\,E(X) + b.$$

□

Caso continuo

La demostración es análoga, reemplazando la suma por una integral y usando la linealidad de la integral: $\int (ax+b) f(x)\,dx = a \int x f(x)\,dx + b \int f(x)\,dx$.

Aditividad: $E(X+Y) = E(X) + E(Y)$

Comentario importante

Esta propiedad es notable porque **no requiere independencia** entre X e Y. Se demuestra usando la densidad (o función de probabilidad) conjunta:

$$E(X+Y) = \iint (x+y) f_{X,Y}(x,y)\, dx\, dy = \iint x f_{X,Y}\, dx\, dy + \iint y f_{X,Y}\, dx\, dy = E(X) + E(Y).$$

Generalización

Por inducción, para cualquier combinación lineal de variables aleatorias $X_1, \ldots, X_n$ y constantes $a_1, \ldots, a_n$:

$$E\left(\sum_{i=1}^{n} a_i X_i\right) = \sum_{i=1}^{n} a_i\, E(X_i).$$

Esta propiedad será clave en la Clase 17 para demostrar la ley de los grandes números.

El "teorema del estadístico inconsciente"

Motivación

Si X es una variable aleatoria y g una función, entonces $Y = g(X)$ también es una variable aleatoria. ¿Cómo calculamos $E(Y)$?

Una forma sería hallar primero la distribución de Y y luego aplicar la definición de esperanza a Y. Pero existe un atajo muy útil:

Theorem (Ley del estadístico inconsciente)

Sea X una variable aleatoria y $g : \mathbb{R} \to \mathbb{R}$ una función. Entonces:

- *Caso discreto:* $E(g(X)) = \sum_{x_i \in R_X} g(x_i)\, p(x_i)$.
- *Caso continuo:* $E(g(X)) = \int_{-\infty}^{\infty} g(x)\, f(x)\, dx$.

Utilidad

Permite calcular $E(g(X))$ **sin** necesidad de hallar la distribución de $Y = g(X)$: basta usar la

Ejemplo: esperanza de X^2

Example

Sea X discreta con $P(X=-1)=0.3$, $P(X=0)=0.4$, $P(X=1)=0.3$. Calculemos $E(X^2)$.

Aplicando la ley del estadístico inconsciente con $g(x)=x^2$:

$$E(X^2)=(-1)^2(0.3)+0^2(0.4)+1^2(0.3)=0.3+0+0.3=0.6.$$

Nota

Observar que $E(X)=-1(0.3)+0(0.4)+1(0.3)=0$, pero $E(X^2)=0.6\neq[E(X)]^2=0$. En general $E(g(X))\neq g(E(X))$: la esperanza no "conmuta" con funciones no lineales.

Ejemplo: caso continuo

Example

Sea $X \sim U(0,1)$ y $Y = e^X$. Calculemos $E(Y)$ sin hallar la densidad de Y.

$$E(Y) = E(e^X) = \int_0^1 e^x \cdot 1 \, dx = [e^x]_0^1 = e - 1 \approx 1.718.$$

Example (Momentos de orden k)

En general, definimos el **momento de orden** k de X como $E(X^k)$, tomando $g(x) = x^k$. Por ejemplo, para $X \sim \text{Exp}(\lambda)$:

$$E(X^2) = \int_0^\infty x^2 \lambda e^{-\lambda x} \, dx = \frac{2}{\lambda^2}$$

(usando integración por partes dos veces, o la función Gamma). Este momento será fundamental para calcular la varianza en la próxima clase.

Caso especial: función de dos variables

Extensión a $g(X, Y)$

Si X, Y tienen densidad (o función de probabilidad) conjunta $f_{X,Y}(x, y)$, entonces

$$E(g(X, Y)) = \iint_{\mathbb{R}^2} g(x, y)\, f_{X,Y}(x, y)\, dx\, dy$$

(análogamente en el caso discreto, con doble suma). Esta versión se usará en la Clase 16 para definir la covarianza $\mathrm{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$.

Example

Si X, Y son independientes, se puede demostrar que $E(XY) = E(X)\, E(Y)$. En general, **sin** independencia, esta igualdad puede fallar.

Ejemplo integrador

Example

Un juego consiste en tirar dos dados equilibrados independientes X_1, X_2 y pagar (o cobrar) $G = 2(X_1 + X_2) - 15$ pesos, donde valores positivos de G son ganancia del jugador. Calculemos $E(G)$.

Por linealidad de la esperanza y aditividad:

$$E(G) = E(2(X_1 + X_2) - 15) = 2\,E(X_1 + X_2) - 15 = 2\big(E(X_1) + E(X_2)\big) - 15.$$

Como $E(X_1) = E(X_2) = 3.5$ (dado equilibrado, visto antes):

$$E(G) = 2(3.5 + 3.5) - 15 = 2(7) - 15 = 14 - 15 = -1.$$

En promedio, el jugador pierde \$1 por partida: el juego no es favorable para el jugador. Observar que no hizo falta calcular la distribución de $X_1 + X_2$, solo usar linealidad y aditividad de la esperanza.

Resumen

Conceptos clave

- La **esperanza matemática** $E(X)$ resume el valor "central" o promedio a largo plazo de una variable aleatoria.
- Caso discreto: $E(X) = \sum x_i p(x_i)$. Caso continuo: $E(X) = \int x f(x)\, dx$.
- Propiedades: $E(c) = c$; $E(aX + b) = aE(X) + b$; $E(X + Y) = E(X) + E(Y)$ (sin necesidad de independencia).
- **Ley del estadístico inconsciente:** $E(g(X)) = \sum g(x_i)p(x_i)$ o $\int g(x)f(x)\, dx$, según el caso.
- En general $E(g(X)) \neq g(E(X))$.

Próxima clase

Usaremos $E(X)$ y $E(X^2)$ para definir la **varianza**, estudiar la desigualdad de Chebyshev y la esperanza condicional.