

Clase 14: Esperanza matemática y sus propiedades

Unidad 4: Función generadora de momentos

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

- 1 Motivación
- 2 Esperanza de una variable aleatoria discreta
- 3 Esperanza de una variable aleatoria continua
- 4 Propiedades de la esperanza
- 5 Esperanza de una función de una variable aleatoria
- 6 Resumen

¿Por qué resumir una variable aleatoria?

Idea central

Hasta ahora describimos una variable aleatoria mediante su función de probabilidad puntual (caso discreto) o su función de densidad (caso continuo). Estas funciones contienen **toda** la información probabilística, pero muchas veces necesitamos un número que resuma el comportamiento “típico” de la variable.

- ¿Cuál es el valor promedio que esperamos observar a largo plazo?
- ¿Cuánto se dispersan los valores respecto de ese promedio? (lo veremos en la Clase 15)
- Estas preguntas se responden con los llamados **momentos** de la distribución.

En esta clase

Definimos la esperanza matemática (primer momento), estudiamos sus propiedades y aprendemos a calcular la esperanza de funciones de una variable aleatoria.

Definición: caso discreto

Definition (Esperanza matemática – caso discreto)

Sea X una variable aleatoria discreta con rango $R_X = \{x_1, x_2, x_3, \dots\}$ y función de probabilidad puntual $p(x_i) = P(X = x_i)$. La **esperanza matemática** (o valor esperado, o media) de X es

$$E(X) = \sum_{x_i \in R_X} x_i p(x_i),$$

siempre que la serie converja **absolutamente**, es decir $\sum_{x_i} |x_i| p(x_i) < \infty$.

Notación

También se escribe μ o μ_X para $E(X)$. Si la serie no converge absolutamente, decimos que la esperanza **no existe**.

Interpretación

$E(X)$ es un promedio ponderado de los valores posibles de X , donde cada valor pesa según su probabilidad. Se interpreta como el valor promedio que tomaría X si repitiéramos el

Ejemplo: dado equilibrado

Example

Sea X el resultado de tirar un dado equilibrado. Entonces $R_X = \{1, 2, 3, 4, 5, 6\}$ y $p(x_i) = 1/6$ para cada i .

$$E(X) = \sum_{i=1}^6 i \cdot \frac{1}{6} = \frac{1}{6}(1 + 2 + 3 + 4 + 5 + 6) = \frac{21}{6} = 3.5$$

Observación importante

$E(X) = 3.5$ **no es** un valor posible de X . La esperanza es un promedio a largo plazo, no un valor que necesariamente pueda observarse en una sola realización.

Ejemplo: variable Bernoulli

Example

Sea $X \sim \text{Bernoulli}(p)$, es decir $P(X = 1) = p$, $P(X = 0) = 1 - p$.

$$E(X) = 0 \cdot (1 - p) + 1 \cdot p = p.$$

Example (Binomial)

Sea $X \sim \text{Bin}(n, p)$. Se puede demostrar (usando la definición y manipulación combinatoria, o más fácilmente como suma de n Bernoulli independientes) que

$$E(X) = np.$$

Example (Poisson)

Sea $X \sim \text{Poisson}(\lambda)$. Entonces

$$E(X) = \sum_{k=0}^{\infty} k \frac{e^{-\lambda} \lambda^k}{k!} = \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} e^{\lambda} = \lambda.$$

Definición: caso continuo

Definition (Esperanza matemática – caso continuo)

Sea X una variable aleatoria continua con función de densidad $f(x)$. La esperanza matemática de X es

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx,$$

siempre que $\int_{-\infty}^{\infty} |x| f(x) dx < \infty$.

Analogía

La suma del caso discreto se reemplaza por una integral, y la función de probabilidad puntual por la densidad. La interpretación es la misma: un promedio ponderado por la “masa de probabilidad”.

Ejemplo: distribución uniforme

Example

Sea $X \sim U(a, b)$, con densidad $f(x) = \frac{1}{b-a}$ para $x \in [a, b]$.

$$E(X) = \int_a^b x \cdot \frac{1}{b-a} dx = \frac{1}{b-a} \left[\frac{x^2}{2} \right]_a^b = \frac{b^2 - a^2}{2(b-a)} = \frac{a+b}{2}.$$

Es decir, la esperanza es el punto medio del intervalo, como era de esperar por simetría.

Ejemplo: distribución exponencial

Example

Sea $X \sim \text{Exp}(\lambda)$, con densidad $f(x) = \lambda e^{-\lambda x}$ para $x \geq 0$.

$$E(X) = \int_0^{\infty} x \lambda e^{-\lambda x} dx.$$

Integrando por partes con $u = x$, $dv = \lambda e^{-\lambda x} dx$:

$$E(X) = \left[-x e^{-\lambda x} \right]_0^{\infty} + \int_0^{\infty} e^{-\lambda x} dx = 0 + \left[-\frac{1}{\lambda} e^{-\lambda x} \right]_0^{\infty} = \frac{1}{\lambda}.$$

Distribución normal

Si $X \sim N(\mu, \sigma^2)$, se puede demostrar (usando simetría de la densidad respecto de μ) que $E(X) = \mu$. El parámetro μ de la normal es, precisamente, su esperanza.

Theorem (Propiedades de la esperanza)

Sean X, Y variables aleatorias con esperanza finita y $a, b \in \mathbb{R}$ constantes. Entonces:

- 1 **Esperanza de una constante:** $E(c) = c$.
- 2 **Homogeneidad:** $E(aX) = a E(X)$.
- 3 **Linealidad:** $E(aX + b) = a E(X) + b$.
- 4 **Aditividad:** $E(X + Y) = E(X) + E(Y)$ (vale siempre, incluso si X e Y no son independientes).
- 5 Si $X \geq 0$ (con probabilidad 1), entonces $E(X) \geq 0$.
- 6 Si $X \leq Y$ (con probabilidad 1), entonces $E(X) \leq E(Y)$ (monotonía).

Demostración de la linealidad (caso discreto)

Demostración.

Sea X discreta con función de probabilidad puntual $p(x_i)$. Por definición,

$$E(aX + b) = \sum_i (ax_i + b) p(x_i) = a \sum_i x_i p(x_i) + b \sum_i p(x_i).$$

Como $\sum_i x_i p(x_i) = E(X)$ y $\sum_i p(x_i) = 1$, se obtiene

$$E(aX + b) = a E(X) + b.$$



Caso continuo

La demostración es análoga, reemplazando la suma por una integral y usando la linealidad de la integral: $\int (ax + b)f(x) dx = a \int xf(x) dx + b \int f(x) dx$.

Aditividad: $E(X + Y) = E(X) + E(Y)$

Comentario importante

Esta propiedad es notable porque **no requiere independencia** entre X e Y . Se demuestra usando la densidad (o función de probabilidad) conjunta:

$$E(X + Y) = \iint (x + y) f_{X,Y}(x, y) dx dy = \iint x f_{X,Y} dx dy + \iint y f_{X,Y} dx dy = E(X) + E(Y).$$

Generalización

Por inducción, para cualquier combinación lineal de variables aleatorias $X_1, \dots, X_n$ y constantes $a_1, \dots, a_n$:

$$E \left(\sum_{i=1}^n a_i X_i \right) = \sum_{i=1}^n a_i E(X_i).$$

Esta propiedad será clave en la Clase 17 para demostrar la ley de los grandes números.

El “teorema del estadístico inconsciente”

Motivación

Si X es una variable aleatoria y g una función, entonces $Y = g(X)$ también es una variable aleatoria. ¿Cómo calculamos $E(Y)$?

Una forma sería hallar primero la distribución de Y y luego aplicar la definición de esperanza a Y . Pero existe un atajo muy útil:

Theorem (Ley del estadístico inconsciente)

Sea X una variable aleatoria y $g : \mathbb{R} \rightarrow \mathbb{R}$ una función. Entonces:

- Caso discreto: $E(g(X)) = \sum_{x_i \in R_X} g(x_i) p(x_i).$
- Caso continuo: $E(g(X)) = \int_{-\infty}^{\infty} g(x) f(x) dx.$

Utilidad

Permite calcular $E(g(X))$ sin necesidad de hallar la distribución de $Y = g(X)$: basta usar la

Ejemplo: esperanza de X^2

Example

Sea X discreta con $P(X = -1) = 0.3$, $P(X = 0) = 0.4$, $P(X = 1) = 0.3$. Calculemos $E(X^2)$.

Aplicando la ley del estadístico inconsciente con $g(x) = x^2$:

$$E(X^2) = (-1)^2(0.3) + 0^2(0.4) + 1^2(0.3) = 0.3 + 0 + 0.3 = 0.6.$$

Nota

Observar que $E(X) = -1(0.3) + 0(0.4) + 1(0.3) = 0$, pero $E(X^2) = 0.6 \neq [E(X)]^2 = 0$. En general $E(g(X)) \neq g(E(X))$: la esperanza no “conmuta” con funciones no lineales.

Ejemplo: caso continuo

Example

Sea $X \sim U(0, 1)$ y $Y = e^X$. Calculemos $E(Y)$ sin hallar la densidad de Y .

$$E(Y) = E(e^X) = \int_0^1 e^x \cdot 1 \, dx = [e^x]_0^1 = e - 1 \approx 1.718.$$

Example (Momentos de orden k)

En general, definimos el **momento de orden** k de X como $E(X^k)$, tomando $g(x) = x^k$. Por ejemplo, para $X \sim \text{Exp}(\lambda)$:

$$E(X^2) = \int_0^\infty x^2 \lambda e^{-\lambda x} \, dx = \frac{2}{\lambda^2}$$

(usando integración por partes dos veces, o la función Gamma). Este momento será fundamental para calcular la varianza en la próxima clase.

Caso especial: función de dos variables

Extensión a $g(X, Y)$

Si X, Y tienen densidad (o función de probabilidad) conjunta $f_{X,Y}(x, y)$, entonces

$$E(g(X, Y)) = \iint_{\mathbb{R}^2} g(x, y) f_{X,Y}(x, y) dx dy$$

(análogamente en el caso discreto, con doble suma). Esta versión se usará en la Clase 16 para definir la covarianza $\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$.

Example

Si X, Y son independientes, se puede demostrar que $E(XY) = E(X)E(Y)$. En general, sin independencia, esta igualdad puede fallar.

Ejemplo integrador

Example

Un juego consiste en tirar dos dados equilibrados independientes X_1, X_2 y pagar (o cobrar) $G = 2(X_1 + X_2) - 15$ pesos, donde valores positivos de G son ganancia del jugador. Calculemos $E(G)$.

Por linealidad de la esperanza y aditividad:

$$E(G) = E(2(X_1 + X_2) - 15) = 2 E(X_1 + X_2) - 15 = 2(E(X_1) + E(X_2)) - 15.$$

Como $E(X_1) = E(X_2) = 3.5$ (dado equilibrado, visto antes):

$$E(G) = 2(3.5 + 3.5) - 15 = 2(7) - 15 = 14 - 15 = -1.$$

En promedio, el jugador pierde \$1 por partida: el juego no es favorable para el jugador. Observar que no hizo falta calcular la distribución de $X_1 + X_2$, solo usar linealidad y aditividad de la esperanza.

Conceptos clave

- La **esperanza matemática** $E(X)$ resume el valor “central” o promedio a largo plazo de una variable aleatoria.
- Caso discreto: $E(X) = \sum x_i p(x_i)$. Caso continuo: $E(X) = \int x f(x) dx$.
- Propiedades: $E(c) = c$; $E(aX + b) = aE(X) + b$; $E(X + Y) = E(X) + E(Y)$ (sin necesidad de independencia).
- **Ley del estadístico inconsciente:** $E(g(X)) = \sum g(x_i) p(x_i)$ o $\int g(x) f(x) dx$, según el caso.
- En general $E(g(X)) \neq g(E(X))$.

Próxima clase

Usaremos $E(X)$ y $E(X^2)$ para definir la **varianza**, estudiar la desigualdad de Chebyshev y la esperanza condicional.