Clase 16: Covarianza, correlación y función generatriz de momentos

Unidad 4: Función generadora de momentos

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

1. Covarianza
2. Coeficiente de correlación
3. Función generatriz de momentos
4. Cálculo de FGM de distribuciones conocidas

Motivación

Pregunta

Cuando tenemos dos variables aleatorias X, Y definidas en el mismo espacio muestral, ¿cómo medimos si tienden a moverse juntas (cuando una es grande, la otra también) o en sentido opuesto?

Ya vimos en la Clase 15 que, en general,

$$\mathrm{Var}(X+Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) + 2\,\mathrm{Cov}(X,Y),$$

lo que motiva definir formalmente la covarianza.

Definición

Definition (Covarianza)

Sean X, Y variables aleatorias con $E(X) = \mu_X$, $E(Y) = \mu_Y$ finitas. La **covarianza** entre X e Y es

$$\mathrm{Cov}(X, Y) = E\big[(X - \mu_X)(Y - \mu_Y)\big].$$

Theorem (Fórmula de cálculo)

$$Cov(X, Y) = E(XY) - E(X)\,E(Y).$$

Proof.

Desarrollando el producto y usando linealidad de la esperanza:

$$\begin{aligned}\mathrm{Cov}(X, Y) &= E[XY - \mu_X Y - \mu_Y X + \mu_X \mu_Y] \\ &= E(XY) - \mu_X E(Y) - \mu_Y E(X) + \mu_X \mu_Y \\ &= E(XY) - \mu_X \mu_Y - \mu_Y \mu_X + \mu_X \mu_Y = E(XY) - \mu_X \mu_Y.\end{aligned}$$

□

Propiedades de la covarianza

Theorem (Propiedades)

Sean X, Y, Z variables aleatorias y $a, b, c, d \in \mathbb{R}$:

1. $Cov(X, X) = Var(X)$.
2. $Cov(X, Y) = Cov(Y, X)$ *(simetría).*
3. $Cov(aX + b, cY + d) = ac\ Cov(X, Y)$.
4. $Cov(X + Z, Y) = Cov(X, Y) + Cov(Z, Y)$ *(bilinealidad).*
5. *Si X, Y son independientes,* $Cov(X, Y) = 0$ *(la recíproca* ***no*** *vale en general).*
6. $Var(X + Y) = Var(X) + Var(Y) + 2\ Cov(X, Y)$.
7. *Más generalmente:* $Var\left(\sum_i a_i X_i\right) = \sum_i a_i^2\, Var(X_i) + 2 \sum_{i<j} a_i a_j\, Cov(X_i, X_j)$.

Independencia no implica covarianza cero... ¡al revés!

Cuidado con la recíproca

Independencia $\Rightarrow \text{Cov}(X, Y) = 0$, pero $\text{Cov}(X, Y) = 0$ **no implica** independencia.

Example

Sea $X \sim U(-1, 1)$ y $Y = X^2$. Claramente Y depende *fuertemente* de X (no son independientes). Sin embargo:

$$E(XY) = E(X^3) = \int_{-1}^{1} x^3 \cdot \frac{1}{2}\, dx = 0 \quad \text{(integrando impar en intervalo simétrico)},$$

y $E(X) = 0$, por lo tanto $\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 0 - 0 = 0$. La covarianza mide solo dependencia **lineal**, no dependencia en general.

Definición

Problema de la covarianza

$\mathrm{Cov}(X, Y)$ depende de las unidades de X e Y (si medimos X en metros o en centímetros, la covarianza cambia). Necesitamos una versión "adimensional".

Definition (Coeficiente de correlación de Pearson)

Sean X, Y con $\sigma_X, \sigma_Y > 0$ finitas. El coeficiente de correlación es

$$\rho_{X,Y} = \frac{\mathrm{Cov}(X, Y)}{\sigma_X \, \sigma_Y}.$$

Theorem (Rango)

$-1 \leq \rho_{X,Y} \leq 1$.

Demostración del rango de ρ

Proof.

Se usa la desigualdad de Cauchy–Schwarz para esperanzas: $[E(UV)]^2 \leq E(U^2)\,E(V^2)$, aplicada a $U = X - \mu_X$, $V = Y - \mu_Y$:

$$\big[\mathrm{Cov}(X,Y)\big]^2 = \big[E(UV)\big]^2 \leq E(U^2)\,E(V^2) = \mathrm{Var}(X)\,\mathrm{Var}(Y) = \sigma_X^2\sigma_Y^2.$$

Por lo tanto $\mathrm{Cov}(X,Y)^2 \leq \sigma_X^2\sigma_Y^2$, y dividiendo,

$$\rho_{X,Y}^2 = \frac{\mathrm{Cov}(X,Y)^2}{\sigma_X^2\sigma_Y^2} \leq 1 \quad \Longrightarrow \quad -1 \leq \rho_{X,Y} \leq 1.$$

□

Interpretación de ρ

Casos extremos

- $\rho_{X,Y} = 1$: X e Y están relacionadas **linealmente en forma creciente** de manera exacta: $Y = aX + b$ con $a > 0$ (con probabilidad 1).
- $\rho_{X,Y} = -1$: relación lineal exacta decreciente, $Y = aX + b$ con $a < 0$.
- $\rho_{X,Y} = 0$: no hay relación lineal (variables "incorreladas"); puede haber relación no lineal, como vimos en el ejemplo anterior.
- Valores intermedios: cuanto más cerca de ± 1, más fuerte la asociación lineal; cuanto más cerca de 0, más débil.

Example

Si $Y = 3X - 5$ (relación lineal exacta), entonces $\mathrm{Cov}(X, Y) = \mathrm{Cov}(X, 3X - 5) = 3\,\mathrm{Var}(X)$, y $\sigma_Y = |3|\sigma_X = 3\sigma_X$. Luego $\rho_{X,Y} = \dfrac{3\sigma_X^2}{\sigma_X \cdot 3\sigma_X} = 1$.

Ejemplo numérico

Example

Sean X, Y con función de probabilidad conjunta dada por la tabla:

	$Y=0$	$Y=1$	$Y=2$
$X=0$	0.2	0.1	0.0
$X=1$	0.1	0.3	0.3

Marginales: $P(X=0)=0.3$, $P(X=1)=0.7$; $P(Y=0)=0.3$, $P(Y=1)=0.4$, $P(Y=2)=0.3$.

$$E(X)=0.7, \quad E(Y)=0(0.3)+1(0.4)+2(0.3)=1.0$$

$$E(XY)=\sum xy\, p(x,y)=0+0+0+0+1(0.3)+2(0.3)=0.9$$

$$\mathrm{Cov}(X,Y)=0.9-(0.7)(1.0)=0.2.$$

Con más cálculo se obtienen σ_X, σ_Y y de ahí $\rho_{X,Y}$ (ejercicio resuelto completo en la Práctica 2)

Motivación

Idea

Vimos que calcular $E(X), E(X^2), E(X^3), \ldots$ (los **momentos** de X) requiere resolver una suma o integral distinta para cada orden. La **función generatriz de momentos** (FGM) es una función que "codifica" todos los momentos de una vez, y además caracteriza unívocamente la distribución.

Definición

Definition (Función generatriz de momentos)

Sea X una variable aleatoria. La función generatriz de momentos de X es

$$M_X(t) = E\left(e^{tX}\right),$$

definida para todo t en un entorno de 0 tal que la esperanza sea finita (si no existe tal entorno, se dice que la FGM no existe).

Caso discreto: $M_X(t) = \sum_i e^{tx_i}\, p(x_i)$. Caso continuo: $M_X(t) = \int_{-\infty}^{\infty} e^{tx} f(x)\, dx$.

¿Por qué "generatriz de momentos"?

Como veremos, derivando $M_X(t)$ respecto de t y evaluando en $t = 0$ se obtienen los momentos $E(X^k)$.

Propiedad 1: generación de momentos

Theorem

Si $M_X(t)$ existe en un entorno de 0, entonces es infinitamente derivable allí y

$$M_X^{(k)}(0) = E(X^k), \qquad k = 1, 2, 3, \ldots$$

Idea de la demostración.

Suponiendo que se puede derivar bajo el signo de esperanza (integral o suma),

$$M_X'(t) = \frac{d}{dt} E(e^{tX}) = E\left(\frac{d}{dt} e^{tX}\right) = E(Xe^{tX}).$$

Evaluando en $t = 0$: $M_X'(0) = E(Xe^0) = E(X)$. Derivando nuevamente,

$$M_X''(t) = E(X^2 e^{tX}) \quad \Rightarrow \quad M_X''(0) = E(X^2),$$

y en general $M_X^{(k)}(t) = E(X^k e^{tX})$, de donde $M_X^{(k)}(0) = E(X^k)$. ■ □

Propiedad 2: unicidad

Theorem (Unicidad)

Si $M_X(t)$ y $M_Y(t)$ existen y coinciden en un entorno de 0, entonces X e Y tienen la ***misma*** *distribución.*

Utilidad práctica

Esta propiedad es muy poderosa: para identificar la distribución de una variable aleatoria (por ejemplo, una suma de variables), basta calcular su FGM y reconocerla como la de una distribución conocida. No hace falta calcular la densidad o función de probabilidad puntual directamente.

Propiedad 3: FGM de una suma de independientes

Theorem

Si X e Y son independientes, entonces

$$M_{X+Y}(t) = M_X(t) \cdot M_Y(t).$$

Proof.

$$M_{X+Y}(t) = E\left(e^{t(X+Y)}\right) = E\left(e^{tX}e^{tY}\right) = E(e^{tX})\,E(e^{tY}) = M_X(t)\,M_Y(t),$$

donde el penúltimo paso usa que X e Y independientes implica que e^{tX} y e^{tY} también lo son, y por lo tanto $E(e^{tX}e^{tY}) = E(e^{tX})E(e^{tY})$. ■ □

Otras propiedades útiles

- $M_{aX+b}(t) = e^{bt}\,M_X(at)$.
- $M_X(0) = 1$ siempre (pues $e^0 = 1$).

FGM de la distribución binomial

Example

Sea $X \sim \text{Bin}(n, p)$.

$$M_X(t) = \sum_{k=0}^{n} e^{tk} \binom{n}{k} p^k (1-p)^{n-k} = \sum_{k=0}^{n} \binom{n}{k} (pe^t)^k (1-p)^{n-k} = (1 - p + pe^t)^n,$$

usando el teorema del binomio de Newton. Se puede verificar: $M'_X(t) = n(1 - p + pe^t)^{n-1} pe^t$, y $M'_X(0) = n(1)^{n-1} p = np = E(X)$. Consistente con lo visto en la Clase 14.

FGM de Poisson y exponencial

Example (Poisson)

Sea $X \sim \text{Poisson}(\lambda)$.

$$M_X(t) = \sum_{k=0}^{\infty} e^{tk} \frac{e^{-\lambda}\lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(\lambda e^t)^k}{k!} = e^{-\lambda}\, e^{\lambda e^t} = e^{\lambda(e^t-1)}.$$

Example (Exponencial)

Sea $X \sim \text{Exp}(\lambda)$, para $t < \lambda$:

$$M_X(t) = \int_0^{\infty} e^{tx} \lambda e^{-\lambda x}\, dx = \lambda \int_0^{\infty} e^{-(\lambda - t)x}\, dx = \frac{\lambda}{\lambda - t}.$$

(La integral converge solo si $t < \lambda$; para $t \geq \lambda$, la FGM no existe.)

FGM de la distribución normal

Example (Normal estándar y general)

Sea $Z \sim N(0,1)$. Completando cuadrados en el exponente:

$$M_Z(t) = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2}\, dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2}\, dz = e^{t^2/2},$$

pues la última integral es el área total bajo una densidad $N(t,1)$, que vale 1.

Si $X = \mu + \sigma Z \sim N(\mu, \sigma^2)$, usando $M_{aX+b}(t) = e^{bt} M_X(at)$:

$$M_X(t) = e^{\mu t}\, M_Z(\sigma t) = e^{\mu t}\, e^{\sigma^2 t^2/2} = e^{\mu t + \sigma^2 t^2/2}.$$

Aplicación clave (Unidad futura y Clase 18)

Como consecuencia de la Propiedad 3, si $X_1 \sim N(\mu_1, \sigma_1^2)$ y $X_2 \sim N(\mu_2, \sigma_2^2)$ son independientes, $M_{X_1+X_2}(t) = e^{(\mu_1+\mu_2)t + (\sigma_1^2+\sigma_2^2)t^2/2}$, que es la FGM de una $N(\mu_1+\mu_2, \sigma_1^2+\sigma_2^2)$. Por unicidad, ¡la suma de normales independientes es normal!

Resumen

Conceptos clave

- $\mathrm{Cov}(X, Y) = E(XY) - E(X)E(Y)$; mide asociación *lineal*. Independencia $\Rightarrow$ covarianza cero (no vale la recíproca).
- $\rho_{X,Y} = \mathrm{Cov}(X, Y)/(\sigma_X \sigma_Y) \in [-1, 1]$: versión adimensional de la covarianza.
- $\mathrm{Var}(X + Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) + 2\mathrm{Cov}(X, Y)$.
- FGM: $M_X(t) = E(e^{tX})$. Genera momentos ($M_X^{(k)}(0) = E(X^k)$), caracteriza la distribución (unicidad), y $M_{X+Y}(t) = M_X(t)M_Y(t)$ si $X \perp Y$.
- FGM conocidas: Binomial $(1 - p + pe^t)^n$; Poisson $e^{\lambda(e^t-1)}$; Exponencial $\lambda/(\lambda - t)$; Normal $e^{\mu t+\sigma^2 t^2/2}$.

Próximas clases

Usaremos estas herramientas para demostrar la ley de los grandes números (Clase 17) y el teorema central del límite (Clase 18).