

Clase 16: Covarianza, correlación y función generatriz de momentos

Unidad 4: Función generadora de momentos

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

- 1 Covarianza
- 2 Coeficiente de correlación
- 3 Función generatriz de momentos
- 4 Cálculo de FGM de distribuciones conocidas

Pregunta

Cuando tenemos dos variables aleatorias X, Y definidas en el mismo espacio muestral, ¿cómo medimos si tienden a moverse juntas (cuando una es grande, la otra también) o en sentido opuesto?

Ya vimos en la Clase 15 que, en general,

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y),$$

lo que motiva definir formalmente la covarianza.

Definición

Definition (Covarianza)

Sean X, Y variables aleatorias con $E(X) = \mu_X$, $E(Y) = \mu_Y$ finitas. La **covarianza** entre X e Y es

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)].$$

Theorem (Fórmula de cálculo)

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y).$$

Demostración.

Desarrollando el producto y usando linealidad de la esperanza:

$$\begin{aligned}\text{Cov}(X, Y) &= E[XY - \mu_X Y - \mu_Y X + \mu_X \mu_Y] \\ &= E(XY) - \mu_X E(Y) - \mu_Y E(X) + \mu_X \mu_Y \\ &= E(XY) - \mu_X \mu_Y - \mu_Y \mu_X + \mu_X \mu_Y = E(XY) - \mu_X \mu_Y.\end{aligned}$$



Propiedades de la covarianza

Theorem (Propiedades)

Sean X, Y, Z variables aleatorias y $a, b, c, d \in \mathbb{R}$:

- 1 $\text{Cov}(X, X) = \text{Var}(X)$.
- 2 $\text{Cov}(X, Y) = \text{Cov}(Y, X)$ (simetría).
- 3 $\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y)$.
- 4 $\text{Cov}(X + Z, Y) = \text{Cov}(X, Y) + \text{Cov}(Z, Y)$ (bilinealidad).
- 5 Si X, Y son independientes, $\text{Cov}(X, Y) = 0$ (la recíproca **no** vale en general).
- 6 $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y)$.
- 7 Más generalmente: $\text{Var}(\sum_i a_i X_i) = \sum_i a_i^2 \text{Var}(X_i) + 2 \sum_{i < j} a_i a_j \text{Cov}(X_i, X_j)$.

Independencia no implica covarianza cero... ¡al revés!

Cuidado con la recíproca

Independencia $\Rightarrow \text{Cov}(X, Y) = 0$, pero $\text{Cov}(X, Y) = 0$ **no implica** independencia.

Example

Sea $X \sim U(-1, 1)$ y $Y = X^2$. Claramente Y depende *fuertemente* de X (no son independientes). Sin embargo:

$$E(XY) = E(X^3) = \int_{-1}^1 x^3 \cdot \frac{1}{2} dx = 0 \quad (\text{integrando impar en intervalo simétrico}),$$

y $E(X) = 0$, por lo tanto $\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = 0 - 0 = 0$. La covarianza mide solo dependencia **lineal**, no dependencia en general.

Definición

Problema de la covarianza

$\text{Cov}(X, Y)$ depende de las unidades de X e Y (si medimos X en metros o en centímetros, la covarianza cambia). Necesitamos una versión “adimensional”.

Definition (Coeficiente de correlación de Pearson)

Sean X, Y con $\sigma_X, \sigma_Y > 0$ finitas. El coeficiente de correlación es

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$

Theorem (Rango)

$$-1 \leq \rho_{X,Y} \leq 1.$$

Demostración del rango de ρ

Demostración.

Se usa la desigualdad de Cauchy–Schwarz para esperanzas: $[E(UV)]^2 \leq E(U^2) E(V^2)$, aplicada a $U = X - \mu_X$, $V = Y - \mu_Y$:

$$[\text{Cov}(X, Y)]^2 = [E(UV)]^2 \leq E(U^2) E(V^2) = \text{Var}(X) \text{Var}(Y) = \sigma_X^2 \sigma_Y^2.$$

Por lo tanto $\text{Cov}(X, Y)^2 \leq \sigma_X^2 \sigma_Y^2$, y dividiendo,

$$\rho_{X,Y}^2 = \frac{\text{Cov}(X, Y)^2}{\sigma_X^2 \sigma_Y^2} \leq 1 \quad \Rightarrow \quad -1 \leq \rho_{X,Y} \leq 1.$$



Interpretación de ρ

Casos extremos

- $\rho_{X,Y} = 1$: X e Y están relacionadas **linealmente en forma creciente** de manera exacta: $Y = aX + b$ con $a > 0$ (con probabilidad 1).
- $\rho_{X,Y} = -1$: relación lineal exacta decreciente, $Y = aX + b$ con $a < 0$.
- $\rho_{X,Y} = 0$: no hay relación lineal (variables “incorreladas”); puede haber relación no lineal, como vimos en el ejemplo anterior.
- Valores intermedios: cuanto más cerca de ± 1 , más fuerte la asociación lineal; cuanto más cerca de 0, más débil.

Example

Si $Y = 3X - 5$ (relación lineal exacta), entonces $\text{Cov}(X, Y) = \text{Cov}(X, 3X - 5) = 3 \text{Var}(X)$, y $\sigma_Y = |3|\sigma_X = 3\sigma_X$. Luego $\rho_{X,Y} = \frac{3\sigma_X^2}{\sigma_X \cdot 3\sigma_X} = 1$.

Ejemplo numérico

Example

Sean X, Y con función de probabilidad conjunta dada por la tabla:

	$Y = 0$	$Y = 1$	$Y = 2$
$X = 0$	0.2	0.1	0.0
$X = 1$	0.1	0.3	0.3

Marginales: $P(X = 0) = 0.3$, $P(X = 1) = 0.7$; $P(Y = 0) = 0.3$, $P(Y = 1) = 0.4$, $P(Y = 2) = 0.3$.

$$E(X) = 0.7, \quad E(Y) = 0(0.3) + 1(0.4) + 2(0.3) = 1.0$$

$$E(XY) = \sum xy p(x, y) = 0 + 0 + 0 + 0 + 1(0.3) + 2(0.3) = 0.9$$

$$\text{Cov}(X, Y) = 0.9 - (0.7)(1.0) = 0.2.$$

Con más cálculo se obtienen σ_X, σ_Y y de ahí $\rho_{X,Y}$ (ejercicio resuelto completo en la Práctica 2)

Idea

Vimos que calcular $E(X)$, $E(X^2)$, $E(X^3)$, ... (los **momentos** de X) requiere resolver una suma o integral distinta para cada orden. La **función generatriz de momentos** (FGM) es una función que “codifica” todos los momentos de una vez, y además caracteriza unívocamente la distribución.

Definición

Definition (Función generatriz de momentos)

Sea X una variable aleatoria. La función generatriz de momentos de X es

$$M_X(t) = E\left(e^{tX}\right),$$

definida para todo t en un entorno de 0 tal que la esperanza sea finita (si no existe tal entorno, se dice que la FGM no existe).

Caso discreto: $M_X(t) = \sum_i e^{tx_i} p(x_i)$. Caso continuo: $M_X(t) = \int_{-\infty}^{\infty} e^{tx} f(x) dx$.

¿Por qué “generatriz de momentos”?

Como veremos, derivando $M_X(t)$ respecto de t y evaluando en $t = 0$ se obtienen los momentos $E(X^k)$.

Propiedad 1: generación de momentos

Theorem

Si $M_X(t)$ existe en un entorno de 0, entonces es infinitamente derivable allí y

$$M_X^{(k)}(0) = E(X^k), \quad k = 1, 2, 3, \dots$$

Idea de la demostración.

Suponiendo que se puede derivar bajo el signo de esperanza (integral o suma),

$$M_X'(t) = \frac{d}{dt} E(e^{tX}) = E\left(\frac{d}{dt} e^{tX}\right) = E(Xe^{tX}).$$

Evaluando en $t = 0$: $M_X'(0) = E(Xe^0) = E(X)$. Derivando nuevamente,

$$M_X''(t) = E(X^2 e^{tX}) \Rightarrow M_X''(0) = E(X^2),$$

y en general $M_X^{(k)}(t) = E(X^k e^{tX})$, de donde $M_X^{(k)}(0) = E(X^k)$. ■



Propiedad 2: unicidad

Theorem (Unicidad)

*Si $M_X(t)$ y $M_Y(t)$ existen y coinciden en un entorno de 0, entonces X e Y tienen la **misma** distribución.*

Utilidad práctica

Esta propiedad es muy poderosa: para identificar la distribución de una variable aleatoria (por ejemplo, una suma de variables), basta calcular su FGM y reconocerla como la de una distribución conocida. No hace falta calcular la densidad o función de probabilidad puntual directamente.

Propiedad 3: FGM de una suma de independientes

Theorem

Si X e Y son independientes, entonces

$$M_{X+Y}(t) = M_X(t) \cdot M_Y(t).$$

Demostración.

$$M_{X+Y}(t) = E\left(e^{t(X+Y)}\right) = E\left(e^{tX}e^{tY}\right) = E(e^{tX})E(e^{tY}) = M_X(t)M_Y(t),$$

donde el penúltimo paso usa que X e Y independientes implica que e^{tX} y e^{tY} también lo son, y por lo tanto $E(e^{tX}e^{tY}) = E(e^{tX})E(e^{tY})$. ■ □

Otras propiedades útiles

- $M_{aX+b}(t) = e^{bt} M_X(at)$.
- $M_X(0) = 1$ siempre (pues $e^0 = 1$).

FGM de la distribución binomial

Example

Sea $X \sim \text{Bin}(n, p)$.

$$M_X(t) = \sum_{k=0}^n e^{tk} \binom{n}{k} p^k (1-p)^{n-k} = \sum_{k=0}^n \binom{n}{k} (pe^t)^k (1-p)^{n-k} = (1-p+pe^t)^n,$$

usando el teorema del binomio de Newton. Se puede verificar: $M'_X(t) = n(1-p+pe^t)^{n-1}pe^t$, y $M'_X(0) = n(1)^{n-1}p = np = E(X)$. Consistente con lo visto en la Clase 14.

FGM de Poisson y exponencial

Example (Poisson)

Sea $X \sim \text{Poisson}(\lambda)$.

$$M_X(t) = \sum_{k=0}^{\infty} e^{tk} \frac{e^{-\lambda} \lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(\lambda e^t)^k}{k!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t - 1)}.$$

Example (Exponencial)

Sea $X \sim \text{Exp}(\lambda)$, para $t < \lambda$:

$$M_X(t) = \int_0^{\infty} e^{tx} \lambda e^{-\lambda x} dx = \lambda \int_0^{\infty} e^{-(\lambda - t)x} dx = \frac{\lambda}{\lambda - t}.$$

(La integral converge solo si $t < \lambda$; para $t \geq \lambda$, la FGM no existe.)

FGM de la distribución normal

Example (Normal estándar y general)

Sea $Z \sim N(0, 1)$. Completando cuadrados en el exponente:

$$M_Z(t) = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz = e^{t^2/2},$$

pues la última integral es el área total bajo una densidad $N(t, 1)$, que vale 1.

Si $X = \mu + \sigma Z \sim N(\mu, \sigma^2)$, usando $M_{aX+b}(t) = e^{bt} M_X(at)$:

$$M_X(t) = e^{\mu t} M_Z(\sigma t) = e^{\mu t} e^{\sigma^2 t^2/2} = e^{\mu t + \sigma^2 t^2/2}.$$

Aplicación clave (Unidad futura y Clase 18)

Como consecuencia de la Propiedad 3, si $X_1 \sim N(\mu_1, \sigma_1^2)$ y $X_2 \sim N(\mu_2, \sigma_2^2)$ son independientes, $M_{X_1+X_2}(t) = e^{(\mu_1+\mu_2)t + (\sigma_1^2+\sigma_2^2)t^2/2}$, que es la FGM de una $N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$. Por unicidad, ¡la suma de normales independientes es normal!

Conceptos clave

- $\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$; mide asociación *lineal*. Independencia $\Rightarrow$ covarianza cero (no vale la recíproca).
- $\rho_{X,Y} = \text{Cov}(X, Y)/(\sigma_X\sigma_Y) \in [-1, 1]$: versión adimensional de la covarianza.
- $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$.
- FGM: $M_X(t) = E(e^{tX})$. Genera momentos ($M_X^{(k)}(0) = E(X^k)$), caracteriza la distribución (unicidad), y $M_{X+Y}(t) = M_X(t)M_Y(t)$ si $X \perp Y$.
- FGM conocidas: Binomial $(1 - p + pe^t)^n$; Poisson $e^{\lambda(e^t-1)}$; Exponencial $\lambda/(\lambda - t)$; Normal $e^{\mu t + \sigma^2 t^2/2}$.

Próximas clases

Usaremos estas herramientas para demostrar la ley de los grandes números (Clase 17) y el teorema central del límite (Clase 18).