

Clase 18: Teorema central del límite

Unidad 4: Función generadora de momentos

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

- 1 Motivación
- 2 Enunciado del TCL
- 3 Aplicaciones: sumas
- 4 Aproximación normal a la binomial
- 5 Aproximación normal a la Poisson
- 6 Visualización y alcance del teorema
- 7 Resumen

De la ley de los grandes números al TCL

Lo que ya sabemos (Clase 17)

Si $X_1, \dots, X_n$ son i.i.d. con $E(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2$, entonces $\bar{X}_n \xrightarrow{P} \mu$: el promedio muestral se acerca a μ , y su varianza $\sigma^2/n \rightarrow 0$.

Pregunta natural

Sabemos que $\bar{X}_n - \mu$ tiende a 0. Pero, ¿con qué **forma** (distribución) se acerca a 0? Si “agrandamos la lupa” apropiadamente (reescalando por $\sqrt{n}$), ¿qué distribución límite aparece?

Este es el contenido del **teorema central del límite** (TCL), posiblemente el resultado más importante de toda la teoría de probabilidad clásica, por su enorme generalidad y sus aplicaciones prácticas.

La variable estandarizada

Sean $X_1, \dots, X_n$ i.i.d. con $E(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2 < \infty$, y sea $S_n = X_1 + \dots + X_n$. Sabemos:

$$E(S_n) = n\mu, \quad \text{Var}(S_n) = n\sigma^2.$$

Definimos la versión estandarizada de S_n (o, equivalentemente, de $\bar{X}_n$):

$$Z_n = \frac{S_n - n\mu}{\sigma\sqrt{n}} = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}.$$

Por construcción (Clase 15), $E(Z_n) = 0$ y $\text{Var}(Z_n) = 1$ para todo n .

Enunciado

Theorem (Teorema central del límite)

Sean $X_1, \dots, X_n$ variables aleatorias i.i.d. con $E(X_i) = \mu$ y $\text{Var}(X_i) = \sigma^2 \in (0, \infty)$. Entonces, cuando $n \rightarrow \infty$, la distribución de

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} = \frac{S_n - n\mu}{\sqrt{n} \sigma}$$

converge a la distribución normal estándar $N(0, 1)$. Es decir, para todo $z \in \mathbb{R}$:

$$\lim_{n \rightarrow \infty} P(Z_n \leq z) = \Phi(z) = P(Z \leq z), \quad Z \sim N(0, 1).$$

Lo notable

El resultado vale sin importar cuál sea la distribución **original** de los X_i (discreta, continua, simétrica, asimétrica...), siempre que tenga media y varianzas finitas. Por eso se llama “central”: es un resultado unificador.

Idea de la demostración usando la FGM

Estrategia

Usamos la unicidad de la función generatriz de momentos (Clase 16): si mostramos que $M_{Z_n}(t) \rightarrow M_Z(t) = e^{t^2/2}$ (la FGM de $N(0, 1)$) para todo t , entonces Z_n converge en distribución a $N(0, 1)$.

Sea $Y_i = \frac{X_i - \mu}{\sigma}$ (estandarización de cada X_i individual), con $E(Y_i) = 0$,
 $\text{Var}(Y_i) = E(Y_i^2) = 1$. Entonces

$$Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i.$$

Por independencia y la propiedad de la FGM de una suma (Clase 16, $M_{aX}(t) = M_X(at)$):

$$M_{Z_n}(t) = \left[M_Y\left(\frac{t}{\sqrt{n}}\right) \right]^n.$$

Idea de la demostración (continuación)

Desarrollo de Taylor de M_Y cerca de 0

Como $M_Y(0) = 1$, $M'_Y(0) = E(Y) = 0$, $M''_Y(0) = E(Y^2) = 1$, el desarrollo de Taylor de segundo orden alrededor de 0 da

$$M_Y(s) \approx 1 + 0 \cdot s + \frac{1}{2}s^2 + o(s^2), \quad \text{cuando } s \rightarrow 0.$$

Sustituyendo $s = t/\sqrt{n}$ (que $\rightarrow 0$ cuando $n \rightarrow \infty$, para t fijo):

$$M_Y\left(\frac{t}{\sqrt{n}}\right) \approx 1 + \frac{t^2}{2n} + o\left(\frac{1}{n}\right).$$

Elevando a la n y usando el límite notable $\left(1 + \frac{a}{n} + o(1/n)\right)^n \rightarrow e^a$:

$$M_{Z_n}(t) = \left[1 + \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right]^n \xrightarrow{n \rightarrow \infty} e^{t^2/2} = M_Z(t).$$

Por la unicidad de la FGM, Z_n converge en distribución a $Z \sim N(0, 1)$. (Una demostración

Aproximación para n grande

Para n suficientemente grande (en la práctica, suele usarse $n \geq 30$ como regla general, aunque depende de cuán “lejos de la normal” sea la distribución original):

$$\bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad S_n = \sum_{i=1}^n X_i \sim N(n\mu, n\sigma^2),$$

donde $\sim$ significa “se distribuye aproximadamente como”. Equivalentemente,

$$P(\bar{X}_n \leq a) \approx \Phi\left(\frac{a - \mu}{\sigma/\sqrt{n}}\right).$$

Ejemplo: suma de tiempos de servicio

Example

El tiempo de atención en una caja tiene media $\mu = 4$ minutos y desviación estándar $\sigma = 2$ minutos (distribución no especificada). Se atienden $n = 64$ clientes independientes. Aproximar la probabilidad de que el tiempo total de atención supere las 4.5 horas (270 minutos).

$$S_{64} \sim N(64 \cdot 4, 64 \cdot 4) = N(256, 256), \text{ con } \sqrt{256} = 16.$$

$$P(S_{64} > 270) \approx P\left(Z > \frac{270 - 256}{16}\right) = P(Z > 0.875) \approx 1 - \Phi(0.875) \approx 1 - 0.8092 = 0.1908.$$

Hay aproximadamente 19 % de probabilidad de superar las 4.5 horas.

Motivación y enunciado

Idea

$X \sim \text{Bin}(n, p)$ puede escribirse como $X = \sum_{i=1}^n X_i$ con $X_i \sim \text{Bernoulli}(p)$ i.i.d. Por el TCL, para n grande,

$$X \dot{\sim} N(np, np(1-p)).$$

Regla práctica de aplicabilidad

La aproximación es razonable cuando $np \geq 5$ y $n(1-p) \geq 5$ (algunos textos piden ≥ 10): la distribución binomial debe ser suficientemente simétrica.

Corrección por continuidad

Como la binomial es discreta y la normal es continua, se mejora la aproximación con la **corrección por continuidad**: para k entero,

$$P(X = k) \approx P(k-0.5 < Y < k+0.5), \quad P(X \leq k) \approx P(Y \leq k+0.5), \quad Y \sim N(np, np(1-p)).$$

Ejemplo resuelto: aproximación normal a la binomial

Example

Una empresa afirma que el 30 % de sus clientes usa la app móvil. Se encuesta a $n = 200$ clientes independientes. Sea X = número de clientes que usan la app. Aproximar $P(50 \leq X \leq 70)$.

$X \sim \text{Bin}(200, 0.3)$: $np = 60 \geq 5$, $n(1 - p) = 140 \geq 5$. $\mu = 60$, $\sigma^2 = 200(0.3)(0.7) = 42$,
 $\sigma = \sqrt{42} \approx 6.481$.

Con corrección por continuidad:

$$\begin{aligned} P(50 \leq X \leq 70) &\approx P(49.5 \leq Y \leq 70.5), \quad Y \sim N(60, 42). \\ &= \Phi\left(\frac{70.5 - 60}{6.481}\right) - \Phi\left(\frac{49.5 - 60}{6.481}\right) = \Phi(1.620) - \Phi(-1.620) \\ &\approx 0.9474 - 0.0526 = 0.8948. \end{aligned}$$

La probabilidad aproximada es 89.5 %.

Motivación y enunciado

Idea

Si $X \sim \text{Poisson}(\lambda)$ con λ grande, X puede pensarse (informalmente) como una suma de muchas variables Poisson pequeñas independientes (la Poisson es “cerrada bajo sumas”: si $X_1 \sim \text{Poisson}(\lambda_1)$, $X_2 \sim \text{Poisson}(\lambda_2)$ independientes, $X_1 + X_2 \sim \text{Poisson}(\lambda_1 + \lambda_2)$). Como $E(X) = \text{Var}(X) = \lambda$, el TCL sugiere

$$X \dot{\sim} N(\lambda, \lambda), \quad \text{razonable para } \lambda \gtrsim 10.$$

Corrección por continuidad

Igual que en la binomial: $P(X \leq k) \approx \Phi\left(\frac{k + 0.5 - \lambda}{\sqrt{\lambda}}\right)$.

Ejemplo resuelto: aproximación normal a la Poisson

Example

El número de llamadas que recibe un call center en una hora sigue una distribución Poisson con $\lambda = 50$. Aproximar $P(X > 60)$.

$\mu = \lambda = 50$, $\sigma = \sqrt{50} \approx 7.071$. Con corrección por continuidad,
 $P(X > 60) = P(X \geq 61) \approx P(Y > 60.5)$:

$$P(X > 60) \approx 1 - \Phi\left(\frac{60.5 - 50}{7.071}\right) = 1 - \Phi(1.485) \approx 1 - 0.9312 = 0.0688.$$

Hay aproximadamente 6.9 % de probabilidad de recibir más de 60 llamadas en una hora.


Comparación (referencia)

El valor exacto (calculado con la fórmula de Poisson, sumando $P(X = 61) + P(X = 62) + \dots$) es aproximadamente 0.0655: la aproximación normal con corrección por continuidad es bastante precisa incluso con λ moderado.

Visualización: la binomial se aproxima a la normal

Idea gráfica

A medida que n crece, el histograma de la distribución binomial (barras) se asemeja cada vez más a la curva de densidad normal continua. El siguiente gráfico esquematiza esta aproximación para $\text{Bin}(n, 0.5)$ estandarizada.



Ejemplo adicional: aproximación normal a la binomial

Example

En una línea de producción, la probabilidad de que un artículo pase el control de calidad es $p = 0.85$. Se inspeccionan $n = 120$ artículos independientes. Aproximar $P(X < 95)$, donde X es el número de artículos que pasan el control.

$np = 120(0.85) = 102 \geq 5$, $n(1 - p) = 120(0.15) = 18 \geq 5$: se puede aproximar. $\mu = 102$, $\sigma^2 = 120(0.85)(0.15) = 15.3$, $\sigma \approx 3.912$.

Con corrección por continuidad, $P(X < 95) = P(X \leq 94) \approx P(Y \leq 94.5)$:

$$P(X < 95) \approx \Phi\left(\frac{94.5 - 102}{3.912}\right) = \Phi(-1.917) \approx 0.0276.$$

Hay aproximadamente 2.76 % de probabilidad de que menos de 95 artículos pasen el control.

Alcance del TCL: por qué es tan importante

Universalidad

El TCL explica por qué la distribución normal aparece con tanta frecuencia en la naturaleza y en las ciencias sociales: cualquier magnitud que resulte de **sumar o promediar** muchos efectos pequeños e independientes (errores de medición, alturas influidas por muchos genes y factores ambientales, promedios de calificaciones, etc.) tiende a distribuirse aproximadamente normal, sin importar la distribución de cada efecto individual.

Conexión con unidades futuras

El TCL es la base teórica de la **inferencia estadística** (estimación de parámetros, intervalos de confianza, pruebas de hipótesis), que se estudiará en unidades posteriores de la materia: permite aproximar la distribución de estadísticos muestrales (como $\bar{X}_n$ o proporciones muestrales) por una normal, aun cuando la población de origen no lo sea.

Ejemplo final: margen de error de una encuesta

Example

Retomando la encuesta de la Clase 17 ($n = 1500$, $p = 0.48$ real), aproximar (en vez de acotar con Chebyshev) la probabilidad de que $\hat{p}$ se aparte de 0.48 en más de 0.03, usando el TCL.

$\sigma_{\hat{p}} = \sqrt{0.0001664} \approx 0.01290$. Por el TCL, $\hat{p} \sim N(0.48, 0.0001664)$:

$$P(|\hat{p} - 0.48| \geq 0.03) \approx 2 \left[1 - \Phi \left(\frac{0.03}{0.01290} \right) \right] = 2[1 - \Phi(2.326)] \approx 2(1 - 0.9900) = 0.0200.$$

La probabilidad aproximada es solo 2 %, mucho más ajustada que el 18.5 % que daba Chebyshev en la Clase 17: al conocer que $\hat{p}$ es (aproximadamente) normal, la estimación de probabilidades es mucho más precisa que la cota universal de Chebyshev.

Conceptos clave

- El **TCL** afirma que $Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$ converge en distribución a $N(0, 1)$, sin importar la distribución original de los X_i (con media y varianza finitas).
- Se demuestra (idea) usando que $M_{Z_n}(t) \rightarrow e^{t^2/2}$, la FGM de la normal estándar, y la propiedad de unicidad de la FGM.
- Forma práctica: $\bar{X}_n \sim N(\mu, \sigma^2/n)$, $S_n \sim N(n\mu, n\sigma^2)$, para n moderadamente grande.
- **Aproximación normal a la binomial**: $\text{Bin}(n, p) \sim N(np, np(1-p))$ si $np \geq 5$ y $n(1-p) \geq 5$.
- **Aproximación normal a la Poisson**: $\text{Poisson}(\lambda) \sim N(\lambda, \lambda)$ para λ grande.
- En ambos casos, usar **corrección por continuidad** al aproximar variables discretas con la normal continua.

Cierre de la Unidad 4

Con esperanza, varianza, covarianza, FGM, ley de los grandes números y TCL, completamos la