Clase 19: Muestras aleatorias y estadísticos muestrales

Unidad 5: Muestras aleatorias y distribuciones

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

1. De la probabilidad a la inferencia
2. Población y muestra
3. Estadísticos muestrales
4. Distribución muestral de un estadístico
5. Esperanza y varianza de la media muestral
6. Resumen

Un cambio de perspectiva

Lo que hicimos hasta ahora

En las Unidades 1 a 4 supusimos **conocido** el modelo probabilístico (distribución, parámetros) y calculamos probabilidades, esperanzas, varianzas, etc. a partir de él.

El problema real

En la práctica casi nunca conocemos los parámetros poblacionales (una media μ, una proporción p, una varianza σ^2). Lo que tenemos son **datos**: mediciones, observaciones, un conjunto finito de valores obtenidos experimentalmente.

Un cambio de perspectiva (cont.)

Example

- ¿Cuál es el peso medio μ de los paquetes que produce una máquina envasadora?
- ¿Cuál es la proporción p de piezas defectuosas en un lote de producción?
- ¿Cuál es la varianza σ^2 del tiempo de reacción de un fármaco?

No conocemos estos valores: los queremos **estimar** a partir de una muestra.

Esta unidad es el puente entre la **probabilidad** (Unidades 1-4) y la **inferencia estadística** (Unidades 6-8).

Estadística descriptiva vs. estadística inferencial

Estadística descriptiva

Organiza, resume y presenta datos: tablas de frecuencias, histogramas, medias y varianzas *muestrales* calculadas directamente sobre los datos disponibles, sin hacer supuestos probabilísticos sobre cómo se generaron.

Estadística inferencial

Usa los datos de una muestra para sacar **conclusiones sobre la población** de la cual provienen, cuantificando la incertidumbre mediante modelos probabilísticos. Incluye estimación de parámetros (Unidad 6), pruebas de hipótesis (Unidad 7) y modelos de regresión (Unidad 8).

La clave

La estadística inferencial necesita entender el **comportamiento aleatorio** de las cantidades calculadas a partir de la muestra. Eso es precisamente lo que estudiamos en esta unidad.

Población

Definition (Población)

La **población** es el conjunto de todos los individuos, objetos o mediciones de interés para un estudio. Puede ser finita (los 5000 artículos producidos hoy) o conceptualmente infinita (todos los artículos que la máquina *podría* producir bajo las mismas condiciones).

Modelo probabilístico de la población

Asociamos a la población una variable aleatoria X cuya distribución (función de probabilidad, densidad, media μ, varianza σ^2, etc.) describe la característica de interés. Los **parámetros** de esa distribución (μ, σ^2, p, λ, ...) son números fijos pero **desconocidos** que queremos estudiar.

Example

- $X =$ peso de un paquete producido por la envasadora. Población: distribución de X, con μ, σ^2 desconocidos.
- $X = 1$ si una pieza es defectuosa, 0 si no. Población: Bernoulli(p), con p desconocido.

Muestra aleatoria: idea intuitiva

¿Cómo estudiamos la población?

No podemos (ni conviene) medir a *toda* la población. En cambio, seleccionamos un subconjunto de n individuos: la **muestra**, y usamos la información que aporta para inferir sobre la población.

Requisito fundamental

Para que las conclusiones sean válidas, la muestra debe seleccionarse de manera que cada observación:

1. tenga la **misma distribución** que la población (represente fielmente a X), y
2. sea **independiente** de las demás observaciones.

Esto se garantiza, típicamente, con muestreo aleatorio (con reposición, o sin reposición de una población muy grande frente a n).

Muestra aleatoria: definición formal

Definition (Muestra aleatoria)

Sea X una variable aleatoria que representa la característica de interés de una población, con función de distribución F_X. Una **muestra aleatoria** de tamaño n es una colección de variables aleatorias

$$X_1, X_2, \ldots, X_n$$

independientes e idénticamente distribuidas (i.i.d.), cada una con la misma distribución F_X que la población.

Notación

Antes de observar los datos, $X_1, \ldots, X_n$ son variables aleatorias (mayúsculas). Una vez realizado el experimento, obtenemos valores concretos $x_1, \ldots, x_n$ (minúsculas): la **realización** de la muestra, es decir, los datos.

Muestra aleatoria: definición formal (cont.)

Example

Se seleccionan al azar y con reposición 10 paquetes de una línea de producción y se pesa cada uno. Antes de pesar: $X_1, \ldots, X_{10}$ i.i.d. Después de pesar: $x_1 = 249.8, x_2 = 251.3, \ldots$ (los datos observados).

¿Por qué i.i.d.?

Idénticamente distribuidas

Cada X_i debe representar a la misma población, con la misma F_X, la misma media μ y la misma varianza σ^2. Si mezclamos poblaciones distintas (por ejemplo, piezas de dos máquinas diferentes) esto falla.

Independientes

El resultado de una observación no debe influir en las demás. En un muestreo *sin* reposición de una población finita de tamaño N, las observaciones no son estrictamente independientes; pero si $N \gg n$ (por ejemplo $n/N < 0.05$), la dependencia es despreciable y se aproxima como muestreo aleatorio simple.

¿Por qué i.i.d.? (cont.)

Consecuencia técnica

Como los X_i son i.i.d., toda la teoría de suma de variables independientes (funciones generadoras de momentos, Unidad 4) se aplica directamente a estadísticos que son funciones de $X_1, \ldots, X_n$.

Parámetro vs. estadístico

	Parámetro	**Estadístico**
¿Qué es?	Número fijo de la población	Función de la muestra
¿Se conoce?	Generalmente no	Se calcula de los datos
¿Es aleatorio?	No, es constante	Sí, es una variable aleatoria
Ejemplo	μ, σ^2, p	$\bar{X}, S^2, \hat{p}$

Definition (Estadístico)

Un **estadístico** es cualquier función $T = h(X_1, \ldots, X_n)$ de una muestra aleatoria que no depende de parámetros desconocidos. Al ser función de variables aleatorias, T es en sí misma una variable aleatoria, con su propia distribución.

Media muestral

Definition (Media muestral)

Dada una muestra aleatoria $X_1, \ldots, X_n$, se define la **media muestral** como

$$\bar{X} = \frac{1}{n} \sum_{i=1}^{n} X_i.$$

Es una variable aleatoria

$\bar{X}$ depende de qué muestra concreta se obtuvo: si repetimos el muestreo, obtenemos otro valor de $\bar{X}$. Por eso tiene sentido preguntarse cuál es **su** distribución, **su** esperanza y **su** varianza.
Esto es distinto de la media aritmética de un conjunto fijo de números (estadística descriptiva), aunque se calculen con la misma fórmula.

Varianza muestral

Definition (Varianza muestral)

Dada una muestra aleatoria $X_1, \ldots, X_n$, se define la **varianza muestral** como

$$S^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \bar{X})^2.$$

¿Por qué dividir por $n-1$ y no por n?

Se pierde "un grado de libertad" porque los n términos $(X_i - \bar{X})$ no son libres: siempre satisfacen $\sum_{i=1}^{n} (X_i - \bar{X}) = 0$. Dividir por $n-1$ hace que S^2 sea un estimador **insesgado** de σ^2, es decir $E(S^2) = \sigma^2$ (lo demostraremos en la Clase 20 y se retomará en la Unidad 6).

Otros estadísticos usuales: desvío estándar muestral $S = \sqrt{S^2}$, mínimo, máximo, mediana muestral, proporción muestral $\hat{p} = \frac{1}{n} \sum X_i$ (cuando $X_i \in \{0, 1\}$).

Ejemplo: cálculo de estadísticos

Example

Se pesan (en gramos) 6 paquetes: $248, 251, 253, 247, 250, 252$.
Calculamos $\bar{x}$ y s^2 (realizaciones, es decir, valores numéricos concretos):

$$\bar{x} = \frac{248 + 251 + 253 + 247 + 250 + 252}{6} = \frac{1501}{6} = 250.1\overline{6}$$

$$\sum (x_i - \bar{x})^2 = (2.17)^2 + (0.83)^2 + (2.83)^2 + (3.17)^2 + (0.17)^2 + (1.83)^2 \approx 24.83$$

$$s^2 = \frac{24.83}{5} \approx 4.97 \quad \Rightarrow \quad s \approx 2.23 \text{ g}$$

Ejemplo: cálculo de estadísticos (cont.)

Distinción clave

$\bar{x} = 250.1\overline{6}$ es **un** número: una realización de la variable aleatoria $\bar{X}$. Si otro operario pesara otros 6 paquetes, obtendría otro valor de $\bar{x}$.

El concepto central de la unidad

Distribución muestral

La **distribución muestral** de un estadístico $T = h(X_1, \ldots, X_n)$ es la distribución de probabilidad de T, considerada como variable aleatoria sobre todas las posibles muestras de tamaño n que se podrían extraer de la población.

¿Por qué importa?

Para hacer inferencia necesitamos saber, por ejemplo: si μ fuera realmente igual a cierto valor, ¿qué tan probable es observar un $\bar{x}$ tan alejado de μ como el que obtuvimos? Responder esto exige conocer la distribución de $\bar{X}$, no solo su valor puntual.

El concepto central de la unidad (cont.)

Example (Ilustración con una población pequeña)

Población: $\{2, 4, 6\}$ equiprobable ($\mu = 4$). Muestras de tamaño $n = 2$ *con reposición*: hay $3^2 = 9$ muestras igualmente probables. Los valores de $\bar{X}$ posibles son $2, 3, 4, 5, 6$, cada uno con cierta probabilidad (no todos igualmente probables): esto ya define una distribución muestral de $\bar{X}$.

Ejemplo: distribución muestral exacta

Example

Continuando: población $\{2, 4, 6\}$, $n = 2$ con reposición. Las 9 muestras equiprobables (prob. 1/9 c/u) y su media:

(2,2)	(2,4)	(2,6)	(4,2)	(4,4)	(4,6)	(6,2)	(6,4)	(6,6)
2	3	4	3	4	5	4	5	6

Distribución muestral de $\bar{X}$:

$$P(\bar{X} = 2) = \tfrac{1}{9},\ P(\bar{X} = 3) = \tfrac{2}{9},\ P(\bar{X} = 4) = \tfrac{3}{9},\ P(\bar{X} = 5) = \tfrac{2}{9},\ P(\bar{X} = 6) = \tfrac{1}{9}$$

Se verifica $E(\bar{X}) = 2 \cdot \frac{1}{9} + 3 \cdot \frac{2}{9} + 4 \cdot \frac{3}{9} + 5 \cdot \frac{2}{9} + 6 \cdot \frac{1}{9} = 4 = \mu$.

Deducción de $E(\bar{X})$

Theorem (Esperanza de la media muestral)

Sea $X_1, \ldots, X_n$ una muestra aleatoria de una población con $E(X_i) = \mu$ (finita). Entonces

$$E(\bar{X}) = \mu.$$

Proof.

Por linealidad de la esperanza (no requiere independencia):

$$E(\bar{X}) = E\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n}\sum_{i=1}^{n} E(X_i) = \frac{1}{n} \cdot n\mu = \mu. \quad \square$$

Interpretación

En promedio (sobre todas las posibles muestras), la media muestral "acierta": ni sobreestima ni subestima sistemáticamente a μ. Se dice que $\bar{X}$ es un estimador **insesgado** de μ.

Deducción de $\mathrm{Var}(\bar{X})$

Theorem (Varianza de la media muestral)

Sea $X_1, \ldots, X_n$ una muestra aleatoria (i.i.d.) de una población con $Var(X_i) = \sigma^2$ (finita). Entonces

$$Var(\bar{X}) = \frac{\sigma^2}{n}.$$

Proof.

Como los X_i son **independientes**, la varianza de la suma es la suma de varianzas:

$$\mathrm{Var}(\bar{X}) = \mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}(X_i) = \frac{1}{n^2}\cdot n\sigma^2 = \frac{\sigma^2}{n}. \quad \square$$

Deducción de $\mathrm{Var}(\bar{X})$ (cont.)

¿Dónde se usó la independencia?

En $\mathrm{Var}(X_i + X_j) = \mathrm{Var}(X_i) + \mathrm{Var}(X_j) + 2\,\mathrm{Cov}(X_i, X_j)$: al ser independientes, $\mathrm{Cov}(X_i, X_j) = 0$ para $i \neq j$, y los términos cruzados desaparecen. Sin independencia, esta fórmula tan simple no valdría.

Consecuencias de $\mathrm{Var}(\bar{X}) = \sigma^2/n$

Desvío estándar de $\bar{X}$ (error estándar)

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

se llama **error estándar** de la media. A diferencia de σ (fijo, de la población), $\sigma_{\bar{X}}$ **disminuye** a medida que crece n.

Interpretación central

Cuantas más observaciones promediamos, menos varía $\bar{X}$ de muestra a muestra: se **concentra** en torno a μ. Esto es la base intuitiva de la Ley de los Grandes Números y de por qué muestras más grandes dan estimaciones más precisas.

Consecuencias de $\mathrm{Var}(\bar{X}) = \sigma^2/n$ (cont.)

Example

Si $\sigma = 4$ g (desvío del peso poblacional) y $n = 25$, entonces $\sigma_{\bar{X}} = 4/\sqrt{25} = 0.8$ g: mucho más preciso que una sola medición individual.

Esperanza y varianza de la proporción muestral

Caso particular importante

Si $X_i \sim \text{Bernoulli}(p)$ (indica éxito/fracaso), entonces $\hat{p} = \bar{X} = \frac{1}{n}\sum X_i$ es la **proporción muestral** de éxitos. Como $E(X_i) = p$ y $\text{Var}(X_i) = p(1-p)$, los resultados anteriores dan directamente:

$$E(\hat{p}) = p, \qquad \text{Var}(\hat{p}) = \frac{p(1-p)}{n}.$$

Example

En un lote grande, la proporción real de piezas defectuosas es $p = 0.05$. Para $n = 200$:

$$E(\hat{p}) = 0.05, \qquad \text{Var}(\hat{p}) = \frac{0.05 \cdot 0.95}{200} = 0.0002375, \qquad \sigma_{\hat{p}} \approx 0.0154.$$

Lo que todavía no sabemos

Pregunta pendiente

Ya sabemos que $E(\bar{X}) = \mu$ y $\text{Var}(\bar{X}) = \sigma^2/n$, **para cualquier** población con media y varianza finitas. Pero esto no nos dice **la forma** de la distribución de $\bar{X}$ (¿es normal?, ¿es simétrica?, ¿qué probabilidad tiene $\bar{X}$ de superar cierto valor?).

Próxima clase

En la Clase 20 estudiaremos:

- la distribución **exacta** de $\bar{X}$ cuando la población es normal;
- la distribución **aproximada** de $\bar{X}$ para poblaciones no normales (Teorema Central del Límite);
- la distribución de S^2 y su relación con la distribución χ^2;
- el estadístico t de Student, que combina $\bar{X}$ y S.

Resumen

- Una **muestra aleatoria** $X_1, \ldots, X_n$ es una colección de v.a. **i.i.d.**, cada una con la distribución de la población.
- Un **parámetro** (ej. μ, σ^2, p) es un número fijo y desconocido de la población; un **estadístico** (ej. $\bar{X}, S^2, \hat{p}$) es una función de la muestra, y por lo tanto una **variable aleatoria**.
- La **distribución muestral** de un estadístico es su distribución de probabilidad, clave para toda la inferencia posterior.
- $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$, con $E(\bar{X}) = \mu$ y $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$ (esta última usa independencia).
- $S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$ estima σ^2; se divide por $n-1$ por la restricción $\sum(X_i - \bar{X}) = 0$.
- A mayor n, menor error estándar $\sigma_{\bar{X}} = \sigma/\sqrt{n}$: la media muestral se concentra en torno a μ.