

Clase 20: Distribución de la media y la varianza muestral

Unidad 5: Muestras aleatorias y distribuciones

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

- 1 Repaso
- 2 Distribución exacta de la media muestral (población normal)
- 3 Teorema Central del Límite aplicado a $\bar{X}$
- 4 Distribución de la varianza muestral
- 5 Independencia de $\bar{X}$ y S^2
- 6 El estadístico t de Student
- 7 Resumen

Repaso de la clase anterior

Lo que ya sabemos

Para una muestra aleatoria $X_1, \dots, X_n$ i.i.d. de una población con $E(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2$:

$$E(\bar{X}) = \mu, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

Lo que falta

Esto vale para **cualquier** población, pero no nos dice la **forma** de la distribución de $\bar{X}$. Hoy respondemos:

- ¿Qué distribución tiene $\bar{X}$ exactamente, si la población es normal?
- ¿Qué distribución tiene $\bar{X}$ aproximadamente, si la población no es normal?
- ¿Qué distribución tiene S^2 ?
- ¿Cómo se combinan $\bar{X}$ y S en el estadístico t ?

Caso población normal

Theorem (Distribución de $\bar{X}$ bajo normalidad)

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población $N(\mu, \sigma^2)$. Entonces

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Demostración.

Cada $X_i \sim N(\mu, \sigma^2)$ tiene función generadora de momentos $M_{X_i}(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right)$. Como los X_i son independientes,

$$\begin{aligned} M_{\bar{X}}(t) &= M_{\sum X_i/n}(t) = \prod_{i=1}^n M_{X_i}\left(\frac{t}{n}\right) = \left[\exp\left(\mu \frac{t}{n} + \frac{\sigma^2}{2} \frac{t^2}{n^2}\right) \right]^n \\ &= \exp\left(\mu t + \frac{\sigma^2/n}{2} t^2\right), \end{aligned}$$

Observaciones sobre el resultado

Es exacto, para cualquier n

A diferencia de otros resultados que veremos, este vale exactamente para $n = 1, 2, 3, \dots$, no solo asintóticamente. Es consecuencia de que la familia normal es **cerrada bajo combinaciones lineales** de variables independientes.

Tipificación

Como siempre con la normal, se puede estandarizar:

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1).$$

Esto permite calcular cualquier probabilidad sobre $\bar{X}$ usando la tabla de la normal estándar (Unidad 2).

Ejemplo resuelto

Example

El contenido de los frascos de una envasadora se distribuye $N(500, 16)$ mL (es decir $\mu = 500$, $\sigma^2 = 16$, $\sigma = 4$). Se toma una muestra aleatoria de $n = 16$ frascos. Calcular $P(498 < \bar{X} < 502)$.

Resolución. $\bar{X} \sim N(500, \frac{16}{16}) = N(500, 1)$, con $\sigma_{\bar{X}} = 1$.

$$\begin{aligned} P(498 < \bar{X} < 502) &= P\left(\frac{498 - 500}{1} < Z < \frac{502 - 500}{1}\right) = P(-2 < Z < 2) \\ &= \Phi(2) - \Phi(-2) = 0.9772 - 0.0228 = 0.9544. \end{aligned}$$

Comparación

$P(498 < X_1 < 502)$ para **una sola** observación sería $P(-0.5 < Z < 0.5) = 0.3829$, mucho menor: promediar reduce la dispersión.

¿Y si la población no es normal?

El problema

En la mayoría de las aplicaciones no sabemos que la población es normal, o sabemos que no lo es (tiempos de vida, ingresos, conteos). ¿Podemos igual decir algo sobre la distribución de $\bar{X}$?

Theorem (Teorema Central del Límite (TCL), para $\bar{X}$)

Sea $X_1, \dots, X_n$ una muestra aleatoria de **cualquier** población con $E(X_i) = \mu$ y $\text{Var}(X_i) = \sigma^2 < \infty$ (sin requerir normalidad). Entonces, cuando $n \rightarrow \infty$,

$$Z_n = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1),$$

es decir, la función de distribución de Z_n converge a la de la normal estándar en todo punto de continuidad.

Este es el mismo TCL de la Unidad 4 (para sumas $\sum X_i$), reescrito para la media $\bar{X} = \frac{1}{n} \sum X_i$.

Uso práctico del TCL

Aproximación para n grande

En la práctica, para n razonablemente grande (regla práctica usual: $n \geq 30$, aunque depende de cuán asimétrica sea la población), se aproxima

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

aunque la población no sea normal. Cuanto más se aleje la población de la normalidad (más asimétrica, colas más pesadas), mayor n se necesita para que la aproximación sea buena.

Caso especial

Si la población ya es normal, la distribución de $\bar{X}$ es **exacta** para todo n (no aproximada): es el caso límite “perfecto” del TCL.

Ejemplo resuelto: TCL

Example

El tiempo de atención en una caja de supermercado tiene media $\mu = 4$ min y desvío $\sigma = 2$ min (distribución desconocida, marcadamente asimétrica). Se observa una muestra de $n = 64$ clientes. Calcular aproximadamente $P(\bar{X} > 4.5)$.

Resolución. Como $n = 64$ es grande, por TCL $\bar{X} \sim N\left(4, \frac{4}{64}\right) = N(4, 0.0625)$, con $\sigma_{\bar{X}} = 0.25$.

$$P(\bar{X} > 4.5) \approx P\left(Z > \frac{4.5 - 4}{0.25}\right) = P(Z > 2) = 1 - \Phi(2) = 1 - 0.9772 = 0.0228.$$

Nota

Sin el TCL, no podríamos calcular esta probabilidad sin conocer la distribución exacta del tiempo de atención.

¿Qué distribución tiene S^2 ?

Al igual que con $\bar{X}$, $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ es una variable aleatoria: cambia de muestra a muestra. Para hacer inferencia sobre σ^2 (Unidad 6) necesitamos conocer su distribución, al menos cuando la población es normal.

Recordatorio: distribución chi-cuadrado (Unidad 4)

Si $Z_1, \dots, Z_k$ son v.a. $N(0, 1)$ independientes, entonces $\sum_{i=1}^k Z_i^2 \sim \chi_k^2$ (chi-cuadrado con k grados de libertad), con $E(\chi_k^2) = k$ y $\text{Var}(\chi_k^2) = 2k$.

Teorema: $(n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$

Theorem

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población $N(\mu, \sigma^2)$. Entonces

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2 \sim \chi_{n-1}^2.$$

Idea de la justificación

Si conociéramos μ en lugar de $\bar{X}$, tendríamos $\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 \sim \chi_n^2$ (suma de n cuadrados de $N(0, 1)$ independientes). Al reemplazar μ por su estimador $\bar{X}$ se “pierde” un grado de libertad, porque los residuos $X_i - \bar{X}$ satisfacen la restricción lineal $\sum_i (X_i - \bar{X}) = 0$: solo $n-1$ de ellos son “libres”. Formalmente se demuestra (usando una transformación ortogonal) que $\bar{X}$ y $\sum (X_i - \bar{X})^2$ son independientes y que esta suma normalizada resulta χ_{n-1}^2 .

Justificación para $n = 2$ (caso simple, verificable)

Example

Sean X_1, X_2 i.i.d. $N(\mu, \sigma^2)$. Entonces $\bar{X} = \frac{X_1 + X_2}{2}$ y

$$\sum_{i=1}^2 (X_i - \bar{X})^2 = \left(\frac{X_1 - X_2}{2} \right)^2 + \left(\frac{X_2 - X_1}{2} \right)^2 = \frac{(X_1 - X_2)^2}{2}.$$

Como $X_1 - X_2 \sim N(0, 2\sigma^2)$ (combinación lineal de normales independientes), se tiene

$$\frac{X_1 - X_2}{\sigma\sqrt{2}} \sim N(0, 1) \Rightarrow \left(\frac{X_1 - X_2}{\sigma\sqrt{2}} \right)^2 \sim \chi_1^2.$$

$$\text{Pero } \left(\frac{X_1 - X_2}{\sigma\sqrt{2}} \right)^2 = \frac{(X_1 - X_2)^2}{2\sigma^2} = \frac{\sum (X_i - \bar{X})^2}{\sigma^2} = \frac{(n-1)S^2}{\sigma^2} \text{ con } n-1 = 1.$$

Esto confirma el teorema para $n = 2$: 1 grado de libertad, tal como predice la fórmula general $n - 1$.

Consecuencia: $E(S^2) = \sigma^2$

Usando $E(\chi_{n-1}^2) = n - 1$

$$E\left(\frac{(n-1)S^2}{\sigma^2}\right) = n - 1 \implies \frac{n-1}{\sigma^2} E(S^2) = n - 1 \implies E(S^2) = \sigma^2.$$

Esto confirma lo anunciado en la Clase 19

S^2 (dividiendo por $n - 1$) es un estimador **insesgado** de σ^2 . Si se dividiera por n , se obtendría $E\left(\frac{n-1}{n} S^2\right) = \frac{n-1}{n} \sigma^2 \neq \sigma^2$: un estimador sesgado (subestima σ^2 en promedio).

Bonus: varianza de S^2

Usando $\text{Var}(\chi_{n-1}^2) = 2(n - 1)$ se obtiene $\text{Var}(S^2) = \frac{2\sigma^4}{n - 1}$ (población normal).

Ejemplo resuelto: chi-cuadrado

Example

El diámetro de piezas producidas por un torno se distribuye $N(\mu, \sigma^2)$ con $\sigma^2 = 0.04 \text{ mm}^2$. Se toma una muestra de $n = 10$ piezas y se obtiene $s^2 = 0.07 \text{ mm}^2$. Calcular $P(S^2 \geq 0.07)$.

Resolución. Bajo H : $\sigma^2 = 0.04$,

$$\frac{(n-1)S^2}{\sigma^2} = \frac{9 \cdot S^2}{0.04} \sim \chi_9^2.$$

El valor observado corresponde a

$$\frac{9 \cdot 0.07}{0.04} = 15.75.$$

Buscando en tabla de χ_9^2 : $P(\chi_9^2 \geq 15.75) \approx 0.073$ (entre los valores tabulados $\chi_{9,0.10}^2 = 14.68$ y $\chi_{9,0.05}^2 = 16.92$).

Es decir, obtener una varianza muestral tan grande o mayor no es muy improbable, aunque σ^2 realmente sea 0.04.

Un resultado no trivial (exclusivo de la normal)

Theorem (Independencia, población normal)

Si $X_1, \dots, X_n$ es una muestra aleatoria de una población $N(\mu, \sigma^2)$, entonces $\bar{X}$ y S^2 son variables aleatorias **independientes**.

¿Por qué sorprende?

S^2 se calcula usando $\bar{X}$ en su fórmula, así que uno esperaría dependencia. Sin embargo, para la distribución normal (y **solo** para ella, en general) resulta que “dónde está centrada” la muestra ($\bar{X}$) es independiente de “cuánto se dispersa alrededor de su centro” (S^2).

Idea geométrica (sin demostración formal aquí)

$\bar{X}$ depende solo de la componente de $(X_1, \dots, X_n)$ en la dirección del vector $(1, 1, \dots, 1)$; S^2 depende solo de las componentes ortogonales a esa dirección. Para vectores normales, componentes ortogonales no correlacionadas son independientes.

Esta independencia es esencial para el resultado que sigue.

El problema: σ desconocido

Repaso

Si σ^2 es **conocido**, sabemos que para población normal

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1).$$

El problema real

En la práctica σ casi nunca se conoce. Lo natural es **reemplazarlo** por su estimador S :

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}.$$

¿Qué distribución tiene T ? Ya no es exactamente $N(0, 1)$, porque ahora el denominador también es aleatorio (varía de muestra a muestra).

Definición y distribución t de Student

Recordatorio (Unidad 3): definición de la distribución t

Si $Z \sim N(0, 1)$ y $W \sim \chi_k^2$ son **independientes**, entonces

$$T = \frac{Z}{\sqrt{W/k}} \sim t_k \quad (\text{t de Student con } k \text{ grados de libertad}).$$

Theorem

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población $N(\mu, \sigma^2)$. Entonces

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

Demostración.

Escribimos T como cociente de $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ y $\sqrt{W/(n-1)}$, con

Propiedades de la t de Student

- Simétrica alrededor de 0, forma de campana, similar a la normal estándar pero con **colas más pesadas** (más dispersión: refleja la incertidumbre extra de estimar σ con S).
- Tiene un parámetro: los **grados de libertad** $k = n - 1$.
- A medida que $n \rightarrow \infty$ (y por tanto $k \rightarrow \infty$), $t_k \rightarrow N(0, 1)$: la incertidumbre de estimar σ se vuelve despreciable.
- Se tabula igual que la normal, pero la tabla depende de k .

Por qué importa

El estadístico $T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$ es la base de la inferencia sobre μ cuando σ es desconocido: intervalos de confianza y pruebas de hipótesis para la media (Unidades 6 y 7).

Ejemplo resuelto: t de Student

Example

El tiempo de secado de una pintura se supone $N(\mu, \sigma^2)$. En una muestra de $n = 15$ probetas se midió $\bar{x} = 20.4$ h y $s = 1.8$ h. Si realmente $\mu = 20$ h, calcular $P(\bar{X} \geq 20.4)$ usando la distribución adecuada.

Resolución. Como σ es desconocido y se estimó con s , usamos $t_{n-1} = t_{14}$:

$$t_{obs} = \frac{\bar{x} - \mu}{s/\sqrt{n}} = \frac{20.4 - 20}{1.8/\sqrt{15}} = \frac{0.4}{0.4648} \approx 0.861.$$

Buscando en tabla t_{14} : $P(T_{14} \geq 0.861)$ está entre 0.20 y 0.25 (valores tabulados: $t_{14,0.20} = 0.868$).

Es decir, $P(\bar{X} \geq 20.4) \approx 0.20$: un resultado bastante plausible si $\mu = 20$ h.

Síntesis: los tres resultados de hoy, en un cuadro

Cantidad	Distribución	Condición
$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$	$N(0, 1)$ exacta	Población normal
$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$	$N(0, 1)$ aproximada	n grande (TCL), cualquier población
$\frac{(n-1)S^2}{\sigma^2}$	χ_{n-1}^2 exacta	Población normal
$\frac{\bar{X} - \mu}{S/\sqrt{n}}$	t_{n-1} exacta	Población normal, σ desconocido

Estas cuatro distribuciones muestrales son las herramientas centrales de la estimación y las pruebas de hipótesis que siguen en las Unidades 6 y 7.

Resumen

- Población normal: $\bar{X} \sim N(\mu, \sigma^2/n)$, **exacto** para todo n (consecuencia de la f.g.m. normal).
- Población cualquiera (con $\sigma^2 < \infty$): TCL da $\bar{X} \dot{\sim} N(\mu, \sigma^2/n)$ para n grande.
- Población normal: $\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$; de aquí $E(S^2) = \sigma^2$ (S^2 insesgado).
- Población normal: $\bar{X}$ y S^2 son **independientes** (propiedad especial de la normal).
- Cuando σ es desconocido y se estima con S : $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$, con colas más pesadas que $N(0, 1)$ y que converge a $N(0, 1)$ cuando $n \rightarrow \infty$.
- Estos cuatro resultados son la base técnica de la estimación de parámetros (Unidad 6) y las pruebas de hipótesis (Unidad 7).