Clase 21: Estimación Puntual

Unidad 6: Estimación de parámetros

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

1. Introducción a la estimación
2. Insesgadez
3. Error cuadrático medio
4. Eficiencia
5. Consistencia
6. Ejemplo integrador
7. Resumen

De la probabilidad a la inferencia

Problema general de la Estadística Inferencial

Tenemos una población descripta por una variable aleatoria X cuya distribución depende de uno o más **parámetros desconocidos** θ (por ejemplo, μ, σ^2, p, λ). A partir de una **muestra aleatoria** $X_1, X_2, \ldots, X_n$ extraída de esa población, queremos decir algo razonable acerca de θ.

Idea central

Un **estimador** es una función de la muestra —es decir, un **estadístico**— que usamos para aproximar el valor del parámetro desconocido.

- Ya vimos (Unidad 5) qué es una muestra aleatoria y algunos estadísticos: $\overline{X}$, S^2, etc.
- Ahora estudiamos: *¿qué hace bueno a un estimador?* y *¿cómo construirlo?*

Definiciones básicas

Definition (Estimador puntual)

Sea $X_1, \ldots, X_n$ una muestra aleatoria de una población con distribución que depende de un parámetro $\theta \in \Theta$. Un **estimador puntual** de θ es un estadístico

$$\widehat{\theta} = \widehat{\theta}(X_1, \ldots, X_n)$$

es decir, una función de la muestra que no depende de θ.

Definition (Estimación)

Si $x_1, \ldots, x_n$ son los valores observados (los datos concretos), el número $\widehat{\theta}(x_1, \ldots, x_n)$ se llama **estimación** puntual de θ.

Definiciones básicas (cont.)

Observación clave

$\widehat{\theta}$ es una variable aleatoria (depende de la muestra, que es aleatoria); por lo tanto tiene su propia distribución, llamada **distribución muestral del estimador**, con su media, varianza, etc.

Ejemplos de estimadores usuales

Sea $X_1, \ldots, X_n$ m.a. de una población con media μ y varianza σ^2.

- Estimadores de μ: la media muestral $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$, o la mediana muestral $\widetilde{X}$.
- Estimadores de σ^2: la cuasivarianza muestral $S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2$, o la varianza muestral $\widehat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2$.
- Estimador de una proporción p: $\widehat{p} = \frac{Y}{n}$, donde $Y \sim \text{Bi}(n, p)$ cuenta *éxitos*.

Pregunta natural

Para un mismo parámetro hay *varios* estimadores posibles ($\overline{X}$ vs. $\widetilde{X}$; S^2 vs. $\widehat{\sigma}^2$). ¿Cuál conviene usar? Necesitamos **criterios de comparación**.

Insesgadez

Definition (Estimador insesgado)

$\widehat{\theta}$ es un **estimador insesgado** (o *centrado*) de θ si

$$E(\widehat{\theta}) = \theta \qquad \text{para todo } \theta \in \Theta.$$

El **sesgo** de $\widehat{\theta}$ se define como

$$B(\widehat{\theta}) = E(\widehat{\theta}) - \theta.$$

Si $B(\widehat{\theta}) \neq 0$, el estimador es **sesgado**.

Interpretación

En promedio, sobre infinitas repeticiones del muestreo, un estimador insesgado no sobreestima ni subestima sistemáticamente al parámetro.

Ejemplo: $\overline{X}$ es insesgado para μ

Example

Sea $X_1, \ldots, X_n$ m.a. de una población con $E(X_i) = \mu$. Entonces

$$E(\overline{X}) = E\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n}\sum_{i=1}^{n} E(X_i) = \frac{1}{n} \cdot n\mu = \mu.$$

Por lo tanto $\overline{X}$ es un estimador insesgado de μ, para **cualquier** distribución poblacional con media finita.

Ejemplo clave: por qué se divide por $n-1$

Example

Se puede probar que, si $X_1, \ldots, X_n$ es m.a. de una población con varianza σ^2,

$$E\left[\sum_{i=1}^{n}(X_i - \overline{X})^2\right] = (n-1)\sigma^2.$$

En consecuencia:

$$E(S^2) = E\left(\frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2\right) = \sigma^2 \quad \Rightarrow \quad S^2 \text{ es insesgado.}$$

Ejemplo clave: por qué se divide por $n-1$ (cont.)

Example

En cambio, el estimador "intuitivo" $\widehat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2$ cumple

$$E(\widehat{\sigma}^2) = \frac{n-1}{n}\sigma^2 \neq \sigma^2,$$

es decir, $\widehat{\sigma}^2$ es **sesgado** (subestima a σ^2), con sesgo $B(\widehat{\sigma}^2) = -\frac{\sigma^2}{n}$.

Deducción del sesgo de $\widehat{\sigma}^2$

Idea de la deducción.

Partimos de la identidad

$$\sum_{i=1}^{n}(X_i-\mu)^2=\sum_{i=1}^{n}(X_i-\overline{X})^2+n(\overline{X}-\mu)^2.$$

Tomando esperanza en ambos lados:

$$n\sigma^2=E\left[\sum_{i=1}^{n}(X_i-\overline{X})^2\right]+n\,\mathrm{Var}(\overline{X})=E\left[\sum(X_i-\overline{X})^2\right]+n\cdot\frac{\sigma^2}{n}.$$

Despejando:

$$E\left[\sum_{i=1}^{n}(X_i-\overline{X})^2\right]=n\sigma^2-\sigma^2=(n-1)\sigma^2.$$

□

Deducción del sesgo de $\widehat{\sigma}^2$ (cont.)

Conclusión práctica

Este es el motivo estadístico por el cual la **cuasivarianza muestral** S^2 (con $n-1$ en el denominador) es la que se usa habitualmente como estimador de σ^2.

Error cuadrático medio (ECM)

Definition (ECM)

El **error cuadrático medio** de un estimador $\widehat{\theta}$ de θ es

$$\mathrm{ECM}(\widehat{\theta}) = E\left[(\widehat{\theta} - \theta)^2\right].$$

Theorem (Descomposición del ECM)

$$\mathrm{ECM}(\widehat{\theta}) = \mathrm{Var}(\widehat{\theta}) + \left[B(\widehat{\theta})\right]^2,$$

donde $B(\widehat{\theta}) = E(\widehat{\theta}) - \theta$ *es el sesgo.*

Error cuadrático medio (ECM) (cont.)

Proof.

$$
\begin{aligned}
E[(\widehat{\theta}-\theta)^2] &= E\left[\left(\widehat{\theta}-E(\widehat{\theta})+E(\widehat{\theta})-\theta\right)^2\right] \\
&= E\left[(\widehat{\theta}-E(\widehat{\theta}))^2\right] + 2\underbrace{E[\widehat{\theta}-E(\widehat{\theta})]}_{=0}\cdot B(\widehat{\theta}) + B(\widehat{\theta})^2 \\
&= \mathrm{Var}(\widehat{\theta}) + B(\widehat{\theta})^2.
\end{aligned}
$$

□

Por qué importa el ECM

El ECM combina precisión y exactitud

- Si $\widehat{\theta}$ es insesgado, $\mathrm{ECM}(\widehat{\theta}) = \mathrm{Var}(\widehat{\theta})$: comparar estimadores insesgados equivale a comparar varianzas.
- Un estimador **sesgado** puede tener menor ECM que uno insesgado, si a cambio tiene mucha menor varianza. El ECM permite comparar estimadores aunque no todos sean insesgados.

Por qué importa el ECM (cont.)

Example

Comparemos $\widehat{\sigma}^2 = \frac{1}{n}\sum(X_i - \overline{X})^2$ (sesgado) con S^2 (insesgado) para estimar σ^2 en una población normal. Se puede probar que

$$\mathrm{Var}(S^2) = \frac{2\sigma^4}{n-1}, \qquad \mathrm{ECM}(\widehat{\sigma}^2) = \frac{2n-1}{n^2}\sigma^4 < \frac{2\sigma^4}{n-1} = \mathrm{ECM}(S^2).$$

Sorprendentemente, ¡el estimador sesgado $\widehat{\sigma}^2$ tiene menor ECM! Aun así, en la práctica se prefiere S^2 por su insesgadez y por simplicidad interpretativa.

Eficiencia relativa y estimador de mínima varianza

Definition (Eficiencia relativa)

Dados dos estimadores insesgados $\widehat{\theta}_1$, $\widehat{\theta}_2$ de θ, la **eficiencia relativa** de $\widehat{\theta}_1$ respecto de $\widehat{\theta}_2$ es

$$\mathrm{ER}(\widehat{\theta}_1, \widehat{\theta}_2) = \frac{\mathrm{Var}(\widehat{\theta}_2)}{\mathrm{Var}(\widehat{\theta}_1)}.$$

Si $\mathrm{ER} > 1$, $\widehat{\theta}_1$ es **más eficiente** (tiene menor varianza).

Definition (Estimador insesgado de mínima varianza, EIMV/UMVUE)

$\widehat{\theta}^*$ es **EIMV** de θ si es insesgado y $\mathrm{Var}(\widehat{\theta}^*) \leq \mathrm{Var}(\widehat{\theta})$ para **todo** otro estimador insesgado $\widehat{\theta}$ de θ.

Eficiencia relativa y estimador de mínima varianza (cont.)

Cota de Cramér–Rao (mención)

Bajo condiciones de regularidad, toda varianza de un estimador insesgado satisface $\mathrm{Var}(\widehat{\theta}) \geq \dfrac{1}{n\, I(\theta)}$, donde $I(\theta)$ es la información de Fisher. Un estimador que alcanza esta cota es EIMV.

Ejemplo: $\overline{X}$ vs. mediana muestral

Example

Sea $X_1, \ldots, X_n$ m.a. de una población $N(\mu, \sigma^2)$, n impar. Se puede probar (resultado avanzado) que la mediana muestral $\widetilde{X}$ es también insesgada para μ, con

$$\mathrm{Var}(\overline{X}) = \frac{\sigma^2}{n}, \qquad \mathrm{Var}(\widetilde{X}) \approx \frac{\pi}{2} \cdot \frac{\sigma^2}{n} \approx 1.57 \cdot \frac{\sigma^2}{n}.$$

Como $\mathrm{Var}(\overline{X}) < \mathrm{Var}(\widetilde{X})$, la eficiencia relativa de $\overline{X}$ respecto de $\widetilde{X}$ es

$$\mathrm{ER}(\overline{X}, \widetilde{X}) = \frac{\mathrm{Var}(\widetilde{X})}{\mathrm{Var}(\overline{X})} \approx 1.57 > 1.$$

Conclusión: en poblaciones normales, $\overline{X}$ es más eficiente que $\widetilde{X}$ para estimar μ (aproximadamente un 57% más eficiente).

Consistencia

Definition (Estimador consistente)

Una sucesión de estimadores $\widehat{\theta}_n$ (uno para cada tamaño muestral n) es **consistente** para θ si converge en probabilidad a θ:

$$\widehat{\theta}_n \xrightarrow{P} \theta, \qquad \text{es decir,} \qquad \lim_{n\to\infty} P\left(|\widehat{\theta}_n - \theta| > \varepsilon\right) = 0 \quad \forall \varepsilon > 0.$$

Theorem (Criterio suficiente de consistencia)

Si $\lim_{n\to\infty} \mathrm{ECM}(\widehat{\theta}_n) = 0$, *entonces* $\widehat{\theta}_n$ *es consistente. En particular, si* $\widehat{\theta}_n$ *es insesgado y* $\lim_{n\to\infty} \mathrm{Var}(\widehat{\theta}_n) = 0$, *entonces es consistente.*

Idea (desigualdad de Chebyshev).

$$P(|\widehat{\theta}_n - \theta| > \varepsilon) \leq \frac{E[(\widehat{\theta}_n - \theta)^2]}{\varepsilon^2} = \frac{\mathrm{ECM}(\widehat{\theta}_n)}{\varepsilon^2} \xrightarrow[n\to\infty]{} 0.$$

□

Ejemplo: consistencia de $\overline{X}$ y S^2

Example

Sea $X_1, \ldots, X_n$ m.a. con $E(X_i) = \mu$, $\mathrm{Var}(X_i) = \sigma^2 < \infty$.

- $\overline{X}$ es insesgado y $\mathrm{Var}(\overline{X}) = \sigma^2/n \to 0$ cuando $n \to \infty$. Luego $\overline{X}$ es consistente para μ (esto también es consecuencia directa de la Ley de los Grandes Números).
- S^2 es insesgado y se puede probar que $\mathrm{Var}(S^2) \to 0$ cuando $n \to \infty$ (bajo momentos finitos adecuados). Luego S^2 es consistente para σ^2.

Importante

Insesgadez y consistencia son propiedades **distintas**: un estimador puede ser sesgado para todo n finito pero consistente (el sesgo desaparece asintóticamente). Ejemplo: $\widehat{\sigma}^2 = \frac{n-1}{n} S^2$ es sesgado pero consistente, pues $\frac{n-1}{n} \to 1$.

Ejemplo integrador numérico

Example

Un ingeniero mide el diámetro (en mm) de $n = 5$ piezas: 10.2, 9.8, 10.1, 9.9, 10.0.

$$\overline{x} = \frac{10.2 + 9.8 + 10.1 + 9.9 + 10.0}{5} = \frac{50.0}{5} = 10.0$$

$$\widetilde{x} = 10.0 \quad \text{(mediana: valor central al ordenar los datos)}$$

$$s^2 = \frac{1}{4}\left[(0.2)^2 + (-0.2)^2 + (0.1)^2 + (-0.1)^2 + 0^2\right] = \frac{0.10}{4} = 0.025$$

$$\widehat{\sigma}^2 = \frac{4}{5}s^2 = \frac{4}{5}(0.025) = 0.02$$

Aquí $\overline{x} = \widetilde{x} = 10.0$ mm son las estimaciones puntuales de μ; $s^2 = 0.025$ mm^2 es la estimación insesgada de σ^2.

Resumen

Propiedades deseables de un estimador $\widehat{\theta}$

- **Insesgadez:** $E(\widehat{\theta}) = \theta$ (sesgo nulo).
- **ECM:** $\mathrm{ECM}(\widehat{\theta}) = \mathrm{Var}(\widehat{\theta}) + B(\widehat{\theta})^2$; mide error total (precisión + exactitud).
- **Eficiencia:** entre estimadores insesgados, preferimos el de menor varianza (EIMV = mínima varianza posible).
- **Consistencia:** $\widehat{\theta}_n \xrightarrow{P} \theta$ cuando $n \to \infty$; garantiza que, con muestras grandes, el estimador se acerca al parámetro.

Próxima clase

¿Cómo **construir** estimadores con buenas propiedades? Método de mínimos cuadrados y método de máxima verosimilitud.