

Clase 21: Estimación Puntual

Unidad 6: Estimación de parámetros

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

- 1 Introducción a la estimación
- 2 Insesgadez
- 3 Error cuadrático medio
- 4 Eficiencia
- 5 Consistencia
- 6 Ejemplo integrador
- 7 Resumen

De la probabilidad a la inferencia

Problema general de la Estadística Inferencial

Tenemos una población descrita por una variable aleatoria X cuya distribución depende de uno o más **parámetros desconocidos** θ (por ejemplo, μ , σ^2 , p , λ). A partir de una **muestra aleatoria** $X_1, X_2, \dots, X_n$ extraída de esa población, queremos decir algo razonable acerca de θ .

Idea central

Un **estimador** es una función de la muestra —es decir, un **estadístico**— que usamos para aproximar el valor del parámetro desconocido.

- Ya vimos (Unidad 5) qué es una muestra aleatoria y algunos estadísticos: $\bar{X}$, S^2 , etc.
- Ahora estudiamos: *¿qué hace bueno a un estimador?* y *¿cómo construirlo?*

Definiciones básicas

Definition (Estimador puntual)

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población con distribución que depende de un parámetro $\theta \in \Theta$. Un **estimador puntual** de θ es un estadístico

$$\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$$

es decir, una función de la muestra que no depende de θ .

Definition (Estimación)

Si $x_1, \dots, x_n$ son los valores observados (los datos concretos), el número $\hat{\theta}(x_1, \dots, x_n)$ se llama **estimación puntual** de θ .

Observación clave

$\hat{\theta}$ es una variable aleatoria (depende de la muestra, que es aleatoria); por lo tanto tiene su propia distribución, llamada **distribución muestral del estimador**, con su media, varianza, etc.

Ejemplos de estimadores usuales

Sea $X_1, \dots, X_n$ m.a. de una población con media μ y varianza σ^2 .

- Estimadores de μ : la media muestral $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, o la mediana muestral $\tilde{X}$.
- Estimadores de σ^2 : la cuasivarianza muestral $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, o la varianza muestral $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$.
- Estimador de una proporción p : $\hat{p} = \frac{Y}{n}$, donde $Y \sim \text{Bi}(n, p)$ cuenta éxitos.

Pregunta natural

Para un mismo parámetro hay *varios* estimadores posibles ($\bar{X}$ vs. $\tilde{X}$; S^2 vs. $\hat{\sigma}^2$). ¿Cuál conviene usar? Necesitamos **criterios de comparación**.

Definition (Estimador insesgado)

$\hat{\theta}$ es un **estimador insesgado** (o *centrado*) de θ si

$$E(\hat{\theta}) = \theta \quad \text{para todo } \theta \in \Theta.$$

El **sesgo** de $\hat{\theta}$ se define como

$$B(\hat{\theta}) = E(\hat{\theta}) - \theta.$$

Si $B(\hat{\theta}) \neq 0$, el estimador es **sesgado**.

Interpretación

En promedio, sobre infinitas repeticiones del muestreo, un estimador insesgado no sobreestima ni subestima sistemáticamente al parámetro.

Ejemplo: $\bar{X}$ es insesgado para μ

Example

Sea $X_1, \dots, X_n$ m.a. de una población con $E(X_i) = \mu$. Entonces

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} \cdot n\mu = \mu.$$

Por lo tanto $\bar{X}$ es un estimador insesgado de μ , para **cualquier** distribución poblacional con media finita.

Ejemplo clave: por qué se divide por $n - 1$

Example

Se puede probar que, si $X_1, \dots, X_n$ es m.a. de una población con varianza σ^2 ,

$$E \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right] = (n - 1)\sigma^2.$$

En consecuencia:

$$E(S^2) = E \left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \right) = \sigma^2 \quad \Rightarrow \quad S^2 \text{ es insesgado.}$$

En cambio, el estimador "intuitivo" $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ cumple

$$E(\hat{\sigma}^2) = \frac{n-1}{n} \sigma^2 \neq \sigma^2,$$

Deducción del sesgo de $\hat{\sigma}^2$

Idea de la deducción.

Partimos de la identidad

$$\sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu)^2.$$

Tomando esperanza en ambos lados:

$$n\sigma^2 = E \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right] + n \operatorname{Var}(\bar{X}) = E \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right] + n \cdot \frac{\sigma^2}{n}.$$

Despejando:

$$E \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right] = n\sigma^2 - \sigma^2 = (n-1)\sigma^2.$$



Error cuadrático medio (ECM)

Definition (ECM)

El **error cuadrático medio** de un estimador $\hat{\theta}$ de θ es

$$\text{ECM}(\hat{\theta}) = E \left[(\hat{\theta} - \theta)^2 \right].$$

Theorem (Descomposición del ECM)

$$\text{ECM}(\hat{\theta}) = \text{Var}(\hat{\theta}) + \left[B(\hat{\theta}) \right]^2,$$

donde $B(\hat{\theta}) = E(\hat{\theta}) - \theta$ es el sesgo.

Demostración.

$$E[(\hat{\theta} - \theta)^2] = E \left[\left(\hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta \right)^2 \right]$$

Por qué importa el ECM

El ECM combina precisión y exactitud

- Si $\hat{\theta}$ es insesgado, $\text{ECM}(\hat{\theta}) = \text{Var}(\hat{\theta})$: comparar estimadores insesgados equivale a comparar varianzas.
- Un estimador **sesgado** puede tener menor ECM que uno insesgado, si a cambio tiene mucha menor varianza. El ECM permite comparar estimadores aunque no todos sean insesgados.

Example

Comparemos $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ (sesgado) con S^2 (insesgado) para estimar σ^2 en una población normal. Se puede probar que

$$\text{Var}(S^2) = \frac{2\sigma^4}{n-1}, \quad \text{ECM}(\hat{\sigma}^2) = \frac{2n-1}{n^2} \sigma^4 < \frac{2\sigma^4}{n-1} = \text{ECM}(S^2).$$

Sorprendentemente, ¡el estimador sesgado $\hat{\sigma}^2$ tiene menor ECM! Aun así, en la práctica se prefiere S^2 por su insesgadez y por simplicidad interpretativa.

Eficiencia relativa y estimador de mínima varianza

Definition (Eficiencia relativa)

Dados dos estimadores insesgados $\hat{\theta}_1, \hat{\theta}_2$ de θ , la **eficiencia relativa** de $\hat{\theta}_1$ respecto de $\hat{\theta}_2$ es

$$ER(\hat{\theta}_1, \hat{\theta}_2) = \frac{\text{Var}(\hat{\theta}_2)}{\text{Var}(\hat{\theta}_1)}.$$

Si $ER > 1$, $\hat{\theta}_1$ es **más eficiente** (tiene menor varianza).

Definition (Estimador insesgado de mínima varianza, EIMV/UMVUE)

$\hat{\theta}^*$ es **EIMV** de θ si es insesgado y $\text{Var}(\hat{\theta}^*) \leq \text{Var}(\hat{\theta})$ para **todo** otro estimador insesgado $\hat{\theta}$ de θ .

Cota de Cramér–Rao (mención)

Bajo condiciones de regularidad, toda varianza de un estimador insesgado satisface

$\text{Var}(\hat{\theta}) \geq \frac{1}{I(\theta)}$ donde $I(\theta)$ es la información de Fisher. Un estimador que alcanza esta cota es

Ejemplo: $\bar{X}$ vs. mediana muestral

Example

Sea $X_1, \dots, X_n$ m.a. de una población $N(\mu, \sigma^2)$, n impar. Se puede probar (resultado avanzado) que la mediana muestral $\tilde{X}$ es también insesgada para μ , con

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}, \quad \text{Var}(\tilde{X}) \approx \frac{\pi}{2} \cdot \frac{\sigma^2}{n} \approx 1.57 \cdot \frac{\sigma^2}{n}.$$

Como $\text{Var}(\bar{X}) < \text{Var}(\tilde{X})$, la eficiencia relativa de $\bar{X}$ respecto de $\tilde{X}$ es

$$\text{ER}(\bar{X}, \tilde{X}) = \frac{\text{Var}(\tilde{X})}{\text{Var}(\bar{X})} \approx 1.57 > 1.$$

Conclusión: en poblaciones normales, $\bar{X}$ es más eficiente que $\tilde{X}$ para estimar μ (aproximadamente un 57 % más eficiente).

Consistencia

Definition (Estimador consistente)

Una sucesión de estimadores $\hat{\theta}_n$ (uno para cada tamaño muestral n) es **consistente** para θ si converge en probabilidad a θ :

$$\hat{\theta}_n \xrightarrow{P} \theta, \quad \text{es decir,} \quad \lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) = 0 \quad \forall \varepsilon > 0.$$

Theorem (Criterio suficiente de consistencia)

Si $\lim_{n \rightarrow \infty} \text{ECM}(\hat{\theta}_n) = 0$, entonces $\hat{\theta}_n$ es consistente. En particular, si $\hat{\theta}_n$ es insesgado y $\lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0$, entonces es consistente.

Idea (desigualdad de Chebyshev).

$$P(|\hat{\theta}_n - \theta| > \varepsilon) \leq \frac{E[(\hat{\theta}_n - \theta)^2]}{\varepsilon^2} = \frac{\text{ECM}(\hat{\theta}_n)}{\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$



Ejemplo: consistencia de $\bar{X}$ y S^2

Example

Sea $X_1, \dots, X_n$ m.a. con $E(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2 < \infty$.

- $\bar{X}$ es insesgado y $\text{Var}(\bar{X}) = \sigma^2/n \rightarrow 0$ cuando $n \rightarrow \infty$. Luego $\bar{X}$ es consistente para μ (esto también es consecuencia directa de la Ley de los Grandes Números).
- S^2 es insesgado y se puede probar que $\text{Var}(S^2) \rightarrow 0$ cuando $n \rightarrow \infty$ (bajo momentos finitos adecuados). Luego S^2 es consistente para σ^2 .

Importante

Insesgadez y consistencia son propiedades **distintas**: un estimador puede ser sesgado para todo n finito pero consistente (el sesgo desaparece asintóticamente). Ejemplo: $\hat{\sigma}^2 = \frac{n-1}{n} S^2$ es sesgado pero consistente, pues $\frac{n-1}{n} \rightarrow 1$.

Ejemplo integrador numérico

Example

Un ingeniero mide el diámetro (en mm) de $n = 5$ piezas: 10.2, 9.8, 10.1, 9.9, 10.0.

$$\bar{x} = \frac{10.2 + 9.8 + 10.1 + 9.9 + 10.0}{5} = \frac{50.0}{5} = 10.0$$

$$\tilde{x} = 10.0 \quad (\text{mediana: valor central al ordenar los datos})$$

$$s^2 = \frac{1}{4} [(0.2)^2 + (-0.2)^2 + (0.1)^2 + (-0.1)^2 + 0^2] = \frac{0.10}{4} = 0.025$$

$$\hat{\sigma}^2 = \frac{4}{5}s^2 = \frac{4}{5}(0.025) = 0.02$$

Aquí $\bar{x} = \tilde{x} = 10.0$ mm son las estimaciones puntuales de μ ; $s^2 = 0.025$ mm² es la estimación insesgada de σ^2 .

Propiedades deseables de un estimador $\hat{\theta}$

- **Insesgadez:** $E(\hat{\theta}) = \theta$ (sesgo nulo).
- **ECM:** $ECM(\hat{\theta}) = \text{Var}(\hat{\theta}) + B(\hat{\theta})^2$; mide error total (precisión + exactitud).
- **Eficiencia:** entre estimadores insesgados, preferimos el de menor varianza (EIMV = mínima varianza posible).
- **Consistencia:** $\hat{\theta}_n \xrightarrow{P} \theta$ cuando $n \rightarrow \infty$; garantiza que, con muestras grandes, el estimador se acerca al parámetro.

Próxima clase

¿Cómo **construir** estimadores con buenas propiedades? Método de mínimos cuadrados y método de máxima verosimilitud.