Clase 22: Métodos de Estimación

Unidad 6: Estimación de parámetros

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

1. Método de mínimos cuadrados
2. Función de verosimilitud
3. EMV en distribuciones discretas
4. EMV en distribuciones continuas
5. Propiedades del EMV
6. Ejemplo numérico integrador
7. Resumen

Idea general del método de mínimos cuadrados

Motivación

Dado un conjunto de observaciones $x_1, \ldots, x_n$ que en teoría deberían ajustarse a un modelo con parámetro(s) θ, el **método de mínimos cuadrados (MC)** elige como estimador el valor $\widehat{\theta}$ que **minimiza la suma de los cuadrados de los errores** entre los datos observados y los valores predichos por el modelo.

Definition (Estimador de mínimos cuadrados)

Si el modelo predice $E(X_i) = g(\theta)$, el estimador de MC de θ es el que minimiza

$$Q(\theta) = \sum_{i=1}^{n} (x_i - g(\theta))^2 .$$

Idea general del método de mínimos cuadrados (cont.)

Uso típico

Es la base de la **regresión lineal** (Unidad 8): allí g depende de variables explicativas y se minimiza la suma de residuos al cuadrado. Aquí lo presentamos en su versión más simple, para fijar la idea.

Ejemplo: mínimos cuadrados para estimar μ

Example

Sea $X_1, \ldots, X_n$ m.a. con $E(X_i) = \mu$ (modelo $g(\mu) = \mu$ constante). Buscamos $\widehat{\mu}$ que minimice

$$Q(\mu) = \sum_{i=1}^{n} (x_i - \mu)^2.$$

Derivando e igualando a cero:

$$Q'(\mu) = -2 \sum_{i=1}^{n} (x_i - \mu) = 0 \implies \sum_{i=1}^{n} x_i = n\mu \implies \widehat{\mu} = \frac{1}{n} \sum_{i=1}^{n} x_i = \overline{x}.$$

Como $Q''(\mu) = 2n > 0$, es efectivamente un mínimo. **Conclusión:** el estimador de mínimos cuadrados de μ coincide con la media muestral $\overline{X}$.

Motivación del método de máxima verosimilitud

Pregunta central

Dada una muestra observada $x_1, \ldots, x_n$, ¿qué valor de θ hace que **sea más "verosímil" (plausible)** haber observado exactamente esos datos?

Definition (Función de verosimilitud)

Sea $X_1, \ldots, X_n$ m.a. de una población con función de probabilidad/densidad $f(x; \theta)$. La **función de verosimilitud** es

$$L(\theta) = L(\theta \mid x_1, \ldots, x_n) = \prod_{i=1}^{n} f(x_i; \theta),$$

vista como función de θ (los datos $x_1, \ldots, x_n$ están fijos, son los observados).

Motivación del método de máxima verosimilitud (cont.)

Diferencia clave con la densidad conjunta

$f(x_1, \ldots, x_n; \theta)$ es función de los datos, con θ fijo. $L(\theta)$ es la *misma expresión* pero pensada como función de θ, con los datos fijos.

Estimador de máxima verosimilitud (EMV)

Definition (EMV)

El **estimador de máxima verosimilitud** de θ es el valor $\widehat{\theta}$ que maximiza $L(\theta)$:

$$\widehat{\theta}_{EMV} = \arg\max_{\theta \in \Theta} L(\theta).$$

Estimador de máxima verosimilitud (EMV) (cont.)

Log-verosimilitud

Como log es una función estrictamente creciente, maximizar $L(\theta)$ equivale a maximizar

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^{n} \ln f(x_i; \theta),$$

que en general es mucho más fácil de derivar (transforma productos en sumas).

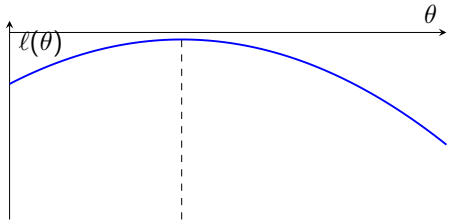
Receta general

1) Escribir $L(\theta)$. 2) Tomar $\ell(\theta) = \ln L(\theta)$. 3) Resolver $\frac{d\ell}{d\theta} = 0$. 4) Verificar que es máximo ($\ell'' < 0$).

Interpretación gráfica de la verosimilitud

¿Qué significa "maximizar" $L(\theta)$?

Para cada valor posible de θ, $L(\theta)$ mide qué tan "compatible" es ese valor con los datos observados. El EMV es el punto más alto de esa curva.



Condición de máximo

En el máximo, $\ell'(\widehat{\theta}) = 0$ y $\ell''(\widehat{\theta}) < 0$ (concavidad hacia abajo).

EMV para la distribución Bernoulli

Example

Sea $X_1, \ldots, X_n$ m.a. de $X \sim \text{Be}(p)$, con $f(x; p) = p^x(1-p)^{1-x}$, $x \in \{0, 1\}$.

$$L(p) = \prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i} = p^{\sum x_i}(1-p)^{n-\sum x_i}.$$

Sea $t = \sum_{i=1}^{n} x_i$ (cantidad de éxitos). Entonces

$$\ell(p) = t \ln p + (n-t)\ln(1-p).$$

EMV para la distribución Bernoulli (cont.)

Example

Derivando:

$$\ell'(p) = \frac{t}{p} - \frac{n-t}{1-p} = 0 \implies t(1-p) = (n-t)p \implies t = np \implies \widehat{p} = \frac{t}{n} = \overline{x}.$$

Como $\ell''(p) = -t/p^2 - (n-t)/(1-p)^2 < 0$, es máximo. **El EMV de p es la proporción muestral $\widehat{p} = \overline{X}$.**

EMV para la distribución de Poisson

Example

Sea $X_1, \ldots, X_n$ m.a. de $X \sim \text{Poisson}(\lambda)$, $f(x;\lambda) = \dfrac{e^{-\lambda}\lambda^x}{x!}$.

$$L(\lambda) = \prod_{i=1}^{n} \frac{e^{-\lambda}\lambda^{x_i}}{x_i!} = \frac{e^{-n\lambda}\lambda^{\sum x_i}}{\prod x_i!}.$$

$$\ell(\lambda) = -n\lambda + \left(\sum_{i=1}^{n} x_i\right) \ln\lambda - \ln\left(\prod x_i!\right).$$

$$\ell'(\lambda) = -n + \frac{\sum x_i}{\lambda} = 0 \implies \widehat{\lambda} = \frac{1}{n}\sum_{i=1}^{n} x_i = \overline{x}.$$

Como $\ell''(\lambda) = -\sum x_i/\lambda^2 < 0$ (si algún $x_i > 0$), es máximo. **El EMV de λ es $\overline{X}$.**

EMV para la distribución exponencial

Example

Sea $X_1, \ldots, X_n$ m.a. de $X \sim \text{Exp}(\lambda)$, $f(x;\lambda) = \lambda e^{-\lambda x}$, $x > 0$.

$$L(\lambda) = \prod_{i=1}^{n} \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum x_i}.$$

$$\ell(\lambda) = n \ln \lambda - \lambda \sum_{i=1}^{n} x_i.$$

$$\ell'(\lambda) = \frac{n}{\lambda} - \sum_{i=1}^{n} x_i = 0 \implies \widehat{\lambda} = \frac{n}{\sum_{i=1}^{n} x_i} = \frac{1}{\overline{x}}.$$

Como $\ell''(\lambda) = -n/\lambda^2 < 0$, es máximo. **El EMV de λ es $1/\overline{X}$** (nótese: $\widehat{\lambda}$ es sesgado, aunque consistente, ya que $E(1/\overline{X}) \neq 1/E(\overline{X})$ en general).

EMV para la distribución normal (deducción completa)

Example

Sea $X_1, \ldots, X_n$ m.a. de $X \sim N(\mu, \sigma^2)$, ambos parámetros desconocidos.

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

$$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2\right).$$

$$\ell(\mu, \sigma^2) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2.$$

EMV para la normal: resolución del sistema

Derivando respecto de μ e igualando a cero:

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i - \mu) = 0 \implies \widehat{\mu} = \frac{1}{n}\sum_{i=1}^{n} x_i = \overline{x}.$$

Derivando respecto de σ^2 (tratándolo como una única variable) e igualando a cero:

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\sum_{i=1}^{n}(x_i - \mu)^2 = 0$$

$$\implies \widehat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \widehat{\mu})^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})^2.$$

Observación importante

El EMV de σ^2 es $\widehat{\sigma}^2$ (con n, **no** $n-1$): coincide con el estimador **sesgado** de la Clase 21, no con S^2. El EMV no siempre es insesgado.

Propiedades del estimador de máxima verosimilitud

Propiedad de invarianza

Si $\widehat{\theta}$ es el EMV de θ y g es una función biunívoca (inyectiva), entonces $g(\widehat{\theta})$ es el EMV de $g(\theta)$.

Example

Como el EMV de σ^2 es $\widehat{\sigma}^2 = \frac{1}{n}\sum(x_i - \overline{x})^2$, por invarianza el EMV del desvío estándar σ es

$$\widehat{\sigma} = \sqrt{\widehat{\sigma}^2} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})^2}.$$

Propiedades del estimador de máxima verosimilitud (cont.)

Propiedades asintóticas (bajo condiciones de regularidad)

- **Consistencia:** $\widehat{\theta}_{EMV} \xrightarrow{P} \theta$ cuando $n \to \infty$.
- **Eficiencia asintótica:** su varianza se aproxima a la cota de Cramér–Rao para n grande.
- **Normalidad asintótica:** $\widehat{\theta}_{EMV}$ tiene distribución aproximadamente normal para n grande.

Comparación: mínimos cuadrados vs. máxima verosimilitud

Similitudes y diferencias

- Ambos métodos son **criterios de optimización**: eligen el parámetro que "mejor explica" los datos, según un objetivo distinto.
- MC minimiza distancias al cuadrado; no requiere especificar toda la distribución, solo la forma de la media.
- EMV maximiza la probabilidad (o densidad) de observar los datos; requiere conocer la distribución completa.
- Para el modelo normal con media constante, ambos métodos coinciden: $\widehat{\mu}_{MC} = \widehat{\mu}_{EMV} = \overline{X}$.

En la práctica

El EMV es el método más usado en Estadística por sus buenas propiedades asintóticas (consistencia, eficiencia, normalidad); MC es central en regresión lineal (Unidad 8).

Ejemplo numérico: EMV con datos concretos

Example

Se registra el número de llamados que recibe un call center por minuto, durante $n = 8$ minutos, asumiendo $X \sim \text{Poisson}(\lambda)$:

$$3,\ 5,\ 2,\ 4,\ 3,\ 6,\ 4,\ 5.$$

Sabemos que el EMV de λ en Poisson es $\widehat{\lambda} = \overline{x}$. Calculamos:

$$\sum_{i=1}^{8} x_i = 3+5+2+4+3+6+4+5 = 32, \qquad \widehat{\lambda} = \overline{x} = \frac{32}{8} = 4.$$

Estimación de máxima verosimilitud: $\widehat{\lambda} = 4$ llamados por minuto.
Si además nos interesara $g(\lambda) = P(X = 0) = e^{-\lambda}$ (probabilidad de no recibir llamados en un minuto), por invarianza:

$$\widehat{g} = e^{-\widehat{\lambda}} = e^{-4} \approx 0.0183.$$

Resumen

Método de mínimos cuadrados

Minimiza $\sum(x_i - g(\theta))^2$. Para el modelo de media constante, coincide con $\overline{X}$.

Método de máxima verosimilitud

Maximiza $L(\theta) = \prod f(x_i; \theta)$, o equivalentemente $\ell(\theta) = \ln L(\theta)$.

Distribución	Parámetro	EMV
Bernoulli(p)	p	$\widehat{p} = \overline{X}$
Poisson(λ)	λ	$\widehat{\lambda} = \overline{X}$
Exponencial(λ)	λ	$\widehat{\lambda} = 1/\overline{X}$
Normal(μ, σ^2)	μ	$\widehat{\mu} = \overline{X}$
Normal(μ, σ^2)	σ^2	$\widehat{\sigma}^2 = \frac{1}{n}\sum(X_i - \overline{X})^2$

Resumen (cont.)

Próxima clase

Usaremos estos estimadores puntuales como base para construir **intervalos de confianza**: en vez de dar un único valor, daremos un rango de valores plausibles para θ.