

Clase 22: Métodos de Estimación

Unidad 6: Estimación de parámetros

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

- 1 Método de mínimos cuadrados
- 2 Función de verosimilitud
- 3 EMV en distribuciones discretas
- 4 EMV en distribuciones continuas
- 5 Propiedades del EMV
- 6 Ejemplo numérico integrador
- 7 Resumen

Idea general del método de mínimos cuadrados

Motivación

Dado un conjunto de observaciones $x_1, \dots, x_n$ que en teoría deberían ajustarse a un modelo con parámetro(s) θ , el **método de mínimos cuadrados (MC)** elige como estimador el valor $\hat{\theta}$ que **minimiza la suma de los cuadrados de los errores** entre los datos observados y los valores predichos por el modelo.

Definition (Estimador de mínimos cuadrados)

Si el modelo predice $E(X_i) = g(\theta)$, el estimador de MC de θ es el que minimiza

$$Q(\theta) = \sum_{i=1}^n (x_i - g(\theta))^2.$$

Uso típico

Es la base de la **regresión lineal** (Unidad 8): allí g depende de variables explicativas y se minimiza la suma de residuos al cuadrado. Aquí lo presentamos en su versión más simple, para

Ejemplo: mínimos cuadrados para estimar μ

Example

Sea $X_1, \dots, X_n$ m.a. con $E(X_i) = \mu$ (modelo $g(\mu) = \mu$ constante). Buscamos $\hat{\mu}$ que minimice

$$Q(\mu) = \sum_{i=1}^n (x_i - \mu)^2.$$

Derivando e igualando a cero:

$$Q'(\mu) = -2 \sum_{i=1}^n (x_i - \mu) = 0 \implies \sum_{i=1}^n x_i = n\mu \implies \hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

Como $Q''(\mu) = 2n > 0$, es efectivamente un mínimo. **Conclusión:** el estimador de mínimos cuadrados de μ coincide con la media muestral $\bar{X}$.

Motivación del método de máxima verosimilitud

Pregunta central

Dada una muestra observada $x_1, \dots, x_n$, ¿qué valor de θ hace que sea más "verosímil" (plausible) haber observado exactamente esos datos?

Definition (Función de verosimilitud)

Sea $X_1, \dots, X_n$ m.a. de una población con función de probabilidad/densidad $f(x; \theta)$. La **función de verosimilitud** es

$$L(\theta) = L(\theta \mid x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta),$$

vista como función de θ (los datos $x_1, \dots, x_n$ están fijos, son los observados).

Diferencia clave con la densidad conjunta

$f(x_1, \dots, x_n; \theta)$ es función de los datos, con θ fijo. $L(\theta)$ es la *misma expresión* pero pensada

Estimador de máxima verosimilitud (EMV)

Definition (EMV)

El **estimador de máxima verosimilitud** de θ es el valor $\hat{\theta}$ que maximiza $L(\theta)$:

$$\hat{\theta}_{EMV} = \arg \max_{\theta \in \Theta} L(\theta).$$

Log-verosimilitud

Como log es una función estrictamente creciente, maximizar $L(\theta)$ equivale a maximizar

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta),$$

que en general es mucho más fácil de derivar (transforma productos en sumas).

Receta general

EMV para la distribución Bernoulli

Example

Sea $X_1, \dots, X_n$ m.a. de $X \sim \text{Be}(p)$, con $f(x; p) = p^x(1-p)^{1-x}$, $x \in \{0, 1\}$.

$$L(p) = \prod_{i=1}^n p^{x_i}(1-p)^{1-x_i} = p^{\sum x_i}(1-p)^{n-\sum x_i}.$$

Sea $t = \sum_{i=1}^n x_i$ (cantidad de éxitos). Entonces

$$\ell(p) = t \ln p + (n-t) \ln(1-p).$$

Derivando:

$$\ell'(p) = \frac{t}{p} - \frac{n-t}{1-p} = 0 \implies t(1-p) = (n-t)p \implies t = np \implies \hat{p} = \frac{t}{n} = \bar{x}.$$

Como $\ell''(p) = -t/p^2 - (n-t)/(1-p)^2 < 0$, es máximo. **El EMV de p es la proporción muestral $\hat{p} = \bar{X}$.**

EMV para la distribución de Poisson

Example

Sea $X_1, \dots, X_n$ m.a. de $X \sim \text{Poisson}(\lambda)$, $f(x; \lambda) = \frac{e^{-\lambda} \lambda^x}{x!}$.

$$L(\lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} = \frac{e^{-n\lambda} \lambda^{\sum x_i}}{\prod x_i!}.$$

$$\ell(\lambda) = -n\lambda + \left(\sum_{i=1}^n x_i \right) \ln \lambda - \ln \left(\prod x_i! \right).$$

$$\ell'(\lambda) = -n + \frac{\sum x_i}{\lambda} = 0 \implies \hat{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{X}.$$

Como $\ell''(\lambda) = -\sum x_i / \lambda^2 < 0$ (si algún $x_i > 0$), es máximo. **El EMV de λ es $\bar{X}$.**

EMV para la distribución exponencial

Example

Sea $X_1, \dots, X_n$ m.a. de $X \sim \text{Exp}(\lambda)$, $f(x; \lambda) = \lambda e^{-\lambda x}$, $x > 0$.

$$L(\lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum x_i}.$$

$$\ell(\lambda) = n \ln \lambda - \lambda \sum_{i=1}^n x_i.$$

$$\ell'(\lambda) = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0 \implies \hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{x}}.$$

Como $\ell''(\lambda) = -n/\lambda^2 < 0$, es máximo. **El EMV de λ es $1/\bar{X}$** (nótese: $\hat{\lambda}$ es sesgado, aunque consistente, ya que $E(1/\bar{X}) \neq 1/E(\bar{X})$ en general).

EMV para la distribución normal (deducción completa)

Example

Sea $X_1, \dots, X_n$ m.a. de $X \sim N(\mu, \sigma^2)$, ambos parámetros desconocidos.

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right).$$

$$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right).$$

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

EMV para la normal: resolución del sistema

Derivando respecto de μ e igualando a cero:

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \implies \hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

Derivando respecto de σ^2 (tratándolo como una única variable) e igualando a cero:

$$\begin{aligned} \frac{\partial \ell}{\partial \sigma^2} &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0 \\ \implies \hat{\sigma}^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2. \end{aligned}$$

Observación importante

El EMV de σ^2 es $\hat{\sigma}^2$ (con n , **no** $n - 1$): coincide con el estimador **sesgado** de la Clase 21, no con S^2 . El EMV no siempre es insesgado.

Propiedades del estimador de máxima verosimilitud

Propiedad de invarianza

Si $\hat{\theta}$ es el EMV de θ y g es una función biunívoca (inyectiva), entonces $g(\hat{\theta})$ es el EMV de $g(\theta)$.

Example

Como el EMV de σ^2 es $\hat{\sigma}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$, por invarianza el EMV del desvío estándar σ es

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

Propiedades asintóticas (bajo condiciones de regularidad)

- **Consistencia:** $\hat{\theta}_{EMV} \xrightarrow{P} \theta$ cuando $n \rightarrow \infty$.
- **Eficiencia asintótica:** su varianza se aproxima a la cota de Cramér–Rao para n grande.
- **Normalidad asintótica:** $\hat{\theta}_{EMV}$ tiene distribución aproximadamente normal para n grande.

Ejemplo numérico: EMV con datos concretos

Example

Se registra el número de llamados que recibe un call center por minuto, durante $n = 8$ minutos, asumiendo $X \sim \text{Poisson}(\lambda)$:

3, 5, 2, 4, 3, 6, 4, 5.

Sabemos que el EMV de λ en Poisson es $\hat{\lambda} = \bar{x}$. Calculamos:

$$\sum_{i=1}^8 x_i = 3 + 5 + 2 + 4 + 3 + 6 + 4 + 5 = 32, \quad \hat{\lambda} = \bar{x} = \frac{32}{8} = 4.$$

Estimación de máxima verosimilitud: $\hat{\lambda} = 4$ llamados por minuto.

Si además nos interesara $g(\lambda) = P(X = 0) = e^{-\lambda}$ (probabilidad de no recibir llamados en un minuto), por invarianza:

$$\hat{g} = e^{-\hat{\lambda}} = e^{-4} \approx 0.0183.$$

Resumen

Método de mínimos cuadrados

Minimiza $\sum (x_i - g(\theta))^2$. Para el modelo de media constante, coincide con $\bar{X}$.

Método de máxima verosimilitud

Maximiza $L(\theta) = \prod f(x_i; \theta)$, o equivalentemente $\ell(\theta) = \ln L(\theta)$.

Distribución	Parámetro	EMV
Bernoulli(p)	p	$\hat{p} = \bar{X}$
Poisson(λ)	λ	$\hat{\lambda} = \bar{X}$
Exponencial(λ)	λ	$\hat{\lambda} = 1/\bar{X}$
Normal(μ, σ^2)	μ	$\hat{\mu} = \bar{X}$
Normal(μ, σ^2)	σ^2	$\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$

Próxima clase

Usaremos estos estimadores puntuales como base para construir intervalos de confianza en