

# Clase 22: Métodos de Estimación

## Unidad 6: Estimación de parámetros

Probabilidad y Estadística (5765)

Universidad Nacional del Sur  
Departamento de Matemática

# Contenidos

- 1 Método de mínimos cuadrados
- 2 Función de verosimilitud
- 3 EMV en distribuciones discretas
- 4 EMV en distribuciones continuas
- 5 Propiedades del EMV
- 6 Ejemplo numérico integrador
- 7 Resumen

# Idea general del método de mínimos cuadrados

## Motivación

Dado un conjunto de observaciones  $x_1, \dots, x_n$  que en teoría deberían ajustarse a un modelo con parámetro(s)  $\theta$ , el **método de mínimos cuadrados (MC)** elige como estimador el valor  $\hat{\theta}$  que **minimiza la suma de los cuadrados de los errores** entre los datos observados y los valores predichos por el modelo.

## Definition (Estimador de mínimos cuadrados)

Si el modelo predice  $E(X_i) = g(\theta)$ , el estimador de MC de  $\theta$  es el que minimiza

$$Q(\theta) = \sum_{i=1}^n (x_i - g(\theta))^2.$$

## Uso típico

Es la base de la **regresión lineal** (Unidad 8): allí  $g$  depende de variables explicativas y se minimiza la suma de residuos al cuadrado. Aquí lo presentamos en su versión más simple, para

## Ejemplo: mínimos cuadrados para estimar $\mu$

### Example

Sea  $X_1, \dots, X_n$  m.a. con  $E(X_i) = \mu$  (modelo  $g(\mu) = \mu$  constante). Buscamos  $\hat{\mu}$  que minimice

$$Q(\mu) = \sum_{i=1}^n (x_i - \mu)^2.$$

Derivando e igualando a cero:

$$Q'(\mu) = -2 \sum_{i=1}^n (x_i - \mu) = 0 \implies \sum_{i=1}^n x_i = n\mu \implies \hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

Como  $Q''(\mu) = 2n > 0$ , es efectivamente un mínimo. **Conclusión:** el estimador de mínimos cuadrados de  $\mu$  coincide con la media muestral  $\bar{X}$ .

# Motivación del método de máxima verosimilitud

## Pregunta central

Dada una muestra observada  $x_1, \dots, x_n$ , ¿qué valor de  $\theta$  hace que sea más "verosímil" (plausible) haber observado exactamente esos datos?

## Definition (Función de verosimilitud)

Sea  $X_1, \dots, X_n$  m.a. de una población con función de probabilidad/densidad  $f(x; \theta)$ . La **función de verosimilitud** es

$$L(\theta) = L(\theta \mid x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta),$$

vista como función de  $\theta$  (los datos  $x_1, \dots, x_n$  están fijos, son los observados).

## Diferencia clave con la densidad conjunta

$f(x_1, \dots, x_n; \theta)$  es función de los datos, con  $\theta$  fijo.  $L(\theta)$  es la *misma expresión* pero pensada

# Estimador de máxima verosimilitud (EMV)

## Definition (EMV)

El **estimador de máxima verosimilitud** de  $\theta$  es el valor  $\hat{\theta}$  que maximiza  $L(\theta)$ :

$$\hat{\theta}_{EMV} = \arg \max_{\theta \in \Theta} L(\theta).$$

## Log-verosimilitud

Como log es una función estrictamente creciente, maximizar  $L(\theta)$  equivale a maximizar

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta),$$


que en general es mucho más fácil de derivar (transforma productos en sumas).

## Receta general

# Interpretación gráfica de la verosimilitud

¿Qué significa "maximizar"  $L(\theta)$ ?

Para cada valor posible de  $\theta$ ,  $L(\theta)$  mide qué tan "compatible" es ese valor con los datos observados. El EMV es el punto más alto de esa curva.



Condición de máximo

En el máximo,  $\ell'(\hat{\theta}) = 0$  y  $\ell''(\hat{\theta}) < 0$  (concavidad hacia abajo).

# EMV para la distribución Bernoulli

## Example

Sea  $X_1, \dots, X_n$  m.a. de  $X \sim \text{Be}(p)$ , con  $f(x; p) = p^x(1-p)^{1-x}$ ,  $x \in \{0, 1\}$ .

$$L(p) = \prod_{i=1}^n p^{x_i}(1-p)^{1-x_i} = p^{\sum x_i}(1-p)^{n-\sum x_i}.$$

Sea  $t = \sum_{i=1}^n x_i$  (cantidad de éxitos). Entonces

$$\ell(p) = t \ln p + (n-t) \ln(1-p).$$

Derivando:

$$\ell'(p) = \frac{t}{p} - \frac{n-t}{1-p} = 0 \implies t(1-p) = (n-t)p \implies t = np \implies \hat{p} = \frac{t}{n} = \bar{x}.$$

Como  $\ell''(p) = -t/p^2 - (n-t)/(1-p)^2 < 0$ , es máximo. **El EMV de  $p$  es la proporción muestral  $\hat{p} = \bar{X}$ .**



## EMV para la distribución de Poisson

### Example

Sea  $X_1, \dots, X_n$  m.a. de  $X \sim \text{Poisson}(\lambda)$ ,  $f(x; \lambda) = \frac{e^{-\lambda} \lambda^x}{x!}$ .

$$L(\lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} = \frac{e^{-n\lambda} \lambda^{\sum x_i}}{\prod x_i!}.$$

$$\ell(\lambda) = -n\lambda + \left( \sum_{i=1}^n x_i \right) \ln \lambda - \ln \left( \prod x_i! \right).$$

$$\ell'(\lambda) = -n + \frac{\sum x_i}{\lambda} = 0 \implies \hat{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{X}.$$

Como  $\ell''(\lambda) = -\sum x_i / \lambda^2 < 0$  (si algún  $x_i > 0$ ), es máximo. **El EMV de  $\lambda$  es  $\bar{X}$ .**

## EMV para la distribución exponencial

### Example

Sea  $X_1, \dots, X_n$  m.a. de  $X \sim \text{Exp}(\lambda)$ ,  $f(x; \lambda) = \lambda e^{-\lambda x}$ ,  $x > 0$ .

$$L(\lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum x_i}.$$

$$\ell(\lambda) = n \ln \lambda - \lambda \sum_{i=1}^n x_i.$$

$$\ell'(\lambda) = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0 \implies \hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{x}}.$$

Como  $\ell''(\lambda) = -n/\lambda^2 < 0$ , es máximo. **El EMV de  $\lambda$  es  $1/\bar{X}$**  (nótese:  $\hat{\lambda}$  es sesgado, aunque consistente, ya que  $E(1/\bar{X}) \neq 1/E(\bar{X})$  en general).

## EMV para la distribución normal (deducción completa)

### Example

Sea  $X_1, \dots, X_n$  m.a. de  $X \sim N(\mu, \sigma^2)$ , ambos parámetros desconocidos.

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right).$$

$$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right).$$

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

## EMV para la normal: resolución del sistema

Derivando respecto de  $\mu$  e igualando a cero:

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \implies \hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

Derivando respecto de  $\sigma^2$  (tratándolo como una única variable) e igualando a cero:

$$\begin{aligned} \frac{\partial \ell}{\partial \sigma^2} &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0 \\ \implies \hat{\sigma}^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2. \end{aligned}$$

### Observación importante

El EMV de  $\sigma^2$  es  $\hat{\sigma}^2$  (con  $n$ , **no**  $n - 1$ ): coincide con el estimador **sesgado** de la Clase 21, no con  $S^2$ . El EMV no siempre es insesgado.

# Propiedades del estimador de máxima verosimilitud

## Propiedad de invarianza

Si  $\hat{\theta}$  es el EMV de  $\theta$  y  $g$  es una función biunívoca (inyectiva), entonces  $g(\hat{\theta})$  es el EMV de  $g(\theta)$ .

## Example

Como el EMV de  $\sigma^2$  es  $\hat{\sigma}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$ , por invarianza el EMV del desvío estándar  $\sigma$  es

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

## Propiedades asintóticas (bajo condiciones de regularidad)

- **Consistencia:**  $\hat{\theta}_{EMV} \xrightarrow{P} \theta$  cuando  $n \rightarrow \infty$ .
- **Eficiencia asintótica:** su varianza se aproxima a la cota de Cramér–Rao para  $n$  grande.
- **Normalidad asintótica:**  $\hat{\theta}_{EMV}$  tiene distribución aproximadamente normal para  $n$  grande.

# Comparación: mínimos cuadrados vs. máxima verosimilitud

## Similitudes y diferencias

- Ambos métodos son **criterios de optimización**: eligen el parámetro que "mejor explica" los datos, según un objetivo distinto.
- MC minimiza distancias al cuadrado; no requiere especificar toda la distribución, solo la forma de la media.
- EMV maximiza la probabilidad (o densidad) de observar los datos; requiere conocer la distribución completa.
- Para el modelo normal con media constante, ambos métodos coinciden:  
$$\hat{\mu}_{MC} = \hat{\mu}_{EMV} = \bar{X}.$$

## En la práctica

El EMV es el método más usado en Estadística por sus buenas propiedades asintóticas (consistencia, eficiencia, normalidad); MC es central en regresión lineal (Unidad 8).

## Ejemplo numérico: EMV con datos concretos

### Example

Se registra el número de llamados que recibe un call center por minuto, durante  $n = 8$  minutos, asumiendo  $X \sim \text{Poisson}(\lambda)$ :

3, 5, 2, 4, 3, 6, 4, 5.

Sabemos que el EMV de  $\lambda$  en Poisson es  $\hat{\lambda} = \bar{x}$ . Calculamos:

$$\sum_{i=1}^8 x_i = 3 + 5 + 2 + 4 + 3 + 6 + 4 + 5 = 32, \quad \hat{\lambda} = \bar{x} = \frac{32}{8} = 4.$$

**Estimación de máxima verosimilitud:**  $\hat{\lambda} = 4$  llamados por minuto.

Si además nos interesara  $g(\lambda) = P(X = 0) = e^{-\lambda}$  (probabilidad de no recibir llamados en un minuto), por invarianza:

$$\hat{g} = e^{-\hat{\lambda}} = e^{-4} \approx 0.0183.$$

# Resumen

## Método de mínimos cuadrados

Minimiza  $\sum (x_i - g(\theta))^2$ . Para el modelo de media constante, coincide con  $\bar{X}$ .

## Método de máxima verosimilitud

Maximiza  $L(\theta) = \prod f(x_i; \theta)$ , o equivalentemente  $\ell(\theta) = \ln L(\theta)$ .

| Distribución              | Parámetro  | EMV                                                   |
|---------------------------|------------|-------------------------------------------------------|
| Bernoulli( $p$ )          | $p$        | $\hat{p} = \bar{X}$                                   |
| Poisson( $\lambda$ )      | $\lambda$  | $\hat{\lambda} = \bar{X}$                             |
| Exponencial( $\lambda$ )  | $\lambda$  | $\hat{\lambda} = 1/\bar{X}$                           |
| Normal( $\mu, \sigma^2$ ) | $\mu$      | $\hat{\mu} = \bar{X}$                                 |
| Normal( $\mu, \sigma^2$ ) | $\sigma^2$ | $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ |

## Próxima clase

Usaremos estos estimadores puntuales como base para construir intervalos de confianza en