

Unidad 7: Prueba de hipótesis

Apunte de teoría

Probabilidad y Estadística (5765)

Universidad Nacional del Sur

Índice

1. Conceptos fundamentales de la prueba de hipótesis	2
1.1. De la estimación a la decisión estadística	2
1.2. Hipótesis nula y alternativa	2
1.3. Errores de tipo I y tipo II	3
1.4. Potencia de una prueba	4
1.5. Estadístico de prueba y región crítica	5
1.6. El valor p	6
1.7. Procedimiento general de una prueba de hipótesis	7
1.8. Dualidad entre prueba de hipótesis e intervalo de confianza	8
2. Pruebas para una media y una varianza poblacional	10
2.1. Prueba para la media con varianza conocida (prueba Z)	10
2.2. Prueba para la media con varianza desconocida (prueba t)	11
2.3. Prueba para la varianza poblacional	12
3. Pruebas para dos muestras	15
3.1. Diferencia de medias: varianzas conocidas	15
3.2. Diferencia de medias: varianzas desconocidas e iguales (pooled)	16
3.3. Muestras apareadas	18
3.4. Igualdad de dos varianzas: prueba F de Snedecor	19
4. Pruebas chi-cuadrado: bondad de ajuste, independencia y homogeneidad	22
4.1. Prueba de bondad de ajuste	22
4.2. Prueba de independencia en tablas de contingencia	24
4.3. Prueba de homogeneidad	25
4.4. Comparación de las tres pruebas y condiciones de aplicación	26
5. Observaciones adicionales	28

1. Conceptos fundamentales de la prueba de hipótesis

1.1. De la estimación a la decisión estadística

En la Unidad 6 desarrollamos la teoría de la **estimación** de parámetros poblacionales: dado un parámetro desconocido θ (una media μ , una varianza σ^2 , una proporción p , etc.), construimos estimadores puntuales y, más informativamente, intervalos de confianza que acompañan la estimación con una medida de precisión. El problema que abordamos ahora es de naturaleza distinta. En muchas aplicaciones el investigador no necesita estimar θ : ya cuenta con un valor de referencia, una conjetura, una especificación técnica o una afirmación que debe verificarse, y lo que necesita es **decidir**, a partir de la evidencia que proporciona una muestra aleatoria, si esa conjetura es sostenible o si debe rechazarse en favor de una alternativa.

Este tipo de problema aparece constantemente en la práctica:

- ¿El contenido medio de las bolsas de un producto es realmente el que indica el rótulo?
- ¿Un nuevo proceso de fabricación reduce la proporción de piezas defectuosas respecto del proceso anterior?
- ¿La variabilidad de un instrumento de medición supera la tolerancia técnica admitida?
- ¿El rendimiento académico de los estudiantes es independiente del turno en el que cursan?
- ¿Dos formulaciones de un medicamento producen, en promedio, el mismo efecto terapéutico?

En todos los casos hay una pregunta binaria de fondo (la afirmación es cierta o no lo es) y una fuente de información parcial y aleatoria (la muestra) con la cual formular una respuesta. La disciplina que organiza este tipo de razonamiento se llama **prueba de hipótesis** (o contraste de hipótesis), y constituye, junto con la estimación, uno de los dos grandes pilares de la inferencia estadística clásica. De hecho, como veremos en la Sección 1.8, ambos pilares están profundamente relacionados: toda prueba de hipótesis bilateral puede reformularse en términos de un intervalo de confianza, y viceversa.

Conviene remarcar desde el inicio la naturaleza *probabilística* —no determinística— de las conclusiones que se obtienen. Una prueba de hipótesis nunca demuestra con certeza absoluta que una afirmación sobre la población es verdadera o falsa: lo que hace es cuantificar, mediante probabilidades controladas de antemano, el riesgo de equivocarse al tomar una decisión basada en una muestra finita. Este control explícito del error es lo que distingue a la inferencia estadística de la mera opinión basada en datos.

1.2. Hipótesis nula y alternativa

Definición 1.1. Una **hipótesis estadística** es una afirmación (conjetura) acerca del valor de uno o más parámetros de una o varias poblaciones, o acerca de la forma de la distribución de una variable aleatoria.

Toda prueba de hipótesis involucra dos afirmaciones complementarias.

Definición 1.2. La **hipótesis nula**, denotada H_0 , es la afirmación que se somete a prueba. Representa la situación de referencia, el *status quo*, el valor histórico, la especificación técnica, o la ausencia de efecto o diferencia. Se formula siempre como una igualdad respecto de un valor de referencia θ_0 :

$$H_0 : \theta = \theta_0.$$

Definición 1.3. La **hipótesis alternativa**, denotada H_1 (o H_a), es la afirmación que se sostiene como razonable cuando la evidencia muestral resulta incompatible con H_0 . Según el problema, puede formularse de tres maneras:

$$H_1 : \theta \neq \theta_0 \quad (\text{bilateral o de dos colas}),$$

$$H_1 : \theta > \theta_0 \quad \text{o bien} \quad H_1 : \theta < \theta_0 \quad (\text{unilaterales o de una cola}).$$

La elección entre una alternativa bilateral y una unilateral no es arbitraria: depende exclusivamente de la pregunta de investigación planteada *antes* de observar los datos. Si el interés es detectar cualquier apartamiento del valor de referencia, sin importar el sentido, corresponde una alternativa bilateral. Si el interés específico es detectar un aumento (o una disminución), corresponde una alternativa unilateral en el sentido correspondiente. Decidir el tipo de alternativa después de observar los datos —por ejemplo, mirar el signo de $\bar{x} - \mu_0$ y recién ahí elegir la cola— invalida por completo el procedimiento, porque distorsiona la probabilidad de error que se pretende controlar.

Observación 1.4. H_0 y H_1 deben ser mutuamente excluyentes y, en el marco que se utiliza en este curso, exhaustivas respecto del parámetro: toda decisión posible (rechazar o no rechazar H_0) se interpreta en términos de estas dos afirmaciones. Es habitual que la afirmación que el investigador sospecha o desea sustentar con evidencia se formule como H_1 , dejando en H_0 la postura conservadora o la que representa ausencia de novedad. Esta convención no es casual: como se verá en la Sección 1.3, la estructura de la prueba está diseñada para controlar rigurosamente el error de rechazar H_0 de manera indebida, por lo que conviene que H_0 sea la afirmación cuyo rechazo erróneo tenga las consecuencias más costosas.

Ejemplo 1.5. Una fábrica de rodamientos afirma que el diámetro medio de su producción es $\mu_0 = 10$ mm. Un control de calidad sospecha que el proceso se desvió de esa especificación, sin tener razones para pensar que el desvío sea en un sentido particular. Se plantea entonces una prueba bilateral:

$$H_0 : \mu = 10 \quad \text{vs.} \quad H_1 : \mu \neq 10.$$

Ejemplo 1.6. Un nuevo fertilizante se ensaya con la esperanza de que **aumente** el rendimiento medio μ de un cultivo respecto del valor histórico $\mu_0 = 40$ qq/ha obtenido con el fertilizante tradicional. La pregunta de investigación tiene un sentido definido (aumento), por lo que corresponde una prueba unilateral:

$$H_0 : \mu \leq 40 \quad \text{vs.} \quad H_1 : \mu > 40.$$

En la práctica, para el cálculo del estadístico y de la región crítica se trabaja siempre con la igualdad $H_0 : \mu = 40$, que es el punto de la frontera de H_0 más desfavorable para el investigador (el más difícil de rechazar), y por lo tanto el que garantiza que la probabilidad de error tipo I no supere el nivel fijado en ningún punto de $H_0 : \mu \leq 40$.

1.3. Errores de tipo I y tipo II

Una prueba de hipótesis conduce, inevitablemente, a una de dos decisiones: **rechazar** H_0 o **no rechazar** H_0 . Puesto que la decisión se basa en una muestra aleatoria y no en la población completa, siempre existe una probabilidad positiva de que la decisión tomada no coincida con el verdadero estado de la naturaleza. La siguiente tabla resume las cuatro situaciones posibles.

	H_0 verdadera	H_0 falsa
No rechazar H_0	Decisión correcta ($1 - \alpha$)	Error de tipo II (β)
Rechazar H_0	Error de tipo I (α)	Decisión correcta ($1 - \beta$, potencia)

Cuadro 1: Errores posibles en una prueba de hipótesis.

Definición 1.7. El **error de tipo I** consiste en rechazar H_0 cuando en realidad es verdadera. Su probabilidad se llama **nivel de significación** de la prueba y se denota

$$\alpha = P(\text{Rechazar } H_0 \mid H_0 \text{ verdadera}).$$

Definición 1.8. El **error de tipo II** consiste en no rechazar H_0 cuando en realidad es falsa. Su probabilidad se denota

$$\beta = P(\text{No rechazar } H_0 \mid H_0 \text{ falsa}).$$

El nivel de significación α es fijado *de antemano* por quien diseña la prueba, típicamente en valores como 0.10, 0.05 o 0.01, y representa la probabilidad máxima que se está dispuesto a tolerar de rechazar erróneamente una hipótesis nula verdadera. Es importante remarcar que α no es una cantidad que se calcule a partir de los datos: es una decisión de diseño, tomada antes de observar la muestra, análoga a fijar el nivel de confianza $1 - \alpha$ de un intervalo de confianza.

A diferencia de α , la probabilidad β de error de tipo II no es un único número: depende de *cuál* sea el verdadero valor del parámetro dentro de H_1 (es decir, de qué tan alejado esté el valor real θ de θ_0). Cuanto más cercano esté el valor verdadero al valor hipotetizado θ_0 , más difícil es distinguirlo con una muestra finita, y por lo tanto mayor será β para ese valor particular.

Propiedad 1.9 (Relación entre α y β). *Para un tamaño de muestra n fijo y un estadístico de prueba dado, α y β están inversamente relacionados: si se reduce el tamaño de la región crítica para disminuir α , aumenta correspondientemente β (y viceversa). La única manera de disminuir simultáneamente ambas probabilidades de error es aumentar el tamaño de la muestra n .*

Esta propiedad tiene una justificación intuitiva sencilla: si RR denota la región crítica y $RA = RR^c$ la región de no rechazo, entonces $\alpha = P(T \in RR \mid H_0)$ y $\beta = P(T \in RA \mid H_1)$. Si se agranda RR para hacer α más chico, automáticamente RA se agranda también (es su complemento), y por lo tanto $\beta = P(T \in RA \mid H_1)$ tiende a crecer. La única forma de reducir el tamaño de ambas regiones de error sin que una compense a la otra es hacer que la distribución del estadístico bajo H_0 y bajo H_1 se *concentren* más y se separen más entre sí, lo cual se logra reduciendo la varianza del estimador, es decir, aumentando n .

Observación 1.10 (¿Por qué se prioriza el control de α ?). En la construcción clásica de una prueba de hipótesis, H_0 suele representar la afirmación conservadora, aquella cuyo rechazo erróneo acarrea las consecuencias más costosas (por ejemplo, retirar del mercado un lote de producto en buen estado, interrumpir un proceso de fabricación que funciona correctamente, o acusar de un efecto que no existe). Por esta razón, el procedimiento controla *directamente* y de manera explícita la probabilidad α de cometer ese error particular, fijando su valor antes de ver los datos. La probabilidad β , en cambio, se analiza indirectamente a través del concepto de potencia, que desarrollamos a continuación.

1.4. Potencia de una prueba

Definición 1.11. La **potencia** de una prueba de hipótesis, para un valor particular $\theta_1 \neq \theta_0$ del parámetro dentro de H_1 , es la probabilidad de rechazar H_0 cuando el verdadero valor del parámetro es θ_1 :

$$\text{Potencia}(\theta_1) = 1 - \beta(\theta_1) = P(\text{Rechazar } H_0 \mid \theta = \theta_1).$$

La potencia mide, entonces, la capacidad de la prueba para *detectar* que H_0 es falsa, cuando el verdadero parámetro se aparta de θ_0 en una magnitud dada. Como función de θ_1 (manteniendo fijos n y α), a la función $\theta_1 \mapsto \text{Potencia}(\theta_1)$ se la llama **función de potencia** de la prueba.

Ilustremos el cálculo de la potencia en el caso más simple: la prueba Z para una media con varianza conocida, $H_0 : \mu = \mu_0$ vs. $H_1 : \mu > \mu_0$, con región crítica $\bar{X} > \mu_0 + z_\alpha \sigma / \sqrt{n}$ (que es equivalente a $Z > z_\alpha$). Si el verdadero valor de la media es $\mu_1 > \mu_0$, entonces $\bar{X} \sim N(\mu_1, \sigma^2/n)$, y

$$\text{Potencia}(\mu_1) = P\left(\bar{X} > \mu_0 + z_\alpha \frac{\sigma}{\sqrt{n}} \mid \mu = \mu_1\right) = P\left(\frac{\bar{X} - \mu_1}{\sigma/\sqrt{n}} > z_\alpha - \frac{\mu_1 - \mu_0}{\sigma/\sqrt{n}}\right) = P\left(Z > z_\alpha - \frac{(\mu_1 - \mu_0)\sqrt{n}}{\sigma}\right)$$

donde ahora $Z \sim N(0, 1)$. Esta expresión permite leer directamente los tres factores que determinan la potencia:

- Cuanto mayor es la diferencia $|\mu_1 - \mu_0|$ (el **efecto** a detectar) en relación con σ , más negativo se vuelve el argumento de $P(Z > \cdot)$ y mayor es la potencia: es "más fácil" detectar diferencias grandes que diferencias pequeñas.
- A mayor tamaño de muestra n , el término $(\mu_1 - \mu_0)\sqrt{n}/\sigma$ crece, y por lo tanto la potencia aumenta para una misma diferencia real $\mu_1 - \mu_0$. Este es el fundamento estadístico de los cálculos de **tamaño de muestra** necesarios para garantizar una potencia mínima deseada frente a un efecto mínimo de interés.
- A mayor α (una región de rechazo más amplia, con z_α más chico), mayor es la potencia, pero a costa de un mayor riesgo de error de tipo I. Esta es, precisamente, la manifestación de la relación inversa entre α y β discutida antes.

Observación 1.12. Entre dos pruebas construidas con el mismo nivel α , se prefiere aquella que tiene mayor potencia (es decir, menor β) para detectar el efecto de interés. Este criterio de comparación entre pruebas —maximizar la potencia sujeto a una cota sobre α — es la base de la teoría de pruebas óptimas (uniformemente más potentes), que excede el alcance de este curso, pero que explica por qué los estadísticos de prueba que estudiaremos (basados en $\bar{X}$, S^2 , etc.) no son elecciones arbitrarias sino, en general, las mejores posibles dentro de su clase.

Ejemplo 1.13. Continuando el ejemplo anterior, supongamos $\sigma = 10$, $n = 36$, $\alpha = 0.05$ (por lo que $z_\alpha = z_{0.05} = 1.645$), y que interesa la potencia para detectar un verdadero $\mu_1 = \mu_0 + 3$. Entonces

$$\text{Potencia} = P\left(Z > 1.645 - \frac{3\sqrt{36}}{10}\right) = P(Z > 1.645 - 1.8) = P(Z > -0.155) \approx 0.5616.$$

Es decir, con este diseño hay solo un 56 % de probabilidad de detectar un verdadero aumento de 3 unidades en la media; para lograr una potencia mayor sería necesario aumentar n .

1.5. Estadístico de prueba y región crítica

Definición 1.14. El **estadístico de prueba** (o estadístico de contraste) es una función de la muestra aleatoria, $T = T(X_1, \dots, X_n)$, cuya distribución de probabilidad **bajo el supuesto de que H_0 es verdadera** es completamente conocida.

El estadístico de prueba resume, en un único número, la información muestral relevante para el parámetro en cuestión, y permite comparar lo efectivamente observado con lo que cabría esperar si H_0 fuese cierta. Valores del estadístico que resultan "poco compatibles" con esa distribución de referencia constituyen evidencia en contra de H_0 y conducen a su rechazo.

Ejemplo 1.15. Para probar $H_0 : \mu = \mu_0$ con varianza poblacional conocida σ^2 , a partir de una muestra $X_1, \dots, X_n$ de una población $N(\mu, \sigma^2)$, el estadístico de prueba natural es

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \stackrel{H_0}{\sim} N(0, 1),$$

lo cual se sigue directamente de que, bajo H_0 , $\bar{X} \sim N(\mu_0, \sigma^2/n)$ y por lo tanto su estandarización es $N(0, 1)$.

Definición 1.16. El espacio de todos los valores posibles del estadístico de prueba se particiona en dos subconjuntos complementarios:

- la **región crítica** o **región de rechazo**, RR : el conjunto de valores del estadístico que llevan a rechazar H_0 ;
- la **región de aceptación** (o de no rechazo), $RA = RR^c$: el conjunto de valores compatibles con H_0 .

La región crítica se determina de modo que, *bajo el supuesto de que H_0 es verdadera*, la probabilidad de que el estadístico caiga en RR sea exactamente igual al nivel de significación α fijado de antemano:


$$P(T \in RR \mid H_0) = \alpha.$$

La forma geométrica de RR (si ocupa una o dos colas de la distribución de referencia) queda determinada por la forma de H_1 :

- $H_1 : \theta \neq \theta_0$ (bilateral) $\Rightarrow RR$ se reparte en **ambas colas** de la distribución, generalmente con $\alpha/2$ de probabilidad en cada extremo.
- $H_1 : \theta > \theta_0 \Rightarrow RR$ ocupa la **cola derecha**, con probabilidad α .
- $H_1 : \theta < \theta_0 \Rightarrow RR$ ocupa la **cola izquierda**, con probabilidad α .

Esta correspondencia tiene una justificación intuitiva: la región crítica debe ubicarse en la zona de valores del estadístico que son "más extremos" en el sentido que indica H_1 , es decir, en la dirección en la que un valor observado sería más difícil de explicar si H_0 fuera cierta y más consistente con H_1 .

A continuación se ilustra la diferencia entre una región crítica bilateral y una unilateral para el caso $Z \sim N(0, 1)$ con $\alpha = 0.05$.



En ambos gráficos, las regiones sombreadas en rojo son las regiones críticas, cuya área total (bajo la curva de densidad de H_0) es igual a α en cada caso.

1.6. El valor p

Además de comparar el estadístico observado con los valores críticos, existe una forma equivalente —y más informativa— de resumir la evidencia muestral en contra de H_0 : el valor p.

Definición 1.17. El **valor p** (o p -valor) es la probabilidad, calculada bajo el supuesto de que H_0 es verdadera, de obtener un valor del estadístico de prueba tan extremo o más extremo (en el sentido indicado por H_1) que el efectivamente observado en la muestra.

Formalmente, si t_{obs} es el valor observado del estadístico T , el valor p se calcula como:

- $H_1 : \theta > \theta_0$: $p = P(T \geq t_{obs} \mid H_0)$;
- $H_1 : \theta < \theta_0$: $p = P(T \leq t_{obs} \mid H_0)$;
- $H_1 : \theta \neq \theta_0$: $p = 2 \min\{P(T \geq t_{obs} \mid H_0), P(T \leq t_{obs} \mid H_0)\}$, que en el caso de estadísticos con distribución simétrica bajo H_0 (como Z o T) se reduce a $p = 2P(T \geq |t_{obs}| \mid H_0)$.

Propiedad 1.18. La regla de decisión basada en el valor p es equivalente a la regla de decisión basada en la región crítica:

$$p\text{-valor} \leq \alpha \iff \text{el estadístico observado cae en la región crítica de nivel } \alpha.$$

Por lo tanto,

$$p\text{-valor} \leq \alpha \Rightarrow \text{se rechaza } H_0; \quad p\text{-valor} > \alpha \Rightarrow \text{no se rechaza } H_0.$$

Demostración. Consideremos el caso unilateral derecho, $H_1 : \theta > \theta_0$, con región crítica $RR = \{T > c_\alpha\}$ donde c_α es el valor crítico que satisface $P(T > c_\alpha | H_0) = \alpha$. Por definición, $p = P(T \geq t_{obs} | H_0)$. Como la función $c \mapsto P(T > c | H_0)$ es no creciente en c (es la función de supervivencia de T bajo H_0), se tiene que $t_{obs} > c_\alpha$ si y solo si $P(T > t_{obs} | H_0) < P(T > c_\alpha | H_0) = \alpha$, es decir, t_{obs} cae en la región crítica si y solo si $p \leq \alpha$ (salvo por la distinción entre desigualdad estricta y no estricta, irrelevante para distribuciones continuas). El mismo argumento, con las adaptaciones obvias, se aplica a los casos unilateral izquierdo y bilateral. $\square$

Esta equivalencia es la razón por la cual, en la práctica —y especialmente al usar software estadístico—, suele reportarse directamente el valor p en lugar de (o además de) los valores críticos: alcanza con comparar un único número contra α .

Observación 1.19 (Interpretación correcta del valor p). El valor p es, posiblemente, el concepto más frecuentemente malinterpretado de la estadística inferencial. Conviene ser precisos:

- El valor p **no** es la probabilidad de que H_0 sea verdadera, ni $1 - p$ es la probabilidad de que H_1 sea verdadera. El valor p se calcula *asumiendo que H_0 es cierta*; no puede, por lo tanto, ser una afirmación de probabilidad sobre la veracidad de H_0 misma (eso requeriría un enfoque bayesiano, con una distribución de probabilidad a priori sobre θ).
- El valor p **no** mide el tamaño o la importancia práctica del efecto detectado. Con una muestra suficientemente grande, incluso una diferencia mínima y sin relevancia práctica puede producir un valor p muy pequeño.
- Lo que el valor p sí mide es cuán compatibles son los datos observados con H_0 : cuanto menor es el valor p , menos compatibles son los datos con H_0 , y por lo tanto mayor es la evidencia en contra de H_0 que aportan los datos.

1.7. Procedimiento general de una prueba de hipótesis

Formalizamos ahora el procedimiento general, que se aplicará de manera sistemática a cada una de las pruebas específicas estudiadas en las secciones siguientes. Consta de cinco pasos esenciales (que a veces se desglosan en más para mayor claridad expositiva):

Paso 1. Formular las hipótesis. Se plantean H_0 y H_1 en términos del parámetro poblacional de interés, de acuerdo con la pregunta de investigación, *antes* de observar los datos muestrales.

Paso 2. Fijar el nivel de significación α y elegir el estadístico de prueba. Se determina el nivel de riesgo tolerado para el error de tipo I, y se elige el estadístico T adecuado a la situación (parámetro de interés, supuestos sobre la población, tamaño de muestra), estableciendo su distribución exacta o aproximada bajo H_0 .

Paso 3. Determinar la región crítica. De acuerdo con α y con la forma de H_1 (bilateral, unilateral derecha o unilateral izquierda), se determina el o los valores críticos que delimitan RR ; alternativamente (o en forma complementaria), se deja planteado el cálculo del valor p .

Paso 4. Calcular el estadístico a partir de los datos. Se evalúa T con los valores efectivamente observados en la muestra, obteniendo t_{obs} ; y, si corresponde, se calcula el valor p asociado.

Paso 5. Decidir y concluir. Se rechaza H_0 si $t_{obs} \in RR$ (equivalentemente, si el valor p es menor o igual que α); en caso contrario, no se rechaza H_0 . Finalmente, la decisión estadística se traduce a una **conclusión** en el lenguaje del problema original, sin jerga técnica.

Observación 1.20. Algunos puntos merecen atención especial:

- “No rechazar H_0 ” **no equivale** a “aceptar H_0 como verdadera”. Significa, únicamente, que la evidencia muestral disponible no alcanza para rechazarla al nivel α elegido; podría deberse tanto a que H_0 es efectivamente cierta como a que la muestra fue insuficiente (poca potencia) para detectar un apartamiento real.
- El nivel α , así como la forma de H_1 y el tamaño de muestra n , deben fijarse **antes** de observar los datos. Modificar cualquiera de estos elementos *después* de ver los resultados (una práctica a veces llamada informalmente *p-hacking*) invalida las propiedades probabilísticas de la prueba, porque la probabilidad de error de tipo I real deja de ser la nominal α .
- El esquema conceptual (hipótesis, estadístico, distribución bajo H_0 , región crítica, valor p , decisión) es común a *todas* las pruebas específicas que se desarrollan en las secciones siguientes; lo único que cambia de una prueba a otra es el estadístico particular utilizado y su distribución de referencia.

1.8. Dualidad entre prueba de hipótesis e intervalo de confianza

Existe una relación profunda —y muy útil en la práctica— entre las pruebas de hipótesis bilaterales y los intervalos de confianza construidos con el mismo estadístico pivotal.

Teorema 1.21 (Dualidad prueba-intervalo). *Sea θ un parámetro poblacional y sea $IC_{1-\alpha}(\theta)$ un intervalo de confianza de nivel $1 - \alpha$ para θ , construido a partir de un estadístico pivotal cuya distribución es simétrica y conocida. Entonces, para la prueba bilateral $H_0 : \theta = \theta_0$ vs. $H_1 : \theta \neq \theta_0$ al nivel de significación α , se cumple*

$$\text{Se rechaza } H_0 \text{ al nivel } \alpha \iff \theta_0 \notin IC_{1-\alpha}(\theta).$$

Demostración. Demostramos la equivalencia en el caso de la media con varianza σ^2 conocida; el argumento se traslada sin cambios estructurales a los demás parámetros. El intervalo de confianza de nivel $1 - \alpha$ para μ es

$$IC_{1-\alpha}(\mu) = \left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right),$$

que se obtiene a partir del pivote $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ despejando μ en la desigualdad $-z_{\alpha/2} < Z < z_{\alpha/2}$.

Por otro lado, la región crítica de la prueba bilateral $H_0 : \mu = \mu_0$ vs. $H_1 : \mu \neq \mu_0$ al nivel α , con estadístico $Z_0 = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$, es $RR = \{|Z_0| > z_{\alpha/2}\}$. Entonces:

$$\begin{aligned} \mu_0 \notin IC_{1-\alpha}(\mu) &\iff \mu_0 < \bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \text{ o } \mu_0 > \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \\ &\iff \bar{X} - \mu_0 > z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \text{ o } \bar{X} - \mu_0 < -z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \iff \left| \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \right| > z_{\alpha/2} \iff |Z_0| > z_{\alpha/2}, \end{aligned}$$

que es exactamente la condición de rechazo de H_0 . Esto prueba la equivalencia. $\square$

Ejemplo 1.22. Si un intervalo de confianza del 95 % para μ resulta $IC = (48.3; 51.7)$ y se desea probar $H_0 : \mu = 50$ vs. $H_1 : \mu \neq 50$ con $\alpha = 0.05$: como $50 \in (48.3; 51.7)$, no se rechaza H_0 . En cambio, si se quisiera probar $H_0 : \mu = 52$ vs. $H_1 : \mu \neq 52$ con el mismo α , como $52 \notin (48.3; 51.7)$, se rechazaría H_0 .

Observación 1.23. La equivalencia demostrada es válida, tal como está enunciada, para pruebas **bilaterales** y su correspondiente intervalo de confianza (bilateral) de nivel $1 - \alpha$. Para pruebas **unilaterales**, existe una correspondencia análoga con intervalos de confianza de una cola (semi-rectas): la prueba $H_0 : \mu = \mu_0$ vs. $H_1 : \mu > \mu_0$ al nivel α es equivalente a rechazar H_0 cuando

μ_0 queda por debajo del extremo inferior de un intervalo de confianza unilateral de nivel $1 - \alpha$ de la forma $(\bar{X} - z_\alpha \sigma / \sqrt{n}, +\infty)$.

La utilidad práctica de esta dualidad es considerable: un único intervalo de confianza permite decidir simultáneamente sobre *cualquier* valor hipotético θ_0 (bilateral), mientras que cada prueba de hipótesis, tal como se plantea habitualmente, evalúa un único valor θ_0 a la vez. Por esta razón, cuando se dispone de un intervalo de confianza ya calculado, suele ser más económico usarlo directamente para responder preguntas de prueba de hipótesis que recalcular el estadístico de prueba desde cero.

2. Pruebas para una media y una varianza poblacional

En esta sección aplicamos el marco general desarrollado a los dos parámetros más habituales de una única población: la media μ y la varianza σ^2 . Como se anticipó, lo único que cambia de una prueba a otra es el estadístico utilizado, su distribución bajo H_0 y, en consecuencia, la forma de la región crítica; la lógica de decisión (pasos 1, 2, 5) permanece invariable.

2.1. Prueba para la media con varianza conocida (prueba Z)

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población $N(\mu, \sigma^2)$ (o, más generalmente, de cualquier población con varianza σ^2 finita y n suficientemente grande, apelando al Teorema Central del Límite), con σ^2 **conocida**. Interesa probar

$$H_0 : \mu = \mu_0.$$

Teorema 2.1 (Estadístico de prueba). *Bajo H_0 , el estadístico*

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$$

se distribuye exactamente $N(0, 1)$ si la población es normal, y aproximadamente $N(0, 1)$ para n grande en el caso general, por el Teorema Central del Límite.

Demostración. Si $X_1, \dots, X_n$ son i.i.d. $N(\mu, \sigma^2)$, entonces $\bar{X}$ es una combinación lineal de variables normales independientes, por lo que $\bar{X} \sim N(\mu, \sigma^2/n)$ exactamente, para cualquier n . Bajo H_0 , $\mu = \mu_0$, luego $\bar{X} \sim N(\mu_0, \sigma^2/n)$, y estandarizando, $Z = (\bar{X} - \mu_0)/(\sigma/\sqrt{n}) \sim N(0, 1)$. Cuando la población no es normal pero n es grande, el Teorema Central del Límite garantiza que $\bar{X}$ es aproximadamente $N(\mu, \sigma^2/n)$, y el mismo argumento produce la distribución aproximada de Z . $\square$

La región crítica se construye de modo que, bajo H_0 , el estadístico Z caiga en ella con probabilidad exactamente α , respetando el sentido de H_1 :

H_1	Región crítica	Naturaleza
$\mu \neq \mu_0$	$ Z > z_{\alpha/2}$	bilateral
$\mu > \mu_0$	$Z > z_\alpha$	cola derecha
$\mu < \mu_0$	$Z < -z_\alpha$	cola izquierda

donde z_γ denota el valor tal que $P(Z > z_\gamma) = \gamma$ para $Z \sim N(0, 1)$. Estas regiones se deducen exigiendo que la probabilidad de rechazo bajo H_0 sea α : por ejemplo, en el caso bilateral, $P(|Z| > z_{\alpha/2} \mid H_0) = P(Z > z_{\alpha/2}) + P(Z < -z_{\alpha/2}) = \alpha/2 + \alpha/2 = \alpha$, usando la simetría de la $N(0, 1)$.

Ejemplo 2.2 (Prueba bilateral, deducción completa). Una máquina envasa paquetes de café cuyo peso se distribuye $N(\mu, \sigma^2)$ con $\sigma = 10$ g. El rótulo indica $\mu_0 = 500$ g. Se toma una muestra de $n = 36$ paquetes y se obtiene $\bar{x} = 496$ g. Con $\alpha = 0.05$, ¿hay evidencia de que el peso medio difiere de 500 g?

1. **Hipótesis:** $H_0 : \mu = 500$ vs. $H_1 : \mu \neq 500$.

2. **Estadístico:** $Z = \frac{\bar{X} - 500}{10/\sqrt{36}} \stackrel{H_0}{\sim} N(0, 1)$.

3. **Región crítica** ($\alpha = 0.05$, bilateral): $|Z| > z_{0.025} = 1.96$.

4. **Cálculo:**

$$z = \frac{496 - 500}{10/\sqrt{36}} = \frac{-4}{1.6667} = -2.40.$$

5. **Decisión por región crítica:** como $|-2.40| = 2.40 > 1.96$, se **rechaza** H_0 .

6. Cálculo del valor p (verificación): para la prueba bilateral,

$$p = 2P(Z < -2.40) = 2 \times 0.0082 = 0.0164.$$

Como $p = 0.0164 < \alpha = 0.05$, se llega exactamente a la misma decisión: se rechaza H_0 , confirmando la equivalencia entre ambos criterios demostrada en la sección anterior.

7. Conclusión: con un 5% de significación, hay evidencia estadísticamente significativa de que el peso medio de los paquetes difiere de 500 g.

Observación 2.3. Si en el ejemplo anterior la hipótesis alternativa hubiera sido unilateral, $H_1 : \mu < 500$, la región crítica sería $Z < -z_{0.05} = -1.645$; como $-2.40 < -1.645$, también se rechazaría H_0 (con más fuerza, dado que la región crítica unilateral es "más generosa" en esa cola), y el valor p sería $p = P(Z < -2.40) = 0.0082$, la mitad del valor p bilateral. Esta relación —el valor p unilateral es la mitad del bilateral, cuando el signo observado coincide con el sentido de H_1 — es general para estadísticos con distribución simétrica.

2.2. Prueba para la media con varianza desconocida (prueba t)

En la inmensa mayoría de las aplicaciones reales, σ^2 no se conoce y debe estimarse a partir de la propia muestra mediante la cuasivarianza muestral

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Al reemplazar σ por S en el estadístico Z , se introduce variabilidad adicional (la propia de estimar σ), que hace que la distribución exacta ya no sea normal estándar.

Teorema 2.4. Sea $X_1, \dots, X_n$ una muestra aleatoria de una población $N(\mu, \sigma^2)$. Bajo $H_0 : \mu = \mu_0$, el estadístico

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$$

se distribuye exactamente según una t de Student con $n-1$ grados de libertad, t_{n-1} .

Idea de la demostración. Se sabe, de la Unidad 5, que para una muestra normal, $\bar{X}$ y S^2 son independientes, que $\bar{X} \sim N(\mu, \sigma^2/n)$ y que $(n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$. Por definición, si $Z \sim N(0, 1)$ y $W \sim \chi_k^2$ son independientes, entonces $Z/\sqrt{W/k} \sim t_k$. Tomando $Z = (\bar{X} - \mu_0)/(\sigma/\sqrt{n})$ (que bajo H_0 es $N(0, 1)$) y $W = (n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$, ambos independientes, se obtiene

$$\frac{Z}{\sqrt{W/(n-1)}} = \frac{\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}}{\sqrt{\frac{(n-1)S^2/\sigma^2}{n-1}}} = \frac{\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}}{S/\sigma} = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} = T,$$

donde el factor σ se cancela algebraicamente. Por lo tanto $T \sim t_{n-1}$ bajo H_0 . □

H_1	Región crítica
$\mu \neq \mu_0$	$ T > t_{n-1, \alpha/2}$
$\mu > \mu_0$	$T > t_{n-1, \alpha}$
$\mu < \mu_0$	$T < -t_{n-1, \alpha}$

Observación 2.5. Cuando n es grande ($n \geq 30$, criterio usual), la distribución t_{n-1} se aproxima cada vez más a la $N(0, 1)$ (los cuantiles $t_{n-1, \gamma} \rightarrow z_\gamma$ cuando $n \rightarrow \infty$), y ambos procedimientos son prácticamente equivalentes en la práctica. Sin embargo, conceptualmente, si σ^2 no se conoce, el estadístico correcto sigue siendo T con $n - 1$ grados de libertad, y no Z ; usar Z subestima levemente la incertidumbre real cuando n no es muy grande.

Ejemplo 2.6 (Prueba unilateral con valor p). Un fabricante de neumáticos afirma que la duración media de un nuevo modelo supera las 40 000 km. En una muestra de $n = 16$ neumáticos (duración $\sim N(\mu, \sigma^2)$) se obtuvo $\bar{x} = 41\,200$ km y $s = 1500$ km. Con $\alpha = 0.05$, ¿respaldan los datos la afirmación del fabricante?

1. Hipótesis: $H_0 : \mu \leq 40\,000$ vs. $H_1 : \mu > 40\,000$ (se trabaja con $H_0 : \mu = 40\,000$, el punto frontera).

2. Estadístico: $T = \frac{\bar{X} - 40\,000}{S/\sqrt{16}} \stackrel{H_0}{\sim} t_{15}$.

3. Región crítica: $T > t_{15, 0.05} = 1.753$.

4. Cálculo:

$$t = \frac{41\,200 - 40\,000}{1500/\sqrt{16}} = \frac{1200}{375} = 3.20.$$

5. Decisión por región crítica: $3.20 > 1.753 \Rightarrow$ se rechaza H_0 .

6. Valor p : usando tablas de t_{15} , $P(T_{15} > 3.20)$ se ubica entre 0.0025 y 0.005 (los valores tabulados usuales dan $t_{15, 0.005} = 2.947$ y $t_{15, 0.0025} \approx 3.286$); concretamente, $p \approx 0.0029$. Como $p < 0.05$, coincide con la decisión anterior.

7. Conclusión: con un 5% de significación, la evidencia muestral respalda que la duración media supera los 40 000 km.

Ejemplo 2.7 (Prueba bilateral con no rechazo). Un laboratorio farmacéutico debe verificar que los comprimidos contienen $\mu_0 = 250$ mg del principio activo. En $n = 10$ comprimidos se midió $\bar{x} = 247.5$ mg y $s = 4.8$ mg. Con $\alpha = 0.05$:

$H_0 : \mu = 250$ vs. $H_1 : \mu \neq 250$. Región crítica ($gl = 9$): $|T| > t_{9, 0.025} = 2.262$.

$$t = \frac{247.5 - 250}{4.8/\sqrt{10}} = \frac{-2.5}{1.518} = -1.65.$$

Como $|-1.65| = 1.65 < 2.262$, no se rechaza H_0 : la evidencia muestral no es suficiente para afirmar que el contenido medio difiere de 250 mg. El valor p bilateral, $p = 2P(T_9 < -1.65) \approx 2 \times 0.0665 = 0.133$, confirma que la evidencia en contra de H_0 es débil (bastante mayor que $\alpha = 0.05$).

2.3. Prueba para la varianza poblacional

Sea nuevamente $X_1, \dots, X_n$ una muestra aleatoria de $N(\mu, \sigma^2)$. Interesa ahora probar afirmaciones sobre la variabilidad de la población, no sobre su valor central:

$$H_0 : \sigma^2 = \sigma_0^2.$$

Teorema 2.8 (Estadístico de prueba para σ^2). *Bajo H_0 , el estadístico*

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$$

se distribuye exactamente χ_{n-1}^2 .

Demostración. Es un resultado establecido en la Unidad 5 (distribuciones asociadas al muestreo normal) que, si $X_1, \dots, X_n$ es una muestra aleatoria de $N(\mu, \sigma^2)$, entonces


$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2,$$

lo cual se deduce de escribir $(n-1)S^2/\sigma^2 = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma}\right)^2$ y observar que esta es una forma cuadrática en variables normales estándar con $n-1$ grados de libertad efectivos, debido a la restricción lineal $\sum_i (X_i - \bar{X}) = 0$ que reduce en uno la dimensión del espacio de variación libre (formalmente, se sigue del teorema de Cochran o de una diagonalización ortogonal del vector $(X_i - \bar{X})/\sigma$). Bajo $H_0 : \sigma^2 = \sigma_0^2$, sustituyendo σ^2 por σ_0^2 se obtiene el estadístico enunciado, que hereda la distribución χ_{n-1}^2 . $\square$

A diferencia de Z y T , la distribución χ_{n-1}^2 **no es simétrica**: es asimétrica a derecha y toma únicamente valores no negativos. Esto tiene una consecuencia importante para el caso bilateral: los dos valores críticos que delimitan la región de rechazo *no* son opuestos entre sí (no hay noción de "signo" en χ^2), sino que se obtienen por separado de las colas inferior y superior de la distribución.

H_1	Región crítica
$\sigma^2 \neq \sigma_0^2$	$\chi^2 < \chi_{n-1, 1-\alpha/2}^2$ o $\chi^2 > \chi_{n-1, \alpha/2}^2$
$\sigma^2 > \sigma_0^2$	$\chi^2 > \chi_{n-1, \alpha}^2$
$\sigma^2 < \sigma_0^2$	$\chi^2 < \chi_{n-1, 1-\alpha}^2$

donde $\chi_{n-1, \gamma}^2$ es el valor tal que $P(\chi_{n-1}^2 > \chi_{n-1, \gamma}^2) = \gamma$.



Ejemplo 2.9 (Prueba unilateral derecha, con valor p). Un proceso de llenado de botellas debe tener una desviación estándar no mayor a $\sigma_0 = 2$ mL (varianza $\sigma_0^2 = 4$). En una muestra de $n = 20$ botellas se midió $s^2 = 6.1$ mL². Con $\alpha = 0.05$, ¿hay evidencia de que la variabilidad del proceso excede la tolerancia?

1. **Hipótesis:** $H_0 : \sigma^2 \leq 4$ vs. $H_1 : \sigma^2 > 4$ (se usa $H_0 : \sigma^2 = 4$).

2. **Estadístico:** $\chi^2 = \frac{(n-1)S^2}{4} \stackrel{H_0}{\sim} \chi_{19}^2$.

3. **Región crítica:** $\chi^2 > \chi_{19, 0.05}^2 = 30.14$.

4. **Cálculo:**

$$\chi^2 = \frac{19 \times 6.1}{4} = \frac{115.9}{4} = 28.98.$$

5. **Decisión:** $28.98 < 30.14 \Rightarrow$ no se rechaza H_0 .

6. **Valor p :** de tablas de χ_{19}^2 , $\chi_{19, 0.10}^2 = 27.20$ y $\chi_{19, 0.05}^2 = 30.14$; como $27.20 < 28.98 < 30.14$, el valor p está entre 0.05 y 0.10 (aproximadamente $p \approx 0.067$), mayor que $\alpha = 0.05$, confirmando el no rechazo.

7. **Conclusión:** con un 5% de significación, no hay evidencia suficiente de que la variabilidad del proceso supere la tolerancia especificada, aunque el resultado está cerca del límite.

Ejemplo 2.10 (Prueba bilateral). Un laboratorio requiere que la varianza de las mediciones de un instrumento sea exactamente $\sigma_0^2 = 0.25$. Una muestra de $n = 15$ mediciones da $s^2 = 0.42$. Con $\alpha = 0.10$, ¿hay evidencia de que la varianza real difiere de 0.25?

Hipótesis: $H_0 : \sigma^2 = 0.25$ vs. $H_1 : \sigma^2 \neq 0.25$.

Región crítica ($\alpha = 0.10$, 14 gl): se rechaza si $\chi^2 < \chi_{14,0.95}^2 = 6.571$ o $\chi^2 > \chi_{14,0.05}^2 = 23.68$.

Cálculo:

$$\chi^2 = \frac{14 \times 0.42}{0.25} = \frac{5.88}{0.25} = 23.52.$$

Decisión: como $23.52 < 23.68$, no se rechaza H_0 , aunque el valor está muy cerca del límite crítico. Consistentemente, el valor p bilateral (aproximadamente $p \approx 2 \times 0.052 = 0.104$, ligeramente mayor que 0.10) confirma la decisión, aunque por un margen muy estrecho.

Conclusión: al nivel 10%, no hay evidencia suficiente para afirmar que la varianza difiere de 0.25; el resultado sugiere revisar el proceso con una muestra mayor antes de descartar definitivamente un cambio en la variabilidad.

Observación 2.11 (Sensibilidad a la normalidad). A diferencia de las pruebas Z y T para la media (que, por el TCL, son razonablemente robustas ante apartamientos moderados de la normalidad cuando n es grande), la prueba χ^2 para la varianza es **muy sensible** al supuesto de normalidad poblacional: si la población tiene curtosis distinta de la normal, la distribución exacta de $(n-1)S^2/\sigma_0^2$ se aparta considerablemente de χ_{n-1}^2 , incluso para n grande. Por esta razón, esta prueba debe usarse con cautela cuando hay evidencia de que la población no es aproximadamente normal.

3. Pruebas para dos muestras

Es habitual comparar dos poblaciones a través de sus medias o de sus varianzas: dos procesos de producción, dos proveedores, un tratamiento frente a un control, mediciones antes y después de una intervención, etc. Antes de elegir el procedimiento adecuado, es imprescindible clasificar correctamente el diseño del estudio en una de las siguientes categorías:

- **Muestras independientes** con varianzas poblacionales **conocidas**.
- **Muestras independientes** con varianzas poblacionales **desconocidas pero supuestas iguales** (se estima una varianza combinada o *pooled*).
- **Muestras apareadas** (o dependientes): cada observación de una muestra está naturalmente asociada a una observación de la otra (mismo individuo medido antes y después, mismo lote medido con dos instrumentos distintos, gemelos, etc.).
- Comparación de las **varianzas** de dos poblaciones (prueba *F*).

Observación 3.1. La pregunta clave del diseño, previa a cualquier cálculo, es: ¿existe una correspondencia natural entre cada observación de una muestra y una de la otra? Ejemplos de diseños **independientes**: dos máquinas distintas, dos proveedores distintos, grupo control vs. grupo tratado con sujetos distintos. Ejemplos de diseños **apareados**: mismo sujeto antes y después de un tratamiento, misma pieza medida por dos instrumentos, unidades emparejadas por algún criterio de similitud. Confundir el diseño lleva a elegir un estadístico incorrecto —típicamente, tratar como independientes datos que en realidad están apareados, lo que produce estimaciones de varianza infladas y pruebas con menor potencia de la que realmente se podría lograr— y, en consecuencia, a conclusiones erróneas.

3.1. Diferencia de medias: varianzas conocidas

Sean $X_1, \dots, X_{n_1}$ una muestra de $N(\mu_1, \sigma_1^2)$ y $Y_1, \dots, Y_{n_2}$ una muestra de $N(\mu_2, \sigma_2^2)$, **independientes** entre sí, con σ_1^2 y σ_2^2 **conocidas**. Se desea probar

$$H_0 : \mu_1 - \mu_2 = \delta_0 \quad (\text{usualmente } \delta_0 = 0).$$

Teorema 3.2. *Bajo H_0 , el estadístico*

$$Z = \frac{(\bar{X} - \bar{Y}) - \delta_0}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

se distribuye $N(0, 1)$.

Demostración. Por independencia de las dos muestras, $\bar{X} \sim N(\mu_1, \sigma_1^2/n_1)$ y $\bar{Y} \sim N(\mu_2, \sigma_2^2/n_2)$ son independientes entre sí, y por lo tanto su diferencia también es normal, con

$$E[\bar{X} - \bar{Y}] = \mu_1 - \mu_2, \quad \text{Var}(\bar{X} - \bar{Y}) = \text{Var}(\bar{X}) + \text{Var}(\bar{Y}) = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}$$

(la suma de varianzas se debe a la independencia, que anula el término de covarianza). Bajo $H_0 : \mu_1 - \mu_2 = \delta_0$, estandarizando $\bar{X} - \bar{Y}$ con esta media y varianza se obtiene exactamente el estadístico $Z \sim N(0, 1)$ enunciado. $\square$

Las regiones críticas son enteramente análogas al caso de una sola media: $|Z| > z_{\alpha/2}$ para $H_1 : \mu_1 - \mu_2 \neq \delta_0$; $Z > z_\alpha$ para $H_1 : \mu_1 - \mu_2 > \delta_0$; $Z < -z_\alpha$ para $H_1 : \mu_1 - \mu_2 < \delta_0$.

Ejemplo 3.3. Dos máquinas envasadoras de un mismo producto tienen desviaciones estándar históricas conocidas $\sigma_1 = 5$ g y $\sigma_2 = 4$ g. Se toman $n_1 = 40$ envases de la máquina 1 ($\bar{x} = 252$

g) y $n_2 = 35$ de la máquina 2 ($\bar{y} = 249$ g). Con $\alpha = 0.05$, ¿difiere el peso medio entregado por ambas máquinas?

1. Hipótesis: $H_0 : \mu_1 - \mu_2 = 0$ vs. $H_1 : \mu_1 - \mu_2 \neq 0$.

2. Región crítica: $|Z| > z_{0.025} = 1.96$.

3. Cálculo:

$$z = \frac{(252 - 249) - 0}{\sqrt{25/40 + 16/35}} = \frac{3}{\sqrt{0.625 + 0.457}} = \frac{3}{\sqrt{1.082}} = \frac{3}{1.040} = 2.88.$$

4. Decisión: $2.88 > 1.96 \Rightarrow$ se rechaza H_0 .

5. Valor p: $p = 2P(Z > 2.88) = 2 \times 0.0020 = 0.0040$, mucho menor que $\alpha = 0.05$ (y también que 0.01): la evidencia en contra de H_0 es muy fuerte.

6. Intervalo de confianza asociado (verificación mediante dualidad): un IC del 95 % para $\mu_1 - \mu_2$ es

$$(\bar{x} - \bar{y}) \pm z_{0.025} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} = 3 \pm 1.96 \times 1.040 = 3 \pm 2.04 = (0.96; 5.04),$$

que no contiene al 0, consistente con el rechazo de $H_0 : \mu_1 - \mu_2 = 0$ de acuerdo con la dualidad prueba-intervalo demostrada en la Sección 1.8.

7. Conclusión: hay evidencia significativa de que el peso medio entregado por ambas máquinas difiere.

3.2. Diferencia de medias: varianzas desconocidas e iguales (pooled)

Cuando σ_1^2 y σ_2^2 son desconocidas, pero resulta razonable suponer que $\sigma_1^2 = \sigma_2^2 = \sigma^2$ (poblaciones normales, muestras independientes), conviene combinar la información de ambas muestras en una única estimación de la varianza común σ^2 , en lugar de estimarla dos veces por separado. Esto se logra mediante la **varianza combinada** o *pooled*.

Definición 3.4 (Varianza combinada).

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}.$$

Propiedad 3.5 (Justificación del estimador combinado). S_p^2 es un promedio ponderado de S_1^2 y S_2^2 , con pesos proporcionales a los respectivos grados de libertad $n_1 - 1$ y $n_2 - 1$, y es un estimador insesgado de σ^2 cuando $\sigma_1^2 = \sigma_2^2 = \sigma^2$.

Demostración. Como $(n_1 - 1)S_1^2/\sigma^2 \sim \chi_{n_1-1}^2$ y $(n_2 - 1)S_2^2/\sigma^2 \sim \chi_{n_2-1}^2$ son independientes (proviene de muestras independientes), su suma se distribuye $\chi_{n_1+n_2-2}^2$ (propiedad aditiva de la χ^2), es decir,

$$\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{\sigma^2} \sim \chi_{n_1+n_2-2}^2.$$

Como la esperanza de una χ_k^2 es k , se obtiene

$$E\left[\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{\sigma^2}\right] = n_1 + n_2 - 2 \implies E[S_p^2] = E\left[\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}\right] = \sigma^2,$$

lo que muestra que S_p^2 es insesgado para σ^2 . Además, de la misma propiedad aditiva se sigue que $\frac{(n_1 + n_2 - 2)S_p^2}{\sigma^2} \sim \chi_{n_1+n_2-2}^2$, resultado que se usa a continuación para derivar la distribución del estadístico de prueba. $\square$

Teorema 3.6 (Estadístico t agrupado). Bajo $H_0 : \mu_1 - \mu_2 = \delta_0$, con $\sigma_1^2 = \sigma_2^2$ desconocida,

$$T = \frac{(\bar{X} - \bar{Y}) - \delta_0}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}.$$

Demostración. Bajo H_0 y el supuesto $\sigma_1^2 = \sigma_2^2 = \sigma^2$, sabemos que $Z = \frac{(\bar{X} - \bar{Y}) - \delta_0}{\sigma \sqrt{1/n_1 + 1/n_2}} \sim N(0, 1)$ (por el mismo argumento que en el caso de varianzas conocidas, con $\sigma_1^2 = \sigma_2^2 = \sigma^2$), y que $W = \frac{(n_1 + n_2 - 2)S_p^2}{\sigma^2} \sim \chi_{n_1+n_2-2}^2$, independiente de Z (pues $\bar{X}, \bar{Y}$ son independientes de S_1^2, S_2^2 dentro de cada muestra, y las dos muestras son independientes entre sí). Aplicando la definición de la t de Student, $T = Z/\sqrt{W/(n_1 + n_2 - 2)}$:

$$T = \frac{\frac{(\bar{X} - \bar{Y}) - \delta_0}{\sigma \sqrt{1/n_1 + 1/n_2}}}{\sqrt{\frac{(n_1 + n_2 - 2)S_p^2/\sigma^2}{n_1 + n_2 - 2}}} = \frac{(\bar{X} - \bar{Y}) - \delta_0}{S_p/\sigma} = \frac{(\bar{X} - \bar{Y}) - \delta_0}{S_p \sqrt{1/n_1 + 1/n_2}},$$

donde nuevamente σ se cancela, quedando el estadístico enunciado, distribuido $t_{n_1+n_2-2}$. $\square$

Las regiones críticas son análogas a las del caso de varianzas conocidas, reemplazando z_γ por $t_{n_1+n_2-2, \gamma}$.

Ejemplo 3.7. Se compara la resistencia a la rotura (en kg) de cables de dos proveedores, suponiendo varianzas poblacionales iguales. Proveedor A: $n_1 = 12$, $\bar{x} = 436$, $s_1^2 = 98$. Proveedor B: $n_2 = 10$, $\bar{y} = 428$, $s_2^2 = 110$. Con $\alpha = 0.05$, ¿el proveedor A ofrece mayor resistencia media?

1. Hipótesis: $H_0 : \mu_1 - \mu_2 \leq 0$ vs. $H_1 : \mu_1 - \mu_2 > 0$.

2. Varianza combinada:

$$S_p^2 = \frac{11(98) + 9(110)}{20} = \frac{1078 + 990}{20} = \frac{2068}{20} = 103.4, \quad S_p = 10.17.$$

3. Región crítica ($gl = 20$): $T > t_{20, 0.05} = 1.725$.

4. Cálculo:

$$t = \frac{(436 - 428) - 0}{10.17 \sqrt{\frac{1}{12} + \frac{1}{10}}} = \frac{8}{10.17 \times 0.4282} = \frac{8}{4.354} = 1.84.$$

5. Decisión: $1.84 > 1.725 \Rightarrow$ se rechaza H_0 .

6. Valor p: de tablas de t_{20} , $t_{20, 0.05} = 1.725$ y $t_{20, 0.025} = 2.086$; como $1.725 < 1.84 < 2.086$, el valor p está entre 0.025 y 0.05 (aproximadamente $p \approx 0.040$), consistente con el rechazo.

7. Conclusión: con un 5% de significación, hay evidencia de que el proveedor A entrega cables con mayor resistencia media.

Observación 3.8 (Criterio para decidir entre varianzas iguales o distintas; mención de Welch). Cuando las varianzas poblacionales son desconocidas, la validez del estadístico t agrupado depende críticamente del supuesto $\sigma_1^2 = \sigma_2^2$. Como criterio práctico, este supuesto puede evaluarse formalmente mediante la prueba F de igualdad de varianzas que se desarrolla en la subsección siguiente; una regla informal frecuentemente usada es que si el cociente entre la mayor y la menor varianza muestral no supera aproximadamente 3 ó 4 (y los tamaños muestrales son similares), el estadístico agrupado suele comportarse razonablemente bien incluso ante apartamientos moderados del supuesto de igualdad.

Cuando las varianzas poblacionales son desconocidas y **no** resulta razonable suponerlas iguales, el estadístico t agrupado deja de tener la distribución $t_{n_1+n_2-2}$ exacta y puede producir

un nivel de significación real distinto del nominal, especialmente si los tamaños de muestra n_1 y n_2 son muy distintos. Para esa situación existe una extensión clásica, la **aproximación de Welch–Satterthwaite**, que utiliza el estadístico

$$T' = \frac{(\bar{X} - \bar{Y}) - \delta_0}{\sqrt{S_1^2/n_1 + S_2^2/n_2}},$$

cuya distribución bajo H_0 se aproxima por una t con grados de libertad *ajustados* (no enteros, en general) dados por la fórmula de Satterthwaite

$$\nu \approx \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1 - 1} + \frac{(S_2^2/n_2)^2}{n_2 - 1}}.$$

El desarrollo completo de esta corrección excede el alcance de este curso; en esta materia se trabaja siempre bajo el supuesto de varianzas desconocidas pero **iguales** cuando corresponde usar una prueba t para dos muestras independientes, contrastando previamente ese supuesto con la prueba F cuando resulte pertinente.

3.3. Muestras apareadas

Cuando las dos muestras **no son independientes** —porque provienen de una correspondencia natural entre observaciones (mismo sujeto medido dos veces, mismo elemento evaluado por dos métodos, pares naturalmente asociados)—, no corresponde aplicar ninguno de los procedimientos anteriores. La estrategia adecuada consiste en trabajar con las **diferencias individuales**

$$D_i = X_i - Y_i, \quad i = 1, \dots, n,$$

reduciendo el problema de comparación de dos medias a una prueba de una sola media (la de las diferencias), aplicada sobre la Sección 2.

Propiedad 3.9. Si $D_1, \dots, D_n$ son aproximadamente $N(\mu_D, \sigma_D^2)$ con σ_D^2 desconocida, entonces bajo $H_0 : \mu_D = \delta_0$ (usualmente $\delta_0 = 0$, es decir, $H_0 : \mu_1 = \mu_2$),

$$T = \frac{\bar{D} - \delta_0}{S_D/\sqrt{n}} \stackrel{H_0}{\sim} t_{n-1},$$

donde $\bar{D}$ y S_D son, respectivamente, la media y el desvío muestral de las diferencias $D_1, \dots, D_n$.

Esto es una consecuencia inmediata del resultado ya demostrado para la prueba t de una media: basta reemplazar la muestra original por la muestra (univariada) de diferencias D_i .

Observación 3.10 (Por qué conviene trabajar con las diferencias). Al trabajar con las diferencias, cada unidad experimental actúa como su propio control, y se elimina de la comparación toda la variabilidad debida a diferencias *entre* unidades (por ejemplo, diferencias basales entre sujetos que nada tienen que ver con el efecto del tratamiento que se quiere detectar). Formalmente, si X_i e Y_i están correlacionadas positivamente (lo cual es típico cuando provienen del mismo sujeto o unidad), entonces

$$\text{Var}(D_i) = \text{Var}(X_i - Y_i) = \sigma_1^2 + \sigma_2^2 - 2 \text{Cov}(X_i, Y_i) < \sigma_1^2 + \sigma_2^2,$$

que es precisamente la varianza que se usaría (erróneamente) si se tratara a las muestras como independientes ignorando el apareamiento. Es decir, ignorar una correlación positiva entre pares infla artificialmente la estimación de la varianza de la diferencia de medias, lo que reduce la potencia de la prueba. El análisis apareado, al usar $\text{Var}(D_i)$ directamente (más chica cuando la correlación es positiva), suele ser considerablemente más potente que tratar las muestras —incorrectamente— como independientes.

Ejemplo 3.11. Se evalúa un programa de entrenamiento midiendo el tiempo (en segundos) que tardan 8 operarios en completar una tarea, antes y después del entrenamiento:

Operario	1	2	3	4	5	6	7	8
Antes	25	28	22	30	27	24	26	29
Después	23	24	22	27	25	24	22	25
Diferencia d_i	2	4	0	3	2	0	4	4

Se obtiene $\bar{d} = 2.375$ y $s_D = 1.685$. Con $\alpha = 0.05$, ¿el entrenamiento reduce el tiempo medio de ejecución?

Hipótesis: $H_0 : \mu_D \leq 0$ vs. $H_1 : \mu_D > 0$ (con $D = \text{Antes} - \text{Después}$; si el entrenamiento reduce el tiempo, D debería ser positivo en promedio).

Región crítica ($gl=7$): $T > t_{7,0.05} = 1.895$.

Cálculo: $t = \frac{2.375 - 0}{1.685/\sqrt{8}} = \frac{2.375}{0.5958} = 3.99$.

Valor p: de tablas de t_7 , $t_{7,0.005} = 3.499$; como $3.99 > 3.499$, $p < 0.005$, muy por debajo de $\alpha = 0.05$.

Decisión y conclusión: $3.99 > 1.895 \Rightarrow$ se rechaza H_0 : el entrenamiento reduce significativamente el tiempo medio de ejecución.

3.4. Igualdad de dos varianzas: prueba F de Snedecor

Sean $X_1, \dots, X_{n_1} \sim N(\mu_1, \sigma_1^2)$ y $Y_1, \dots, Y_{n_2} \sim N(\mu_2, \sigma_2^2)$ muestras independientes. Se desea probar

$$H_0 : \sigma_1^2 = \sigma_2^2.$$

Esta prueba es importante no solo por sí misma (comparar variabilidades es, muchas veces, la pregunta sustantiva del problema), sino porque, como se mencionó, es el criterio formal para decidir si es razonable aplicar el estadístico t agrupado de la subsección anterior.

Teorema 3.12. Bajo H_0 , el estadístico

$$F = \frac{S_1^2}{S_2^2}$$

se distribuye según una F de Snedecor con $n_1 - 1$ grados de libertad en el numerador y $n_2 - 1$ en el denominador, F_{n_1-1, n_2-1} .

Demostración. Recordemos que la distribución F con k_1 y k_2 grados de libertad se define como el cociente de dos variables χ^2 independientes, cada una dividida por sus grados de libertad: si $W_1 \sim \chi_{k_1}^2$ y $W_2 \sim \chi_{k_2}^2$ son independientes, entonces $\frac{W_1/k_1}{W_2/k_2} \sim F_{k_1, k_2}$.

Sabemos que $(n_1-1)S_1^2/\sigma_1^2 \sim \chi_{n_1-1}^2$ y $(n_2-1)S_2^2/\sigma_2^2 \sim \chi_{n_2-1}^2$, y que ambas son independientes (proviene de muestras independientes). Aplicando la definición con $W_1 = (n_1 - 1)S_1^2/\sigma_1^2$, $k_1 = n_1 - 1$, $W_2 = (n_2 - 1)S_2^2/\sigma_2^2$, $k_2 = n_2 - 1$:

$$\frac{W_1/k_1}{W_2/k_2} = \frac{\left(\frac{(n_1 - 1)S_1^2/\sigma_1^2}{n_1 - 1} \right)}{\left(\frac{(n_2 - 1)S_2^2/\sigma_2^2}{n_2 - 1} \right)} = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} = \frac{S_1^2}{S_2^2} \cdot \frac{\sigma_2^2}{\sigma_1^2} \sim F_{n_1-1, n_2-1}.$$


Bajo $H_0 : \sigma_1^2 = \sigma_2^2$, el factor $\sigma_2^2/\sigma_1^2 = 1$, de modo que $F = S_1^2/S_2^2 \sim F_{n_1-1, n_2-1}$, como se quería demostrar. $\square$

H_1	Región crítica
$\sigma_1^2 \neq \sigma_2^2$	$F < F_{n_1-1, n_2-1, 1-\alpha/2}$ o $F > F_{n_1-1, n_2-1, \alpha/2}$
$\sigma_1^2 > \sigma_2^2$	$F > F_{n_1-1, n_2-1, \alpha}$

Observación 3.13 (Convención práctica y relación con las tablas). Las tablas usuales de la distribución F solo tabulan cuantiles en la cola superior (γ pequeño). Para obtener cuantiles de la cola inferior se utiliza la identidad

$$F_{k_1, k_2, 1-\gamma} = \frac{1}{F_{k_2, k_1, \gamma}},$$

que se deduce de que si $F \sim F_{k_1, k_2}$, entonces $1/F \sim F_{k_2, k_1}$ (basta invertir el cociente de las dos χ^2 normalizadas en la definición). Por esta razón, en la práctica —y en particular para el caso bilateral—, es usual colocar en el numerador la muestra con mayor varianza muestral, de modo que el estadístico calculado resulte $F \geq 1$, y compararlo únicamente con el valor crítico superior $F_{n_1-1, n_2-1, \alpha/2}$ (con los grados de libertad correspondientes a la muestra que efectivamente se colocó en el numerador), evitando así tener que buscar cuantiles de cola inferior.



Ejemplo 3.14. Un nuevo instrumento de medición se propone como más preciso (menor variabilidad) que el instrumento estándar. Instrumento estándar: $n_1 = 16$, $s_1^2 = 2.8$. Instrumento nuevo: $n_2 = 13$, $s_2^2 = 1.1$. Con $\alpha = 0.05$, ¿hay evidencia de que el nuevo instrumento es más preciso?

1. **Hipótesis:** $H_0 : \sigma_1^2 \leq \sigma_2^2$ vs. $H_1 : \sigma_1^2 > \sigma_2^2$ (equivalente a trabajar con $H_0 : \sigma_1^2 = \sigma_2^2$).

2. **Estadístico:** $F = \frac{S_1^2}{S_2^2} \stackrel{H_0}{\sim} F_{15,12}$.

3. **Región crítica:** $F > F_{15,12,0.05} = 2.62$.

4. **Cálculo:** $F = \frac{2.8}{1.1} = 2.55$.

5. **Decisión:** $2.55 < 2.62 \Rightarrow$ no se rechaza H_0 .

6. **Conclusión:** al 5 %, no hay evidencia estadísticamente suficiente de que el nuevo instrumento sea más preciso, aunque el resultado es sugestivo (muy cercano al valor crítico) y amerita ampliar la muestra antes de descartar la mejora.

Ejemplo 3.15 (Caso bilateral). Se comparan dos líneas de producción respecto de la variabilidad en el diámetro (mm) de una pieza. Línea A: $n_1 = 13$, $s_1^2 = 0.048$. Línea B: $n_2 = 10$, $s_2^2 = 0.019$. Con $\alpha = 0.10$, ¿hay evidencia de que las variabilidades difieren?

1. **Hipótesis:** $H_0 : \sigma_1^2 = \sigma_2^2$ vs. $H_1 : \sigma_1^2 \neq \sigma_2^2$.

2. **Estadístico** (numerador = mayor varianza muestral, según la convención práctica): $F = \frac{S_1^2}{S_2^2} \stackrel{H_0}{\sim} F_{12,9}$.

3. **Región crítica:** $F > F_{12,9,0.05} = 3.07$.

4. Cálculo:

$$F = \frac{0.048}{0.019} = 2.53.$$

5. Decisión: $2.53 < 3.07 \Rightarrow$ no se rechaza H_0 .

6. Conclusión: al nivel 10 %, no hay evidencia suficiente de que las variabilidades de ambas líneas difieran, por lo cual, de ser necesario, sería razonable aplicar el estadístico t agrupado (pooled) para comparar las medias de ambas líneas.

4. Pruebas chi-cuadrado: bondad de ajuste, independencia y homogeneidad


Las pruebas desarrolladas en las secciones anteriores se aplican a parámetros de variables cuantitativas (medias, varianzas). En esta sección estudiamos una familia distinta de pruebas, basada en la comparación de **frecuencias observadas** contra **frecuencias esperadas** bajo una hipótesis nula, aplicables fundamentalmente a datos categóricos (de conteo). Las tres pruebas que veremos —bondad de ajuste, independencia y homogeneidad— comparten el mismo tipo de estadístico, propuesto originalmente por Karl Pearson.

Definición 4.1 (Estadístico χ^2 de Pearson).

$$\chi^2 = \sum_i \frac{(O_i - E_i)^2}{E_i},$$

donde O_i son las frecuencias **observadas** y E_i las frecuencias **esperadas** bajo H_0 , en cada una de las categorías o celdas consideradas.

Intuitivamente, cada término $(O_i - E_i)^2/E_i$ mide, en una escala relativa al tamaño esperado, cuánto se aparta la frecuencia observada en la categoría i de la que predice H_0 ; la división por E_i evita que las categorías con mayor frecuencia esperada dominen artificialmente la suma solo por tener un valor absoluto de discrepancia más grande. Cuando H_0 es verdadera, cada término tiende a ser pequeño (en un sentido probabilístico preciso); cuando H_0 es falsa, algunas frecuencias observadas se apartan sistemáticamente de las esperadas y el estadístico tiende a tomar valores grandes. Por esta razón, en las tres pruebas de esta sección la región crítica está **siempre en la cola derecha**: valores grandes de χ^2 (mucha discrepancia) llevan a rechazar H_0 ; valores pequeños de χ^2 (buen ajuste entre lo observado y lo esperado) son compatibles con H_0 .



La justificación teórica de por qué este estadístico se distribuye aproximadamente χ^2 bajo H_0 proviene de un resultado asintótico: cada frecuencia observada O_i puede pensarse como una suma de indicadores independientes, de modo que, por el Teorema Central del Límite (multivariado), el vector de frecuencias observadas se aproxima a una distribución normal multivariada, y el estadístico de Pearson resulta ser, asintóticamente, una forma cuadrática de esas variables normales que se distribuye χ^2 con tantos grados de libertad como dimensiones libres tenga el problema (el número de categorías menos el número de restricciones impuestas, entre ellas la de que las frecuencias esperadas sumen n , y menos los parámetros estimados a partir de los datos).

4.1. Prueba de bondad de ajuste

Se dispone de n observaciones clasificadas en k categorías mutuamente excluyentes y exhaustivas, con frecuencias observadas $O_1, \dots, O_k$ (con $\sum_i O_i = n$). Se desea comprobar si los datos son

compatibles con una distribución teórica que asigna probabilidades $p_1, \dots, p_k$ a cada categoría ($\sum_i p_i = 1$):

$$H_0 : P(\text{categoría } i) = p_i, i = 1, \dots, k \quad \text{vs.} \quad H_1 : \text{para algún } i, P(\text{categoría } i) \neq p_i.$$

Bajo H_0 , la frecuencia **esperada** en la categoría i es $E_i = n p_i$ (el número medio de observaciones que caerían en esa categoría si H_0 fuera cierta), y el estadístico de prueba es

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \stackrel{H_0}{\approx} \chi_{k-1-m}^2,$$

donde m es la cantidad de parámetros de la distribución teórica que debieron **estimarse** a partir de la propia muestra (si la distribución está completamente especificada de antemano, sin parámetros libres, $m = 0$).

Observación 4.2 (Por qué se pierden grados de libertad al estimar parámetros). Los grados de libertad de referencia son $k-1$ (y no k) porque las frecuencias esperadas $E_i = n p_i$ están sujetas a la restricción $\sum_i E_i = n = \sum_i O_i$: solo $k-1$ de las k discrepancias $(O_i - E_i)$ son libres, la última queda determinada por las demás. Cuando, además, algún parámetro de la distribución teórica (por ejemplo, la media λ de una Poisson, o la media y varianza de una normal) debe **estimarse** a partir de los mismos datos $O_1, \dots, O_k$ que se están usando para calcular el estadístico, se introduce una restricción adicional por cada parámetro estimado: intuitivamente, los valores estimados "se ajustan" a los datos observados, acercando artificialmente las frecuencias esperadas a las observadas y reduciendo la discrepancia esperable bajo H_0 . Este efecto se compensa restando un grado de libertad adicional por cada parámetro estimado, lo que da la fórmula general $k-1-m$.

Observación 4.3 (Condición de aplicación). La aproximación de la distribución exacta (discreta) del estadístico χ^2 de Pearson por la distribución continua χ_{k-1-m}^2 es adecuada únicamente cuando las frecuencias esperadas no son demasiado pequeñas. El criterio usual —muchas veces llamado **condición de Cochran**— exige

$E_i \geq 5$ para todas las categorías (o, en versiones más flexibles, para al menos el 80 % de ellas, sin ninguna categoría con $E_i < 1$).

Si alguna E_i no cumple esta condición, se recomienda **agrupar** categorías contiguas (o categorías con sentido similar) hasta satisfacerla, teniendo en cuenta que esto reduce en consecuencia el número efectivo de categorías k y, por lo tanto, los grados de libertad de la prueba.

Ejemplo 4.4 (Distribución completamente especificada, $m = 0$). Se lanza un dado 120 veces para verificar si está equilibrado. Frecuencias observadas:

Cara	1	2	3	4	5	6
O_i	25	17	15	23	24	16

Con $\alpha = 0.05$, pruebe si el dado es equilibrado.

1. Hipótesis: $H_0 : p_i = 1/6 \forall i$ vs. $H_1 : \text{algún } p_i \neq 1/6$.

2. Frecuencias esperadas: $E_i = 120 \times \frac{1}{6} = 20$ para todo i (todas ≥ 5 : se cumple la condición de Cochran).

3. Grados de libertad: $k = 6, m = 0 \Rightarrow \text{gl} = 5$.

4. Región crítica: $\chi^2 > \chi_{5,0.05}^2 = 11.07$.

5. Cálculo:

$$\chi^2 = \frac{5^2}{20} + \frac{3^2}{20} + \frac{5^2}{20} + \frac{3^2}{20} + \frac{4^2}{20} + \frac{4^2}{20} = \frac{25 + 9 + 25 + 9 + 16 + 16}{20} = \frac{100}{20} = 5.0.$$

6. Decisión y conclusión: $5.0 < 11.07 \Rightarrow$ no se rechaza H_0 ; no hay evidencia de que el dado esté desequilibrado. (De tablas de χ_5^2 , $\chi_{5,0.50}^2 \approx 4.35$, de modo que el valor p es algo mayor que 0.50: la discrepancia observada es incluso menor que la típica bajo H_0 .)

Ejemplo 4.5 (Distribución con parámetro estimado, $m = 1$). Se registra el número de defectos por unidad en 200 piezas, y se desea comprobar si sigue una distribución de Poisson (la media λ debe estimarse de los datos: $\hat{\lambda} = 1.5$).

N° defectos	0	1	2	3	≥ 4
O_i	48	65	48	26	13
p_i (Poisson, $\hat{\lambda} = 1.5$)	0.223	0.335	0.251	0.126	0.065
$E_i = 200 p_i$	44.6	67.0	50.2	25.2	13.0

Con $\alpha = 0.05$: $gl = k - 1 - m = 5 - 1 - 1 = 3$ (se estimó λ , por lo que $m = 1$).

Región crítica: $\chi^2 > \chi_{3,0.05}^2 = 7.815$.

Cálculo:

$$\chi^2 = \frac{(48 - 44.6)^2}{44.6} + \frac{(65 - 67.0)^2}{67.0} + \frac{(48 - 50.2)^2}{50.2} + \frac{(26 - 25.2)^2}{25.2} + \frac{(13 - 13.0)^2}{13.0}$$

$$\approx 0.259 + 0.060 + 0.096 + 0.025 + 0.000 = 0.44.$$

Decisión: $0.44 < 7.815 \Rightarrow$ no se rechaza H_0 : el ajuste a la distribución de Poisson es adecuado. El valor p es muy alto (bastante mayor que 0.90), consistente con un ajuste casi perfecto entre lo observado y lo esperado.

4.2. Prueba de independencia en tablas de contingencia

Se clasifica una muestra de n individuos simultáneamente según **dos variables categóricas**, A (con r categorías) y B (con c categorías), formando una tabla de contingencia de $r \times c$ celdas con frecuencias observadas O_{ij} , $i = 1, \dots, r$, $j = 1, \dots, c$. Denotamos $O_{i\bullet} = \sum_j O_{ij}$ el total de la fila i y $O_{\bullet j} = \sum_i O_{ij}$ el total de la columna j , con $\sum_i O_{i\bullet} = \sum_j O_{\bullet j} = n$.

$$H_0 : A \text{ y } B \text{ son independientes} \quad \text{vs.} \quad H_1 : A \text{ y } B \text{ no son independientes.}$$

Teorema 4.6 (Frecuencias esperadas bajo independencia). *Bajo el supuesto de independencia entre A y B , la frecuencia esperada en la celda (i, j) es*

$$E_{ij} = \frac{O_{i\bullet} \cdot O_{\bullet j}}{n}.$$

Demostración. Sean $p_{i\bullet} = P(A = i)$ y $p_{\bullet j} = P(B = j)$ las probabilidades marginales (desconocidas) de cada categoría. Si A y B son independientes, la probabilidad conjunta de la celda (i, j) es $p_{ij} = p_{i\bullet} \cdot p_{\bullet j}$ (definición de independencia de eventos), y la frecuencia esperada en esa celda, sobre n observaciones, es $E_{ij} = n p_{ij} = n p_{i\bullet} p_{\bullet j}$.

Como las probabilidades marginales $p_{i\bullet}$ y $p_{\bullet j}$ son desconocidas, se estiman naturalmente por sus proporciones muestrales, $\hat{p}_{i\bullet} = O_{i\bullet}/n$ y $\hat{p}_{\bullet j} = O_{\bullet j}/n$ (estimadores de máxima verosimilitud de las marginales). Sustituyendo estas estimaciones en la expresión de E_{ij} :

$$\hat{E}_{ij} = n \cdot \frac{O_{i\bullet}}{n} \cdot \frac{O_{\bullet j}}{n} = \frac{O_{i\bullet} \cdot O_{\bullet j}}{n},$$

que es la fórmula enunciada. □

El estadístico de prueba es

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \stackrel{H_0}{\approx} \chi_{(r-1)(c-1)}^2.$$

Observación 4.7 (Grados de libertad). Los $(r - 1)(c - 1)$ grados de libertad se explican de la siguiente manera: la tabla tiene rc celdas, pero las frecuencias esperadas E_{ij} se calculan a partir de las $r + c - 1$ marginales estimadas de la muestra (los r totales de fila y los c totales de columna, que suman una restricción menos porque ambos conjuntos de totales deben sumar n). Restando estas restricciones —y compensando adecuadamente la doble estimación—, el número de celdas cuya discrepancia $(O_{ij} - E_{ij})$ es efectivamente libre resulta $rc - (r - 1) - (c - 1) - 1 = (r - 1)(c - 1)$.

Ejemplo 4.8. Se estudia si el ausentismo laboral es independiente del turno de trabajo, sobre 300 empleados:

	Mañana	Tarde	Noche	Total
Con ausentismo	18	22	35	75
Sin ausentismo	82	78	65	225
Total	100	100	100	300

Con $\alpha = 0.05$, ¿el ausentismo depende del turno?

- 1. Hipótesis:** H_0 : ausentismo y turno son independientes vs. H_1 : no lo son.
- 2. Frecuencias esperadas** ($E_{ij} = O_{i\bullet}O_{\bullet j}/300$):

$$E_{11} = \frac{75 \times 100}{300} = 25, \quad E_{12} = 25, \quad E_{13} = 25, \quad E_{21} = 75, \quad E_{22} = 75, \quad E_{23} = 75.$$

Todas las frecuencias esperadas superan 5: se cumple la condición de Cochran.

- 3. Grados de libertad:** $(r - 1)(c - 1) = (2 - 1)(3 - 1) = 2$.
- 4. Región crítica:** $\chi^2 > \chi^2_{2,0.05} = 5.991$.
- 5. Cálculo:**

$$\begin{aligned} \chi^2 &= \frac{(18 - 25)^2}{25} + \frac{(22 - 25)^2}{25} + \frac{(35 - 25)^2}{25} + \frac{(82 - 75)^2}{75} + \frac{(78 - 75)^2}{75} + \frac{(65 - 75)^2}{75} \\ &= \frac{49}{25} + \frac{9}{25} + \frac{100}{25} + \frac{49}{75} + \frac{9}{75} + \frac{100}{75} = 1.96 + 0.36 + 4.00 + 0.653 + 0.12 + 1.333 = 8.43. \end{aligned}$$

- 6. Decisión:** $8.43 > 5.991 \Rightarrow$ se rechaza H_0 .

7. Valor p: de tablas de χ^2_2 , $\chi^2_{2,0.025} = 7.378$ y $\chi^2_{2,0.01} = 9.210$; como $7.378 < 8.43 < 9.210$, el valor p está entre 0.01 y 0.025.

8. Conclusión: al 5% de significación, hay evidencia de que el ausentismo **no** es independiente del turno de trabajo; el turno noche muestra un ausentismo notablemente mayor que el esperado bajo independencia.

4.3. Prueba de homogeneidad

Se toman muestras **independientes** de r poblaciones distintas, con tamaños fijados de antemano por el diseño del muestreo, y se clasifica cada observación según una variable categórica común con c categorías. Se desea probar si las r poblaciones tienen la **misma distribución** respecto de esa variable:

H_0 : las r poblaciones tienen la misma distribución en la variable categórica,

H_1 : al menos una población difiere de las demás.

Observación 4.9 (Diferencia conceptual con la prueba de independencia). La distinción entre independencia y homogeneidad es puramente de **diseño de muestreo**, no de cálculo. En la prueba de **independencia**, se extrae **una única muestra aleatoria** de n individuos de una población, y se los clasifica *a posteriori* según dos variables categóricas; en ese caso, tanto los totales de fila como los de columna son cantidades **aleatorias**, resultado del muestreo. En la

prueba de **homogeneidad**, en cambio, se extraen r muestras **independientes**, una de cada población, con tamaños (los totales de fila, o de columna, según cómo se organice la tabla) **fijados de antemano** por el investigador, y la variable de clasificación es una sola (la que define las columnas).

A pesar de esta diferencia conceptual en el mecanismo de generación de los datos, el desarrollo matemático —frecuencias esperadas $E_{ij} = O_{i\bullet}O_{\bullet j}/n$, estadístico $\chi^2 = \sum (O_{ij} - E_{ij})^2/E_{ij}$, y grados de libertad $(r-1)(c-1)$ — resulta **formalmente idéntico** al de la prueba de independencia. La razón profunda es que, condicionalmente a los totales marginales observados, la distribución del estadístico bajo ambas hipótesis nulas (independencia, homogeneidad) coincide.

Ejemplo 4.10. Se extraen muestras de 150 piezas de cada uno de tres proveedores y se clasifican según su calidad:

	Proveedor A	Proveedor B	Proveedor C	Total
Primera calidad	120	108	96	324
Segunda calidad	30	42	54	126
Total	150	150	150	450

Con $\alpha = 0.01$, ¿los tres proveedores son homogéneos respecto de la calidad entregada?

1. Hipótesis: H_0 : los tres proveedores tienen igual distribución de calidad vs. H_1 : al menos uno difiere.

2. Frecuencias esperadas: $E_{1j} = \frac{324 \times 150}{450} = 108$ para cada proveedor (primera calidad);
 $E_{2j} = \frac{126 \times 150}{450} = 42$ (segunda calidad). Todas superan 5: se cumple la condición de Cochran.

3. Grados de libertad: $(r-1)(c-1) = (2-1)(3-1) = 2$.

4. Región crítica: $\chi^2 > \chi_{2,0.01}^2 = 9.210$.

5. Cálculo:

$$\begin{aligned}\chi^2 &= \frac{(120-108)^2}{108} + \frac{(108-108)^2}{108} + \frac{(96-108)^2}{108} + \frac{(30-42)^2}{42} + \frac{(42-42)^2}{42} + \frac{(54-42)^2}{42} \\ &= \frac{144}{108} + 0 + \frac{144}{108} + \frac{144}{42} + 0 + \frac{144}{42} = 1.333 + 1.333 + 3.429 + 3.429 = 9.52.\end{aligned}$$

6. Decisión: $9.52 > 9.210 \Rightarrow$ se rechaza H_0 .

7. Valor p: de tablas de χ_2^2 , $\chi_{2,0.01}^2 = 9.210$ y $\chi_{2,0.005}^2 = 10.60$; como $9.210 < 9.52 < 10.60$, el valor p está entre 0.005 y 0.01.

8. Conclusión: al 1% de significación, hay evidencia de que los tres proveedores no son homogéneos en la calidad de las piezas entregadas; el proveedor C presenta una proporción de segunda calidad notablemente mayor que la esperada bajo homogeneidad.

4.4. Comparación de las tres pruebas y condiciones de aplicación

Pese a responder preguntas conceptualmente distintas, las pruebas de independencia y homogeneidad comparten exactamente el mismo cálculo. Además, todas las pruebas χ^2 desarrolladas en esta sección están sujetas a las mismas condiciones generales de aplicación:

- Las observaciones deben ser **independientes** entre sí.
- Cada individuo u observación debe clasificarse en **una y solo una** categoría o celda (categorías mutuamente excluyentes y exhaustivas).
- Las frecuencias esperadas deben ser suficientemente grandes para que la aproximación por la distribución continua χ^2 sea adecuada: la **condición de Cochran** exige $E_i \geq 5$ (o $E_{ij} \geq 5$ en tablas de contingencia) en todas las celdas, admitiéndose en versiones más flexibles hasta un 20% de celdas con E_i entre 1 y 5, siempre que ninguna celda tenga $E_i < 1$.

Prueba	Diseño de muestreo	Pregunta que responde
Bondad de ajuste	una muestra, una variable categórica	¿la variable sigue una distribución teórica dada?
Independencia	una muestra, dos variables categóricas (ambos totales marginales aleatorios)	¿las dos variables están relacionadas?
Homogeneidad	varias muestras independientes (una por población, tamaños fijados de antemano), una variable categórica	¿las poblaciones tienen la misma distribución?

Cuadro 2: Comparación de las tres pruebas basadas en el estadístico de Pearson.

- Si la condición no se cumple, se deben **agrupar** categorías o filas/columnas adyacentes (con sentido sustantivo) hasta satisfacerla, lo cual reduce en consecuencia los grados de libertad de la prueba.
- En las tres pruebas, el estadístico de Pearson conduce siempre a una región crítica de **cola derecha**: valores grandes de χ^2 indican una discrepancia importante entre lo observado y lo esperado bajo H_0 , y por lo tanto evidencia en contra de H_0 .

5. Observaciones adicionales

A modo de cierre, conviene situar el contenido de esta unidad dentro del panorama más amplio de la inferencia estadística, y anticipar su conexión con la Unidad 8.

- **Unificación conceptual.** A lo largo de esta unidad vimos una variedad de estadísticos de prueba — Z , T , χ^2 , F — aplicados a distintos parámetros y situaciones. Es importante no perder de vista que, detrás de esa aparente diversidad, subyace siempre la misma estructura lógica: un estadístico cuya distribución bajo H_0 es conocida (exacta o aproximadamente), una región crítica determinada por α y por el sentido de H_1 , y una decisión basada en comparar lo observado con lo esperado bajo H_0 , ya sea mediante el estadístico o mediante el valor p .
- **Relación con la estimación.** La dualidad entre pruebas de hipótesis e intervalos de confianza, demostrada en la Sección 1, no es una curiosidad aislada: refleja que estimación y prueba de hipótesis son, en el fondo, dos maneras de resumir la misma información muestral (a través del mismo estadístico pivotal) para responder preguntas distintas —"¿cuál es el rango plausible de θ ?" versus "¿es θ igual a un valor específico?"—.
- **Hacia la Unidad 8: el modelo de regresión lineal.** En la Unidad 8 se introduce el modelo de regresión lineal simple, $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, con $\varepsilon_i \sim N(0, \sigma^2)$ independientes. Bajo este modelo, los estimadores de mínimos cuadrados $\hat{\beta}_0$ y $\hat{\beta}_1$ resultan ser combinaciones lineales de las observaciones Y_i , y por lo tanto normales; esto permite construir, exactamente con la misma lógica que la prueba t para una media desarrollada en la Sección 2, estadísticos de la forma

$$T = \frac{\hat{\beta}_1 - \beta_{1,0}}{S_{\hat{\beta}_1}} \sim t_{n-2}$$

para probar hipótesis sobre la pendiente poblacional (típicamente $H_0 : \beta_1 = 0$, es decir, ausencia de relación lineal entre x e y). La construcción de este estadístico —numerador que mide un apartamiento respecto de un valor de referencia, denominador que estima el error estándar correspondiente, cociente que resulta t de Student— es exactamente la misma estructura que la prueba t para una media vista en este apunte, aplicada ahora a un parámetro de un modelo más complejo.

- **Hacia la Unidad 8: el análisis de varianza (ANOVA).** La prueba F de Snedecor, introducida en la Sección 3 para comparar dos varianzas, reaparece en la Unidad 8 en un contexto distinto pero estrechamente emparentado: el análisis de varianza de un factor (ANOVA), utilizado para comparar las medias de **más de dos** poblaciones simultáneamente (una generalización natural de la comparación de dos medias vista en la Sección 3 de este apunte). La idea del ANOVA es descomponer la variabilidad total de los datos en una componente **entre grupos** y una componente **dentro de los grupos**, y comparar ambas mediante un cociente de varianzas —formalmente análogo al estadístico $F = S_1^2/S_2^2$ ya estudiado— que se distribuye F bajo la hipótesis nula de igualdad de todas las medias poblacionales. Es decir, el mismo estadístico F que aquí usamos para contrastar variabilidades se reutiliza, con una interpretación distinta de "numerador" y "denominador", para contrastar medias de múltiples grupos.
- **Una perspectiva unificadora.** Tanto la regresión como el ANOVA pueden presentarse como *modelos lineales*, y las pruebas de hipótesis asociadas a sus parámetros (pendientes, medias de grupo) no son más que aplicaciones —más elaboradas, pero conceptualmente idénticas— del marco de prueba de hipótesis desarrollado íntegramente en esta unidad: formular H_0 y H_1 , elegir un estadístico con distribución conocida bajo H_0 , determinar la región crítica o el valor p , y decidir. Dominar en profundidad los conceptos de esta Unidad 7 —en particular, la lógica de los errores tipo I y II, la construcción de estadísticos a partir de pivotes normales y χ^2 , y la interpretación correcta del valor p — es, por lo tanto, el requisito indispensable para abordar con solidez los modelos más ricos que se estudian en

la Unidad 8.