

Práctica 1: Regresión lineal simple

Unidad 8: Modelos lineales

Probabilidad y Estadística (5765)

Universidad Nacional del Sur

Ejercicio 1. En un proceso de secado industrial, se registran la **temperatura del horno** X (en °C) y el **contenido de humedad residual** Y (en %) de la lámina de papel a la salida, sobre $n = 8$ lotes:

x_i (°C)	60	65	70	75	80	85	90	95
y_i (%)	14.8	13.9	12.7	11.5	10.9	9.0	8.4	6.2

- (a) Ajuste la recta de mínimos cuadrados $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$.
- (b) Calcule el coeficiente de determinación R^2 e interprételo.
- (c) Interprete el signo y la magnitud de $\hat{\beta}_1$ en el contexto del problema.

Solución. Con $n = 8$: $\sum x_i = 620$, $\bar{x} = 77.5$; $\sum y_i = 87.4$, $\bar{y} = 10.925$; $\sum x_i^2 = 49100$; $\sum y_i^2 = 1014.6$; $\sum x_i y_i = 6525.0$.

$$S_{xx} = \sum x_i^2 - n\bar{x}^2 = 49100 - 8(77.5)^2 = 49100 - 48050 = 1050.0,$$

$$S_{yy} = \sum y_i^2 - n\bar{y}^2 = 1014.6 - 8(10.925)^2 \approx 1014.6 - 954.845 = 59.755,$$

$$S_{xy} = \sum x_i y_i - n\bar{x}\bar{y} = 6525.0 - 8(77.5)(10.925) \approx 6525.0 - 6773.5 = -248.5.$$

(a)

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{-248.5}{1050.0} \approx -0.2367, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 10.925 - (-0.2367)(77.5) \approx 29.267.$$

$$\hat{y} = 29.267 - 0.2367 x.$$

(b) $SCE = \sum (y_i - \hat{y}_i)^2 \approx 0.943$ (calculado a partir de los residuos), $SCT = S_{yy} \approx 59.755$, luego $SCR = SCT - SCE \approx 58.812$ y

$$R^2 = \frac{SCR}{SCT} \approx \frac{58.812}{59.755} \approx 0.9842.$$

El modelo lineal explica aproximadamente el 98.4% de la variabilidad observada en la humedad residual; el ajuste es muy bueno.

(c) $\hat{\beta}_1 \approx -0.237 < 0$: por cada grado adicional de temperatura del horno, la humedad residual esperada **disminuye** en aproximadamente 0.237 puntos porcentuales, dentro del rango de temperaturas estudiado (60 a 95 °C). Esto es consistente con lo esperado en un proceso de secado: a mayor temperatura, mayor evaporación de humedad.

Ejercicio 2. Con los datos del Ejercicio 1:

- (a) Pruebe, al nivel $\alpha = 0.05$, si existe relación lineal significativa entre la temperatura y la humedad residual ($H_0 : \beta_1 = 0$ vs. $H_1 : \beta_1 \neq 0$).
- (b) Construya un intervalo de confianza del 95 % para β_1 .

Solución.

$$CME = SCE/(n - 2) = 0.943/6 \approx 0.1572.$$

$$\widehat{e}(\hat{\beta}_1) = \sqrt{CME/S_{xx}} = \sqrt{0.1572/1050.0} \approx 0.01224.$$

(a) Estadístico de prueba:

$$T = \frac{\hat{\beta}_1 - 0}{\widehat{e}(\hat{\beta}_1)} = \frac{-0.2367}{0.01224} \approx -19.34.$$

Valor crítico: $t_{6;0.025} = 2.447$. Como $|T| = 19.34 > 2.447$, se **rechaza** H_0 : existe evidencia muy fuerte de relación lineal (significativa) entre la temperatura y la humedad residual.

(b) IC del 95 % para β_1 :

$$-0.2367 \pm 2.447(0.01224) = -0.2367 \pm 0.0299 \Rightarrow (-0.2667, -0.2068).$$

El intervalo no contiene al 0, confirmando el rechazo de H_0 del inciso (a). Con 95 % de confianza, cada grado adicional de temperatura reduce la humedad residual esperada entre 0.207 y 0.267 puntos porcentuales.

Ejercicio 3. Una cadena de tiendas quiere estudiar la relación entre el **gasto mensual en publicidad** X (en miles de \$) y las **ventas mensuales** Y (en miles de \$) de $n = 7$ sucursales:

x_i	10	15	20	25	30	35	40
y_i	105	120	138	141	158	163	180

- (a) Ajuste la recta de mínimos cuadrados.
- (b) Arme la tabla ANOVA de la regresión y pruebe la significancia global del modelo con un estadístico F , al nivel $\alpha = 0.05$.

Solución. $n = 7$: $\sum x_i = 175$, $\bar{x} = 25$; $\sum y_i = 1005$, $\bar{y} \approx 143.571$; $\sum x_i^2 = 5075$; $\sum y_i^2 = 148283$; $\sum x_i y_i = 26780$.

$$S_{xx} = 5075 - 7(25)^2 = 5075 - 4375 = 700, \quad S_{yy} = 148283 - 7(143.571)^2 \approx 3993.71,$$

$$S_{xy} = 26780 - 7(25)(143.571) \approx 26780 - 25125 = 1655.0.$$

(a)

$$\hat{\beta}_1 = \frac{1655.0}{700} \approx 2.364, \quad \hat{\beta}_0 = 143.571 - 2.364(25) \approx 84.464.$$

$$\hat{y} = 84.464 + 2.364x.$$

(b) $SCR = \hat{\beta}_1 S_{xy} = 2.364(1655.0) \approx 3912.89$; $SCT = S_{yy} \approx 3993.71$; $SCE = SCT - SCR \approx 80.82$.

Con $F_{1,5;0.05} = 6.61$: como $F_{\text{calc}} \approx 242.07 \gg 6.61$, se **rechaza** $H_0 : \beta_1 = 0$. La regresión es altamente significativa: el gasto en publicidad explica de manera significativa las variaciones en las ventas.

Ejercicio 4. Con los datos y el ajuste del Ejercicio 3:

Fuente	SC	gl	CM	F
Regresión	3912.89	1	3912.89	242.07
Error	80.82	5	16.164	
Total	3993.71	6		

- (a) Estime la venta media esperada para una sucursal con $x_0 = 28$ (miles de \$ de publicidad) y construya un intervalo de confianza del 95 % para esa respuesta media.
- (b) Construya un intervalo de predicción del 95 % para las ventas de una **nueva** sucursal particular que invierta $x_0 = 28$.
- (c) Compare la amplitud de ambos intervalos y explique por qué difieren.

Solución. $CME = 16.164$, $t_{5;0.025} = 2.571$.

(a) $\hat{y}_0 = 84.464 + 2.364(28) \approx 150.65$.

$$\hat{e}e(\hat{y}_0) = \sqrt{CME \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]} = \sqrt{16.164 \left[\frac{1}{7} + \frac{(28 - 25)^2}{700} \right]} = \sqrt{16.164(0.15571)} \approx 1.587.$$

IC 95 % para la respuesta media: $150.65 \pm 2.571(1.587) \approx (146.57, 154.73)$ miles de \$.

(b)

$$\hat{e}e_{\text{pred}} = \sqrt{CME \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]} = \sqrt{16.164(1.15571)} \approx 4.323.$$

Intervalo de predicción 95 %: $150.65 \pm 2.571(4.323) \approx (139.53, 161.77)$ miles de \$.

(c) El intervalo de predicción (b) es notablemente más ancho que el de la respuesta media (a), porque además de la incertidumbre en la estimación de la recta (presente en ambos), incorpora la variabilidad propia de una observación individual nueva (+1 dentro de la raíz).

Ejercicio 5. Un analista ajustó una regresión lineal simple con $n = 12$ observaciones y obtuvo la siguiente salida parcial:

$$S_{xx} = 840, \quad S_{xy} = 630, \quad SCT = 520, \quad SCE = 126.$$

- (a) Complete los valores de $\hat{\beta}_1$, SCR , R^2 y CME .
- (b) Pruebe $H_0 : \beta_1 = 0$ mediante un estadístico F , al nivel $\alpha = 0.05$ (use $F_{1,10;0.05} = 4.96$).

Solución. (a)

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{630}{840} = 0.75.$$

$$SCR = SCT - SCE = 520 - 126 = 394.$$

$$R^2 = \frac{SCR}{SCT} = \frac{394}{520} \approx 0.7577.$$

$$CME = \frac{SCE}{n - 2} = \frac{126}{10} = 12.6.$$

(b)

$$F = \frac{SCR/1}{SCE/(n - 2)} = \frac{394}{12.6} \approx 31.27.$$

Como $F_{\text{calc}} \approx 31.27 > 4.96 = F_{1,10;0.05}$, se **rechaza** $H_0 : \beta_1 = 0$: la regresión es significativa al 5 %.

Ejercicio 6. Indique si cada afirmación es **verdadera** o **falsa**, justificando brevemente.

- (a) En la recta de mínimos cuadrados, la suma de los residuos $\sum e_i$ es siempre igual a 0.
- (b) Un valor de R^2 alto garantiza que X es la **causa** de los cambios observados en Y .
- (c) Si $\hat{\beta}_1 > 0$, entonces necesariamente el coeficiente de correlación r también es positivo.
- (d) La recta de mínimos cuadrados minimiza la suma de las distancias **perpendiculares** de los puntos a la recta.
- (e) Un único punto atípico (outlier), alejado de la nube de puntos en la dirección de x , puede modificar sustancialmente la pendiente estimada $\hat{\beta}_1$.

Solución. (a) **Verdadero.** Es consecuencia directa de la primera ecuación normal, $\sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$.

(b) **Falso.** R^2 mide la proporción de variabilidad de Y explicada **linealmente** por X dentro de los datos observados, pero correlación (o buen ajuste) no implica causalidad: podría existir una variable de confusión, o la relación podría ser casual dentro del rango estudiado.

(c) **Verdadero.** $\hat{\beta}_1 = S_{xy}/S_{xx}$ y $r = S_{xy}/\sqrt{S_{xx}S_{yy}}$ comparten el mismo numerador S_{xy} , y $S_{xx}, S_{yy} > 0$; por lo tanto $\hat{\beta}_1$ y r tienen siempre el mismo signo.

(d) **Falso.** Minimiza la suma de las distancias **verticales** al cuadrado (en la dirección de Y), no las distancias perpendiculares (eso correspondería a otro método, la regresión ortogonal o *total least squares*).

(e) **Verdadero.** Un valor de x muy alejado del resto (alto *leverage*) tiene gran influencia en la pendiente estimada, ya que $\hat{\beta}_1 = \sum c_i y_i$ con $c_i = (x_i - \bar{x})/S_{xx}$: cuanto más lejos está x_i de $\bar{x}$, mayor es $|c_i|$ y mayor su peso en la estimación.

Ejercicio 7. Se estudia la relación entre la **antigüedad** X de una máquina (en años) y su **costo anual de mantenimiento** Y (en miles de \$), sobre $n = 9$ máquinas similares:

x_i (años)	1	2	3	4	5	6	7	8	9
y_i (miles \$)	2.1	2.6	3.0	3.8	4.1	5.0	5.4	6.3	6.9

- (a) Ajuste la recta de mínimos cuadrados y calcule R^2 .
- (b) Pruebe $H_0 : \beta_1 = 0$ vs. $H_1 : \beta_1 > 0$ al nivel $\alpha = 0.01$ (prueba unilateral, pues se espera que el costo aumente con la antigüedad).
- (c) Estime el costo medio esperado de mantenimiento para una máquina de $x_0 = 6.5$ años, con un intervalo de confianza del 95 %.

Solución. $n = 9$: $\sum x_i = 45$, $\bar{x} = 5$; $\sum y_i = 39.2$, $\bar{y} \approx 4.3556$; $\sum x_i^2 = 285$; $\sum y_i^2 = 192.88$; $\sum x_i y_i = 232.3$.

$$S_{xx} = 285 - 9(5)^2 = 285 - 225 = 60, \quad S_{yy} = 192.88 - 9(4.3556)^2 \approx 22.142,$$

$$S_{xy} = 232.3 - 9(5)(4.3556) \approx 232.3 - 196.0 = 36.3.$$

(a)

$$\hat{\beta}_1 = \frac{36.3}{60} = 0.605, \quad \hat{\beta}_0 = 4.3556 - 0.605(5) \approx 1.3306.$$

$$\hat{y} = 1.331 + 0.605x.$$

$SCR = \hat{\beta}_1 S_{xy} = 0.605(36.3) \approx 21.962$; $SCE = SCT - SCR \approx 22.142 - 21.962 = 0.181$; $R^2 \approx 21.962/22.142 \approx 0.9918$: el modelo explica cerca del 99.2 % de la variabilidad del costo de mantenimiento.

$$\text{(b)} \ CME = SCE/(n - 2) = 0.180/7 \approx 0.02582; \widehat{ee}(\hat{\beta}_1) = \sqrt{0.02582/60} \approx 0.02074.$$

$$T = \frac{0.605}{0.02074} \approx 29.17.$$

Valor crítico unilateral: $t_{7;0.01} = 2.998$. Como $T \approx 29.17 \gg 2.998$, se **rechaza** H_0 : hay evidencia contundente de que el costo de mantenimiento aumenta con la antigüedad.

$$\text{(c)} \ \hat{y}_0 = 1.331 + 0.605(6.5) \approx 5.264.$$

$$\widehat{ee}(\hat{y}_0) = \sqrt{0.02582 \left[\frac{1}{9} + \frac{(6.5 - 5)^2}{60} \right]} = \sqrt{0.02582(0.1486)} \approx 0.0619.$$

Con $t_{7;0.025} = 2.365$: IC 95 % = $5.264 \pm 2.365(0.0619) \approx (5.117, 5.411)$ miles de \$.