

Clase 29: Regresión lineal simple

Unidad 8: Modelos lineales

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

- 1 Motivación: relación entre dos variables
- 2 El modelo de regresión lineal simple
- 3 Estimación por mínimos cuadrados
- 4 Propiedades de los estimadores
- 5 Bondad del ajuste
- 6 Ejemplo numérico completo
- 7 Resumen

De la correlación a la regresión

En unidades anteriores estudiamos cómo describir la relación *conjunta* entre dos variables aleatorias. Ahora nos interesa un problema distinto:

Pregunta central

Dado un valor de una variable **explicativa** (o regresora) X , ¿podemos **predecir** o **explicar** el valor de una variable **respuesta** Y ?


Ejemplos

- X : horas de estudio; Y : nota en un examen.
- X : temperatura del horno; Y : resistencia de una pieza cerámica.
- X : dosis de un fertilizante; Y : rendimiento de un cultivo.
- X : antigüedad de una máquina; Y : costo de mantenimiento anual.

La **teoría de regresión** propone un modelo matemático-estadístico para esta relación, y la **correlación** mide su intensidad.

Diagrama de dispersión

La primera herramienta exploratoria es el **diagrama de dispersión**: se grafican los pares (x_i, y_i) observados.



Si los puntos se agrupan alrededor de una tendencia **lineal**, tiene sentido buscar la “mejor” recta que resuma esa tendencia: ese es el objetivo de la **regresión lineal simple**.

Planteo del modelo

Definition (Modelo de regresión lineal simple)

Suponemos que la variable respuesta Y se relaciona con la variable regresora (no aleatoria, controlada o fijada) X mediante

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

donde:

- β_0 : **ordenada al origen** (intercepto), parámetro desconocido.
- β_1 : **pendiente**, parámetro desconocido; mide el cambio esperado en Y por unidad de cambio en X .
- ε : **error aleatorio**, no observable, que recoge la variabilidad de Y no explicada por X .

Supuestos del modelo

Supuestos sobre el error ε

- 1 $E(\varepsilon) = 0$ (en promedio, el modelo lineal es correcto).
- 2 $V(\varepsilon) = \sigma^2$, constante para todo X (**homocedasticidad**).
- 3 Los errores correspondientes a observaciones distintas son **independientes** entre sí.
- 4 (Para inferencia, Clase 30) $\varepsilon \sim N(0, \sigma^2)$.

Consecuencia

Bajo los supuestos 1 y 2, para cada valor fijo x de la regresora:

$$E(Y \mid X = x) = \beta_0 + \beta_1 x, \quad V(Y \mid X = x) = \sigma^2.$$

La recta $\beta_0 + \beta_1 x$ describe cómo cambia la **media** de Y con x ; σ^2 mide la dispersión alrededor de esa media, la misma para todo x .

Datos y notación

Disponemos de una muestra de n pares de observaciones

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n),$$

donde cada y_i se interpreta como una realización de

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n,$$

con $\varepsilon_1, \dots, \varepsilon_n$ independientes, $E(\varepsilon_i) = 0$, $V(\varepsilon_i) = \sigma^2$.

Objetivo

Estimar β_0 y β_1 a partir de los datos, obteniendo la **recta ajustada**

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x,$$

que sea, en algún sentido preciso, la que mejor se ajusta a la nube de puntos.

El criterio de mínimos cuadrados

Para cada posible recta $\hat{y} = b_0 + b_1x$, el **residuo** de la observación i es

$$e_i = y_i - (b_0 + b_1x_i),$$

la distancia vertical entre el punto observado y la recta.

Método de mínimos cuadrados

Elegimos $b_0 = \hat{\beta}_0$, $b_1 = \hat{\beta}_1$ que minimizan la **suma de cuadrados de los residuos**

$$S(b_0, b_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - b_0 - b_1x_i)^2.$$

Se penalizan más los residuos grandes (al elevarlos al cuadrado) y el problema tiene solución analítica simple, como veremos a continuación.

Deducción de las ecuaciones normales

Para minimizar $S(b_0, b_1)$ igualamos a cero las derivadas parciales:

$$\frac{\partial S}{\partial b_0} = -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) = 0,$$

$$\frac{\partial S}{\partial b_1} = -2 \sum_{i=1}^n x_i (y_i - b_0 - b_1 x_i) = 0.$$

Reordenando se obtienen las **ecuaciones normales**:

$$\begin{cases} \sum_{i=1}^n y_i = n b_0 + b_1 \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i y_i = b_0 \sum_{i=1}^n x_i + b_1 \sum_{i=1}^n x_i^2 \end{cases}$$

un sistema lineal de 2 ecuaciones con 2 incógnitas (b_0, b_1) .

Resolución: fórmulas de los estimadores

De la primera ecuación normal, dividiendo por n :

$$\bar{y} = b_0 + b_1 \bar{x} \implies \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

Sustituyendo en la segunda ecuación y despejando b_1 se obtiene

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}},$$

donde se define

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_i x_i y_i - n \bar{x} \bar{y}, \quad S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_i x_i^2 - n \bar{x}^2.$$

Estimadores de mínimos cuadrados

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Recta ajustada y residuos

Recta de regresión estimada (recta de mínimos cuadrados)

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i, \quad i = 1, \dots, n.$$

Definition

El **residuo** de la observación i es $e_i = y_i - \hat{y}_i$, el valor **observado** menos el **predicho** por el modelo ajustado.

Propiedades algebraicas inmediatas de la recta de mínimos cuadrados

- $\sum_{i=1}^n e_i = 0$ (los residuos suman cero).
- $\sum_{i=1}^n x_i e_i = 0$ (los residuos son “no correlacionados” con x_i).
- La recta ajustada pasa por el punto $(\bar{x}, \bar{y})$.

Insesgadez de $\hat{\beta}_1$

Bajo el modelo $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ con $E(\varepsilon_i) = 0$, veamos que $\hat{\beta}_1$ es insesgado. Escribiendo $\hat{\beta}_1 = \sum_i c_i Y_i$ con $c_i = \frac{x_i - \bar{x}}{S_{xx}}$ (nótese $\sum_i c_i = 0$ y $\sum_i c_i x_i = 1$):

$$E(\hat{\beta}_1) = \sum_{i=1}^n c_i E(Y_i) = \sum_{i=1}^n c_i (\beta_0 + \beta_1 x_i) = \beta_0 \underbrace{\sum_i c_i}_{=0} + \beta_1 \underbrace{\sum_i c_i x_i}_{=1} = \beta_1.$$

Conclusión

$$E(\hat{\beta}_1) = \beta_1.$$

$\hat{\beta}_1$ es un **estimador insesgado** de la pendiente poblacional β_1 .

Insesgadez de $\hat{\beta}_0$

Como $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}$ y $E(\bar{Y}) = \beta_0 + \beta_1 \bar{x}$ (promediando el modelo sobre las n observaciones):

$$E(\hat{\beta}_0) = E(\bar{Y}) - \bar{x} E(\hat{\beta}_1) = (\beta_0 + \beta_1 \bar{x}) - \bar{x} \beta_1 = \beta_0.$$

Conclusión

$$E(\hat{\beta}_0) = \beta_0.$$

$\hat{\beta}_0$ también es insesgado. Ambos estimadores son, además, **lineales** en las Y_i y, bajo los supuestos del modelo, los de **menor varianza** entre todos los estimadores lineales insesgados (teorema de Gauss–Markov, que se enuncia sin demostración en este curso).

Descomposición de la variabilidad de Y

Definimos las siguientes sumas de cuadrados:

$$SCT = \sum_{i=1}^n (y_i - \bar{y})^2 \quad (\text{total}), \quad SCR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \quad (\text{regresión}),$$

$$SCE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_i e_i^2 \quad (\text{error o residual}).$$

Identidad fundamental

$$SCT = SCR + SCE.$$

La variabilidad total de Y se descompone en la parte **explicada** por la recta de regresión (SCR) y la parte **no explicada**, atribuida al error (SCE). (Esta misma idea de descomposición reaparecerá, con otro nombre, en el análisis de la varianza de las Clases 31–32.)

Coeficiente de determinación R^2

Definition

El **coeficiente de determinación** es

$$R^2 = \frac{SCR}{SCT} = 1 - \frac{SCE}{SCT}, \quad 0 \leq R^2 \leq 1.$$

Interpretación

R^2 es la **proporción de la variabilidad total de Y que es explicada por la relación lineal con X .**

- R^2 cercano a 1: el ajuste lineal explica casi toda la variabilidad de Y .
- R^2 cercano a 0: la recta ajustada explica muy poco; X aporta escasa información lineal sobre Y .

Coeficiente de correlación muestral

Definition

El **coeficiente de correlación muestral (de Pearson)** entre X e Y es

$$r = \frac{S_{xy}}{\sqrt{S_{xx} S_{yy}}}, \quad \text{con } S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2 = SCT.$$

Propiedades

- $-1 \leq r \leq 1$; mide la fuerza y el sentido de la asociación **lineal**.
- $r > 0$: asociación lineal directa; $r < 0$: inversa; $r \approx 0$: sin asociación lineal apreciable.
- Se relaciona con R^2 mediante $R^2 = r^2$ en el modelo de regresión simple.
- $\hat{\beta}_1$ y r tienen siempre el mismo signo, pues ambos dependen de S_{xy} .

Ejemplo: resistencia de una soldadura

Un ingeniero estudia la relación entre el **tiempo de soldadura** X (segundos) y la **resistencia a la tracción** Y (kg) de una unión, sobre $n = 8$ probetas.

i	1	2	3	4	5	6	7	8
x_i (seg)	2	3	4	5	6	7	8	9
y_i (kg)	32	38	41	45	48	53	55	61

Cuadro 1: Datos de tiempo de soldadura y resistencia

Queremos: (a) la recta de mínimos cuadrados; (b) R^2 y r ; (c) interpretar los resultados.

Ejemplo: cálculos preliminares

$$n = 8, \quad \sum x_i = 44, \quad \bar{x} = 5.5, \quad \sum y_i = 373, \quad \bar{y} = 46.625$$
$$\sum x_i^2 = 284, \quad \sum x_i y_i = 2215$$

Entonces:

$$S_{xx} = \sum x_i^2 - n\bar{x}^2 = 284 - 8(5.5)^2 = 284 - 242 = 42,$$
$$S_{xy} = \sum x_i y_i - n\bar{x}\bar{y} = 2215 - 8(5.5)(46.625) = 2215 - 2051.5 = 163.5.$$

Ejemplo: recta ajustada

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{163.5}{42} \approx 3.893,$$


$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 46.625 - 3.893(5.5) \approx 25.214.$$

Recta de mínimos cuadrados

$$\hat{y} = 25.214 + 3.893x.$$

Interpretación: por cada segundo adicional de soldadura, la resistencia esperada aumenta en aproximadamente 3.89 kg. Para $x = 0$ el modelo predice $\hat{y} \approx 25.21$ kg, aunque extrapolar fuera del rango observado (2 a 9 seg) debe hacerse con cautela.

Ejemplo: gráfico de la recta ajustada



Ejemplo: S_{yy} , R^2 y r

Con $\sum y_i^2 = 18033$:

$$S_{yy} = \sum y_i^2 - n\bar{y}^2 = 18033 - 8(46.625)^2 = 18033 - 17391.125 = 641.875.$$

$$r = \frac{S_{xy}}{\sqrt{S_{xx} S_{yy}}} = \frac{163.5}{\sqrt{42 \times 641.875}} = \frac{163.5}{\sqrt{26958.75}} \approx \frac{163.5}{164.19} \approx 0.9958.$$

$$R^2 = r^2 \approx 0.9916.$$

Conclusión

La correlación lineal es muy fuerte y positiva ($r \approx 0.996$); el modelo lineal explica aproximadamente el 99.2 % de la variabilidad observada en la resistencia. El ajuste lineal es excelente para estos datos.

Resumen de la clase

- El **modelo de regresión lineal simple** es $Y = \beta_0 + \beta_1 X + \varepsilon$, con $E(\varepsilon) = 0$, $V(\varepsilon) = \sigma^2$ constante y errores independientes.
- Los estimadores de **mínimos cuadrados** minimizan $\sum e_i^2$ y se obtienen resolviendo las ecuaciones normales:

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

- $\hat{\beta}_0$ y $\hat{\beta}_1$ son estimadores **insesgados** de β_0 y β_1 .
- La variabilidad total se descompone: $SCT = SCR + SCE$.
- El **coeficiente de determinación** $R^2 = SCR/SCT$ mide qué proporción de la variabilidad de Y explica el modelo; el **coeficiente de correlación** r mide la fuerza de la asociación lineal, con $R^2 = r^2$.
- Próxima clase: distribución de los estimadores, pruebas de hipótesis e intervalos de confianza para β_0 y β_1 .