

Clase 30: Inferencia en el modelo de regresión

Unidad 8: Modelos lineales

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

- 1 El supuesto de normalidad
- 2 Distribución de los estimadores
- 3 Estimación de la varianza del error
- 4 Inferencia sobre la pendiente β_1
- 5 Significancia global de la regresión
- 6 Predicción
- 7 Verificación de los supuestos
- 8 Ejemplo numérico completo
- 9 Resumen

De la estimación puntual a la inferencia

En la Clase 29 obtuvimos los estimadores de mínimos cuadrados $\hat{\beta}_0, \hat{\beta}_1$ y vimos que son insesgados. Para construir **pruebas de hipótesis** e **intervalos de confianza** necesitamos conocer su **distribución muestral**, lo cual requiere un supuesto adicional.

Supuesto de normalidad

$$\varepsilon_i \sim N(0, \sigma^2), \quad \varepsilon_1, \dots, \varepsilon_n \text{ independientes,}$$

o, equivalentemente,

$$Y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2), \quad Y_1, \dots, Y_n \text{ independientes.}$$

Bajo este supuesto, como $\hat{\beta}_0$ y $\hat{\beta}_1$ son **combinaciones lineales** de las Y_i , también tienen distribución normal.

Distribución de $\hat{\beta}_1$

Recordando que $\hat{\beta}_1 = \sum_i c_i Y_i$ con $c_i = (x_i - \bar{x})/S_{xx}$, y que una combinación lineal de normales independientes es normal:

Distribución de $\hat{\beta}_1$

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right).$$

Esperanza: ya vimos $E(\hat{\beta}_1) = \beta_1$ (Clase 29).

Varianza:

$$V(\hat{\beta}_1) = \sum_i c_i^2 V(Y_i) = \sigma^2 \sum_i c_i^2 = \sigma^2 \sum_i \frac{(x_i - \bar{x})^2}{S_{xx}^2} = \frac{\sigma^2}{S_{xx}}.$$

A mayor dispersión de los x_i (mayor S_{xx}), menor es la varianza de $\hat{\beta}_1$: los datos más “separados” en X estiman la pendiente con mayor precisión.

Distribución de $\hat{\beta}_0$

De manera análoga, usando $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}$:

Distribución de $\hat{\beta}_0$

$$\hat{\beta}_0 \sim N\left(\beta_0, \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right] \right).$$

Ambos estimadores son normales, insesgados, pero **no independientes** entre sí (están correlacionados a través de $\bar{x}$), salvo en el caso particular $\bar{x} = 0$.

Cuadrado medio del error

El parámetro σ^2 (varianza del error) es desconocido y debe estimarse a partir de los residuos.

Definition

El **cuadrado medio del error** es

$$CME = \frac{SCE}{n-2} = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n-2} = \frac{\sum_{i=1}^n e_i^2}{n-2}.$$

¿Por qué $n - 2$ grados de libertad?

Se “pierden” 2 grados de libertad porque SCE se calcula a partir de los residuos de una recta ajustada con 2 parámetros estimados ($\hat{\beta}_0$ y $\hat{\beta}_1$). Puede probarse que

$$E(CME) = \sigma^2,$$

es decir, CME es un estimador **insesgado** de σ^2 . Se define además $\hat{\sigma} = \sqrt{CME}$, el **error estándar de la estimación**.

Errores estándar de $\hat{\beta}_0$ y $\hat{\beta}_1$

Reemplazando σ^2 por su estimador CME obtenemos los **errores estándar estimados**:

$$\widehat{ee}(\hat{\beta}_1) = \sqrt{\frac{CME}{S_{xx}}}, \quad \widehat{ee}(\hat{\beta}_0) = \sqrt{CME \left[\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}.$$

Resultado clave para la inferencia

Bajo normalidad de los errores,

$$\frac{\hat{\beta}_1 - \beta_1}{\widehat{ee}(\hat{\beta}_1)} \sim t_{n-2}, \quad \frac{\hat{\beta}_0 - \beta_0}{\widehat{ee}(\hat{\beta}_0)} \sim t_{n-2},$$

distribución t de Student con $n - 2$ grados de libertad (los mismos que en la estimación de una media con σ desconocida, pero aquí “se gastan” 2 grados de libertad en vez de 1).

Intervalo de confianza para β_1

IC del $(1 - \alpha)100\%$ para β_1

$$\hat{\beta}_1 \pm t_{n-2, \alpha/2} \widehat{ee}(\hat{\beta}_1).$$

Prueba de hipótesis para β_1

La hipótesis de mayor interés práctico es

$$H_0 : \beta_1 = 0 \quad \text{vs.} \quad H_1 : \beta_1 \neq 0$$

(u opciones unilaterales), ya que $\beta_1 = 0$ significa que X **no aporta información lineal** sobre Y (no hay relación lineal). El estadístico de prueba es

$$T = \frac{\hat{\beta}_1 - 0}{\widehat{ee}(\hat{\beta}_1)} \sim t_{n-2} \quad \text{bajo } H_0,$$

y se rechaza H_0 si $|T| > t_{n-2, \alpha/2}$ (bilateral) al nivel α .

Inferencia sobre β_0

De manera totalmente análoga:

IC e hipótesis para β_0

$$\text{IC: } \hat{\beta}_0 \pm t_{n-2, \alpha/2} \widehat{ee}(\hat{\beta}_0), \quad T = \frac{\hat{\beta}_0 - \beta_{0,0}}{\widehat{ee}(\hat{\beta}_0)} \sim t_{n-2} \text{ bajo } H_0 : \beta_0 = \beta_{0,0}.$$

Observación

En la mayoría de las aplicaciones el interés central está en β_1 (existencia y magnitud de la relación lineal), ya que β_0 suele carecer de interpretación práctica directa (con frecuencia representa una extrapolación fuera del rango de los datos).

Prueba F de significancia de la regresión

En regresión lineal **simple** (una sola regresora), probar $H_0 : \beta_1 = 0$ mediante el estadístico t es equivalente a una prueba **F** basada en la descomposición $SCT = SCR + SCE$:

$$F = \frac{SCR/1}{SCE/(n-2)} = \frac{CMR}{CME} \sim F_{1, n-2} \quad \text{bajo } H_0 : \beta_1 = 0.$$

Relación entre T y F

Puede demostrarse que $F = T^2$, de modo que ambas pruebas llevan siempre a la misma conclusión en regresión simple. La prueba F es la que se generaliza naturalmente a regresión **múltiple** y al análisis de la varianza (Clases 31–32).

Tabla ANOVA de la regresión

Es habitual resumir la descomposición de la variabilidad en una **tabla ANOVA de regresión**:

Fuente	SC	gl	CM	F
Regresión	SCR	1	$CMR = SCR/1$	CMR/CME
Error	SCE	$n - 2$	$CME = SCE/(n - 2)$	
Total	SCT	$n - 1$		

Cuadro 1: Tabla ANOVA para la regresión lineal simple

Nótese que los grados de libertad también se descomponen: $n - 1 = 1 + (n - 2)$.

Predicción de la respuesta media

Para un valor particular x_0 de la regresora, distinguimos dos problemas de predicción distintos.

(a) Respuesta media en x_0

Estimamos $E(Y | X = x_0) = \beta_0 + \beta_1 x_0$ mediante $\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$, con

$$V(\hat{y}_0) = \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right].$$

IC del $(1 - \alpha)100\%$ para la respuesta media:

$$\hat{y}_0 \pm t_{n-2, \alpha/2} \sqrt{CME \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]}.$$

Predicción de una observación individual

(b) Valor individual futuro en x_0

Predecimos una **nueva** observación $Y_0 = \beta_0 + \beta_1 x_0 + \varepsilon_0$ con el mismo punto $\hat{y}_0$, pero ahora hay que sumar también la variabilidad propia del nuevo error ε_0 :

$$V(Y_0 - \hat{y}_0) = \sigma^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right].$$

Intervalo de predicción del $(1 - \alpha)100\%$:

$$\hat{y}_0 \pm t_{n-2, \alpha/2} \sqrt{CME \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]}.$$

Comparación

El intervalo de **predicción** (b) es siempre más ancho que el de **respuesta media** (a), porque incorpora tanto la incertidumbre en la estimación de la recta como la variabilidad individual de una observación nueva. Ambos son más angostos cuanto más cerca está x_0 de $\bar{x}$.

Diagnóstico mediante el análisis de residuos

Toda la inferencia desarrollada (pruebas t , F , intervalos) depende de los supuestos de normalidad, homocedasticidad e independencia de los errores. En la práctica se verifican de manera **informal** mediante gráficos de los residuos $e_i = y_i - \hat{y}_i$.

Qué mirar en un gráfico de residuos vs. $\hat{y}_i$ (o vs. x_i)

- **Nube sin patrón**, dispersa aleatoriamente alrededor de 0: apoya los supuestos del modelo.
- **Forma de embudo** (residuos que crecen o decrecen en magnitud): indica **heterocedasticidad** (viola $V(\varepsilon) = \sigma^2$ constante).
- **Patrón curvo** (no aleatorio): sugiere que la relación no es lineal, o falta algún término en el modelo.
- Puntos muy alejados del resto: posibles **valores atípicos** (outliers), a investigar.

Observación

Un histograma o gráfico de probabilidad normal (Q-Q plot) de los residuos permite además evaluar informalmente el supuesto de normalidad.

Ejemplo: retomando la soldadura

Retomamos los datos de la Clase 29: tiempo de soldadura (X , segundos) y resistencia a la tracción (Y , kg), $n = 8$.

x_i	2	3	4	5	6	7	8	9
y_i	32	38	41	45	48	53	55	61

Ya sabemos: $\hat{\beta}_0 \approx 25.214$, $\hat{\beta}_1 \approx 3.893$, $S_{xx} = 42$, $S_{yy} = 641.875$, $S_{xy} = 163.5$, $\bar{x} = 5.5$.

$$SCR = \hat{\beta}_1 S_{xy} = \frac{S_{xy}^2}{S_{xx}} = \frac{163.5^2}{42} = \frac{26732.25}{42} \approx 636.482.$$

$$SCE = SCT - SCR = S_{yy} - SCR = 641.875 - 636.482 \approx 5.393.$$

Ejemplo: tabla ANOVA de la regresión

Fuente	SC	gl	CM	F
Regresión	636.482	1	636.482	708.1
Error	5.393	6	0.899	
Total	641.875	7		

$$CME = \frac{SCE}{n-2} = \frac{5.393}{6} \approx 0.899, \quad F = \frac{CMR}{CME} = \frac{636.482}{0.899} \approx 708.1.$$

Con $F_{1,6;0.05} = 5.99$: como $F = 708.1 \gg 5.99$, se **rechaza** $H_0 : \beta_1 = 0$: la regresión es altamente significativa.

Ejemplo: IC para β_1 y predicción

Con $CME = 0.899$, $\widehat{ee}(\hat{\beta}_1) = \sqrt{0.899/42} = \sqrt{0.02140} \approx 0.1463$.

IC del 95 % para β_1 ($t_{6;0.025} = 2.447$):

$$3.893 \pm 2.447(0.1463) = 3.893 \pm 0.358 \Rightarrow (3.535, 4.251).$$

Como el intervalo no contiene al 0, se confirma (por otra vía) el rechazo de $H_0 : \beta_1 = 0$.

Predicción en $x_0 = 6.5$ (respuesta media): $\hat{y}_0 = 25.214 + 3.893(6.5) \approx 50.518$ kg, con

$$\widehat{ee}(\hat{y}_0) = \sqrt{0.899 \left[\frac{1}{8} + \frac{(6.5-5.5)^2}{42} \right]} = \sqrt{0.899(0.1488)} \approx 0.366,$$

IC del 95 %: $50.518 \pm 2.447(0.366) \approx (49.62, 51.41)$ kg.

Para el valor **individual** futuro, $\widehat{ee} \approx 1.016$, y el intervalo de **predicción** del 95 % es $(48.03, 53.00)$ kg, claramente más ancho.

Ejemplo: síntesis de los resultados

Cantidad	Valor
$\hat{\beta}_1$ (pendiente)	3.893
IC 95 % para β_1	(3.535, 4.251)
$\hat{\beta}_0$ (ordenada)	25.214
CME	0.899
F (significancia global)	708.1
R^2	0.9916

Conclusión general del ejemplo: existe una relación lineal fuerte, positiva y altamente significativa entre el tiempo de soldadura y la resistencia a la tracción; el modelo ajustado explica más del 99 % de la variabilidad observada y permite predecir con buena precisión la resistencia media para tiempos dentro del rango estudiado.

Resumen de la clase

- Bajo normalidad de los errores, $\hat{\beta}_1 \sim N(\beta_1, \sigma^2/S_{xx})$ y $\hat{\beta}_0 \sim N(\beta_0, \sigma^2[\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}])$.
- $CME = SCE/(n-2)$ es un estimador insesgado de σ^2 ; con σ^2 estimado, los estadísticos estandarizados siguen t_{n-2} .
- Se construyen **IC** y **pruebas** t para β_0 y β_1 ; la prueba $H_0 : \beta_1 = 0$ es central: equivale a decir que X no explica linealmente a Y .
- La **prueba F** de significancia global ($CMR/CME \sim F_{1,n-2}$) es equivalente a la prueba t para β_1 en regresión simple ($F = T^2$).
- Se distinguen los IC para la **respuesta media** y el intervalo de **predicción** de una observación individual (este último siempre más ancho).
- Próxima clase: comparación de más de dos medias mediante **análisis de la varianza**.