

Clase 31: Análisis de la varianza de un factor

Unidad 8: Modelos lineales

Probabilidad y Estadística (5765)

Universidad Nacional del Sur
Departamento de Matemática

Contenidos

- 1 Motivación
- 2 Modelo de un factor de efectos fijos (Modelo I)
- 3 Descomposición de la variabilidad total
- 4 Grados de libertad
- 5 Tabla ANOVA
- 6 Fórmulas de cálculo
- 7 Verificación de los supuestos
- 8 Resumen

Comparando más de dos medias

En la Unidad 7 aprendimos a comparar las medias de **dos** poblaciones (prueba t para dos muestras). Muchas situaciones reales exigen comparar **tres o más**:

Ejemplos

- Rendimiento de un cultivo bajo k fertilizantes distintos.
- Resistencia de piezas fabricadas por k máquinas o k proveedores.
- Tiempo de reacción de un fármaco a k dosis diferentes.
- Puntaje de satisfacción del cliente en k sucursales de una empresa.

¿Por qué no hacer pruebas t de a pares?

Si hay $k = 5$ grupos, comparar de a pares requiere $\binom{5}{2} = 10$ pruebas t . Cada una tiene una probabilidad α de error de tipo I; al repetirlas, la probabilidad de cometer **al menos un** error de tipo I en el conjunto crece muy por encima de α . Se necesita un procedimiento que compare las k medias **simultáneamente**, con un único nivel de significación global: el **análisis de la varianza (ANOVA)**.

La idea central del ANOVA

Paradójicamente, para comparar **medias** el procedimiento analiza **varianzas**: se compara la variabilidad **entre** los grupos con la variabilidad **dentro** de cada grupo.

Intuición

- Si las medias poblacionales son todas iguales, la variabilidad *entre* las medias muestrales de los grupos debería ser del mismo orden que la variabilidad *dentro* de cada grupo (ambas reflejan solo el azar).
- Si las medias poblacionales difieren, la variabilidad *entre* grupos tiende a ser mayor que la variabilidad *dentro* de los grupos.

El análisis de la varianza formaliza esta comparación mediante un cociente de varianzas (estadístico F), que estudiaremos en la Clase 32.

Planteo del modelo

Se tienen k poblaciones (**niveles** o **tratamientos**) del factor en estudio, de las cuales se extraen muestras aleatorias independientes de tamaños $n_1, \dots, n_k$, con $N = \sum_{i=1}^k n_i$.

Definition (Modelo I: efectos fijos)

La observación j -ésima del tratamiento i se modela como

$$Y_{ij} = \mu + \tau_i + \varepsilon_{ij}, \quad i = 1, \dots, k, \quad j = 1, \dots, n_i,$$

donde:

- μ : media general (común a todos los tratamientos).
- τ_i : **efecto del tratamiento** i , fijo y desconocido, con $\sum_{i=1}^k n_i \tau_i = 0$ (restricción de identificabilidad).
- ε_{ij} : error aleatorio asociado a la observación (i, j) .

Se dice “Modelo I” o de **efectos fijos** porque los k niveles del factor son los únicos de interés

Media de cada tratamiento

Si definimos $\mu_i = \mu + \tau_i$ como la **media poblacional del tratamiento i** , el modelo dice simplemente

$$Y_{ij} = \mu_i + \varepsilon_{ij},$$

es decir, las observaciones del grupo i tienen media μ_i y fluctúan alrededor de ella por efecto del error aleatorio.

Hipótesis de interés

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_k \quad \text{vs.} \quad H_1 : \text{al menos dos } \mu_i \text{ son distintas.}$$

Equivalentemente, en términos de los efectos:

$$H_0 : \tau_1 = \tau_2 = \cdots = \tau_k = 0.$$

Supuestos del modelo

Supuestos sobre los errores

- 1 $E(\varepsilon_{ij}) = 0$ para todo i, j .
- 2 $V(\varepsilon_{ij}) = \sigma^2$, la **misma** para todos los tratamientos (**homocedasticidad**).
- 3 Los ε_{ij} son **independientes** entre sí.
- 4 $\varepsilon_{ij} \sim N(0, \sigma^2)$ (normalidad, necesaria para la prueba F).

Consecuencia

Bajo estos supuestos, $Y_{ij} \sim N(\mu_i, \sigma^2)$, con las k poblaciones teniendo la **misma varianza** σ^2 pero posiblemente distinta media μ_i . Estos tres supuestos (normalidad, homocedasticidad, independencia) son análogos a los del modelo de regresión (Clase 29) y se verifican en la práctica con gráficos de residuos y pruebas específicas.

Notación y organización de los datos

	Trat. 1	Trat. 2	...	Trat. k
	Y_{11}	Y_{21}	...	Y_{k1}
	Y_{12}	Y_{22}	...	Y_{k2}
	$\vdots$	$\vdots$		$\vdots$
	Y_{1n_1}	Y_{2n_2}	...	Y_{kn_k}
Medias	$\bar{Y}_{1\cdot}$	$\bar{Y}_{2\cdot}$	...	$\bar{Y}_{k\cdot}$

$$\bar{Y}_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} Y_{ij} \quad (\text{media del tratamiento } i), \quad \bar{Y}_{\cdot\cdot} = \frac{1}{N} \sum_{i=1}^k \sum_{j=1}^{n_i} Y_{ij} \quad (\text{media general}).$$

Suma de cuadrados total

Definition

La **suma de cuadrados total** mide la dispersión de todas las observaciones respecto de la media general:

$$SCTo = \sum_{i=1}^k \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{..})^2.$$

La idea del ANOVA es escribir esta variabilidad total como la suma de dos fuentes: la variabilidad **entre** tratamientos y la variabilidad **dentro** de los tratamientos.

Deducción de la descomposición

Sumamos y restamos $\bar{Y}_{i.}$ dentro de cada término:

$$Y_{ij} - \bar{Y}_{..} = (\bar{Y}_{i.} - \bar{Y}_{..}) + (Y_{ij} - \bar{Y}_{i.}).$$

Elevando al cuadrado y sumando sobre i, j :

$$\sum_{i,j} (Y_{ij} - \bar{Y}_{..})^2 = \sum_{i,j} (\bar{Y}_{i.} - \bar{Y}_{..})^2 + \sum_{i,j} (Y_{ij} - \bar{Y}_{i.})^2 + 2 \sum_{i,j} (\bar{Y}_{i.} - \bar{Y}_{..})(Y_{ij} - \bar{Y}_{i.}).$$

El término cruzado se anula

Para cada i fijo, $\sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{i.}) = 0$ (los residuos dentro de un grupo suman cero, igual que en regresión). Por lo tanto el término cruzado es idénticamente 0.

Identidad de la descomposición

Descomposición de la variabilidad total

$$SCTo = SCTr + SCE,$$

donde

$$SCTr = \sum_{i=1}^k n_i (\bar{Y}_{i.} - \bar{Y}_{..})^2 \quad (\text{suma de cuadrados } \mathbf{entre} \text{ tratamientos}),$$

$$SCE = \sum_{i=1}^k \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{i.})^2 \quad (\text{suma de cuadrados } \mathbf{dentro} \text{ de los tratamientos, o del error}).$$

Interpretación

$SCTr$ mide cuánto difieren las medias muestrales de los grupos entre sí (variabilidad “explicada” por el factor); SCE mide la variabilidad natural dentro de cada grupo, atribuible únicamente al azar. Es exactamente la misma lógica de $SCT = SCR + SCE$ vista en regresión (Clase 29), aplicada ahora a k grupos en lugar de una recta.

Grados de libertad de cada suma de cuadrados

Conteo de grados de libertad

- SCT_o : se calculan N desvíos respecto de $\bar{Y}_{..}$, con **una** restricción ($\sum(Y_{ij} - \bar{Y}_{..}) = 0$) $\Rightarrow N - 1$ grados de libertad.
- SCT_r : se calculan k desvíos $\bar{Y}_{i.} - \bar{Y}_{..}$, con **una** restricción $\Rightarrow k - 1$ grados de libertad.
- SCE : dentro de cada grupo i hay $n_i - 1$ grados de libertad (se estima μ_i con $\bar{Y}_{i.}$);
sumando sobre los k grupos, $\sum_{i=1}^k (n_i - 1) = N - k$ grados de libertad.

Los grados de libertad también se descomponen

$$N - 1 = (k - 1) + (N - k).$$

Cuadrados medios

Dividiendo cada suma de cuadrados por sus grados de libertad se obtienen los **cuadrados medios**:

$$CMTr = \frac{SCTr}{k-1} \quad (\text{cuadrado medio entre tratamientos}), \quad CME = \frac{SCE}{N-k} \quad (\text{cuadrado medio de error})$$

Propiedades (esperanzas de los cuadrados medios)

Puede demostrarse que, bajo el Modelo I:

$$E(CME) = \sigma^2 \quad \text{siempre (sin importar si } H_0 \text{ es cierta),}$$

$$E(CMTr) = \sigma^2 + \frac{\sum_{i=1}^k n_i \tau_i^2}{k-1} \geq \sigma^2,$$

con igualdad si y solo si todos los $\tau_i = 0$, es decir, bajo H_0 . Esto sugiere comparar $CMTr$ con CME : si son “parecidos”, apoya H_0 ; si $CMTr$ es notablemente mayor que CME , apoya H_1 . Esta comparación se formaliza con el estadístico F en la Clase 32.

Tabla ANOVA de un factor

Fuente de variación	SC	gl	CM	F
Entre tratamientos	$SCTr$	$k - 1$	$CMTr = \frac{SCTr}{k - 1}$	$\frac{CMTr}{CME}$
Dentro de tratamientos (error)	SCE	$N - k$	$CME = \frac{SCE}{N - k}$	
Total	$SCTo$	$N - 1$		

Cuadro 1: Tabla ANOVA de un factor (Modelo I)

Esta tabla resume toda la información necesaria para la prueba de hipótesis de igualdad de medias, que desarrollaremos en detalle, con un ejemplo numérico completo, en la próxima clase.

Fórmulas prácticas para calcular las sumas de cuadrados

En la práctica conviene usar fórmulas “de cálculo directo”, análogas a las de regresión, para evitar acumular error de redondeo:

Total, tratamiento por tratamiento

Sea $T_i = \sum_j Y_{ij}$ (total del tratamiento i) y $T = \sum_i T_i$ (total general). Entonces:

$$SCTo = \sum_{i,j} Y_{ij}^2 - \frac{T^2}{N},$$

$$SCTr = \sum_{i=1}^k \frac{T_i^2}{n_i} - \frac{T^2}{N},$$

$$SCE = SCTo - SCTr.$$

Estas son las fórmulas que usaremos en el ejemplo numérico de la Clase 32.

Diagnóstico de los supuestos del Modelo I

Al igual que en regresión (Clase 30), los supuestos de **normalidad**, **homocedasticidad** e **independencia** se verifican de manera informal a partir de los residuos $e_{ij} = Y_{ij} - \bar{Y}_{i.}$.

Herramientas usuales

- Gráfico de residuos vs. tratamiento (o vs. valores predichos $\bar{Y}_{i.}$): buscar dispersión similar en todos los grupos (homocedasticidad).
- Gráfico de caja (*boxplot*) comparativo de las k muestras: permite ver de un vistazo diferencias en posición y en dispersión.
- Q-Q plot o histograma de los residuos combinados: para evaluar normalidad.
- Regla práctica de homocedasticidad: si el mayor desvío estándar muestral no supera 2 veces al menor, la prueba F es razonablemente robusta a violaciones moderadas del supuesto.

Independencia

Se garantiza principalmente por el **diseño del experimento** (muestreo aleatorio, o aleatorización de las unidades experimentales a los tratamientos), más que por un chequeo posterior sobre los datos.

Diseño equilibrado vs. no equilibrado

Diseño equilibrado (*balanced*)

Cuando $n_1 = n_2 = \dots = n_k = n$ (igual número de observaciones por tratamiento), $N = nk$, y las fórmulas y el análisis son algo más simples; además la prueba F resulta más robusta ante apartamientos moderados de la homocedasticidad.

Diseño no equilibrado

Con n_i distintos, la teoría desarrollada (descomposición $SCTo = SCTr + SCE$, grados de libertad $N - 1 = (k - 1) + (N - k)$, tabla ANOVA) sigue siendo exactamente válida; solo cambian las fórmulas de cálculo, que ya contemplan n_i general.

En el ejemplo numérico de la Clase 32 usaremos un diseño equilibrado, con $n_i = 5$ para los $k = 4$ tratamientos.

Resumen de la clase

- El **análisis de la varianza** permite comparar simultáneamente $k \geq 2$ medias poblacionales, evitando la inflación del error de tipo I que produciría hacer múltiples pruebas t de a pares.
- El **Modelo I** (efectos fijos) postula $Y_{ij} = \mu + \tau_i + \varepsilon_{ij}$, con $\varepsilon_{ij} \sim N(0, \sigma^2)$ independientes, la misma varianza para todos los tratamientos.
- La hipótesis de interés es $H_0 : \mu_1 = \dots = \mu_k$ (equivalentemente, $\tau_1 = \dots = \tau_k = 0$).
- La variabilidad total se descompone: $SCTo = SCTr + SCE$, con grados de libertad $N - 1 = (k - 1) + (N - k)$.
- $E(CME) = \sigma^2$ siempre; $E(CMTr) = \sigma^2$ solo bajo H_0 , y es mayor si las medias difieren: esto motiva comparar $CMTr$ con CME .
- Próxima clase: el estadístico $F = CMTr/CME$, su distribución bajo H_0 , un ejemplo numérico completo y comparaciones múltiples.